

AI a paměť

Měření podobnosti fotografií pomocí
konvolučních sítí

Jiří Lukavský

Psychologický ústav AV ČR
Filozofická fakulta UK

Kde jsme

Jiří Lukavský
Filip Děchtěrenko



Problém

V kterém páru jsou si fotografie podobnější?



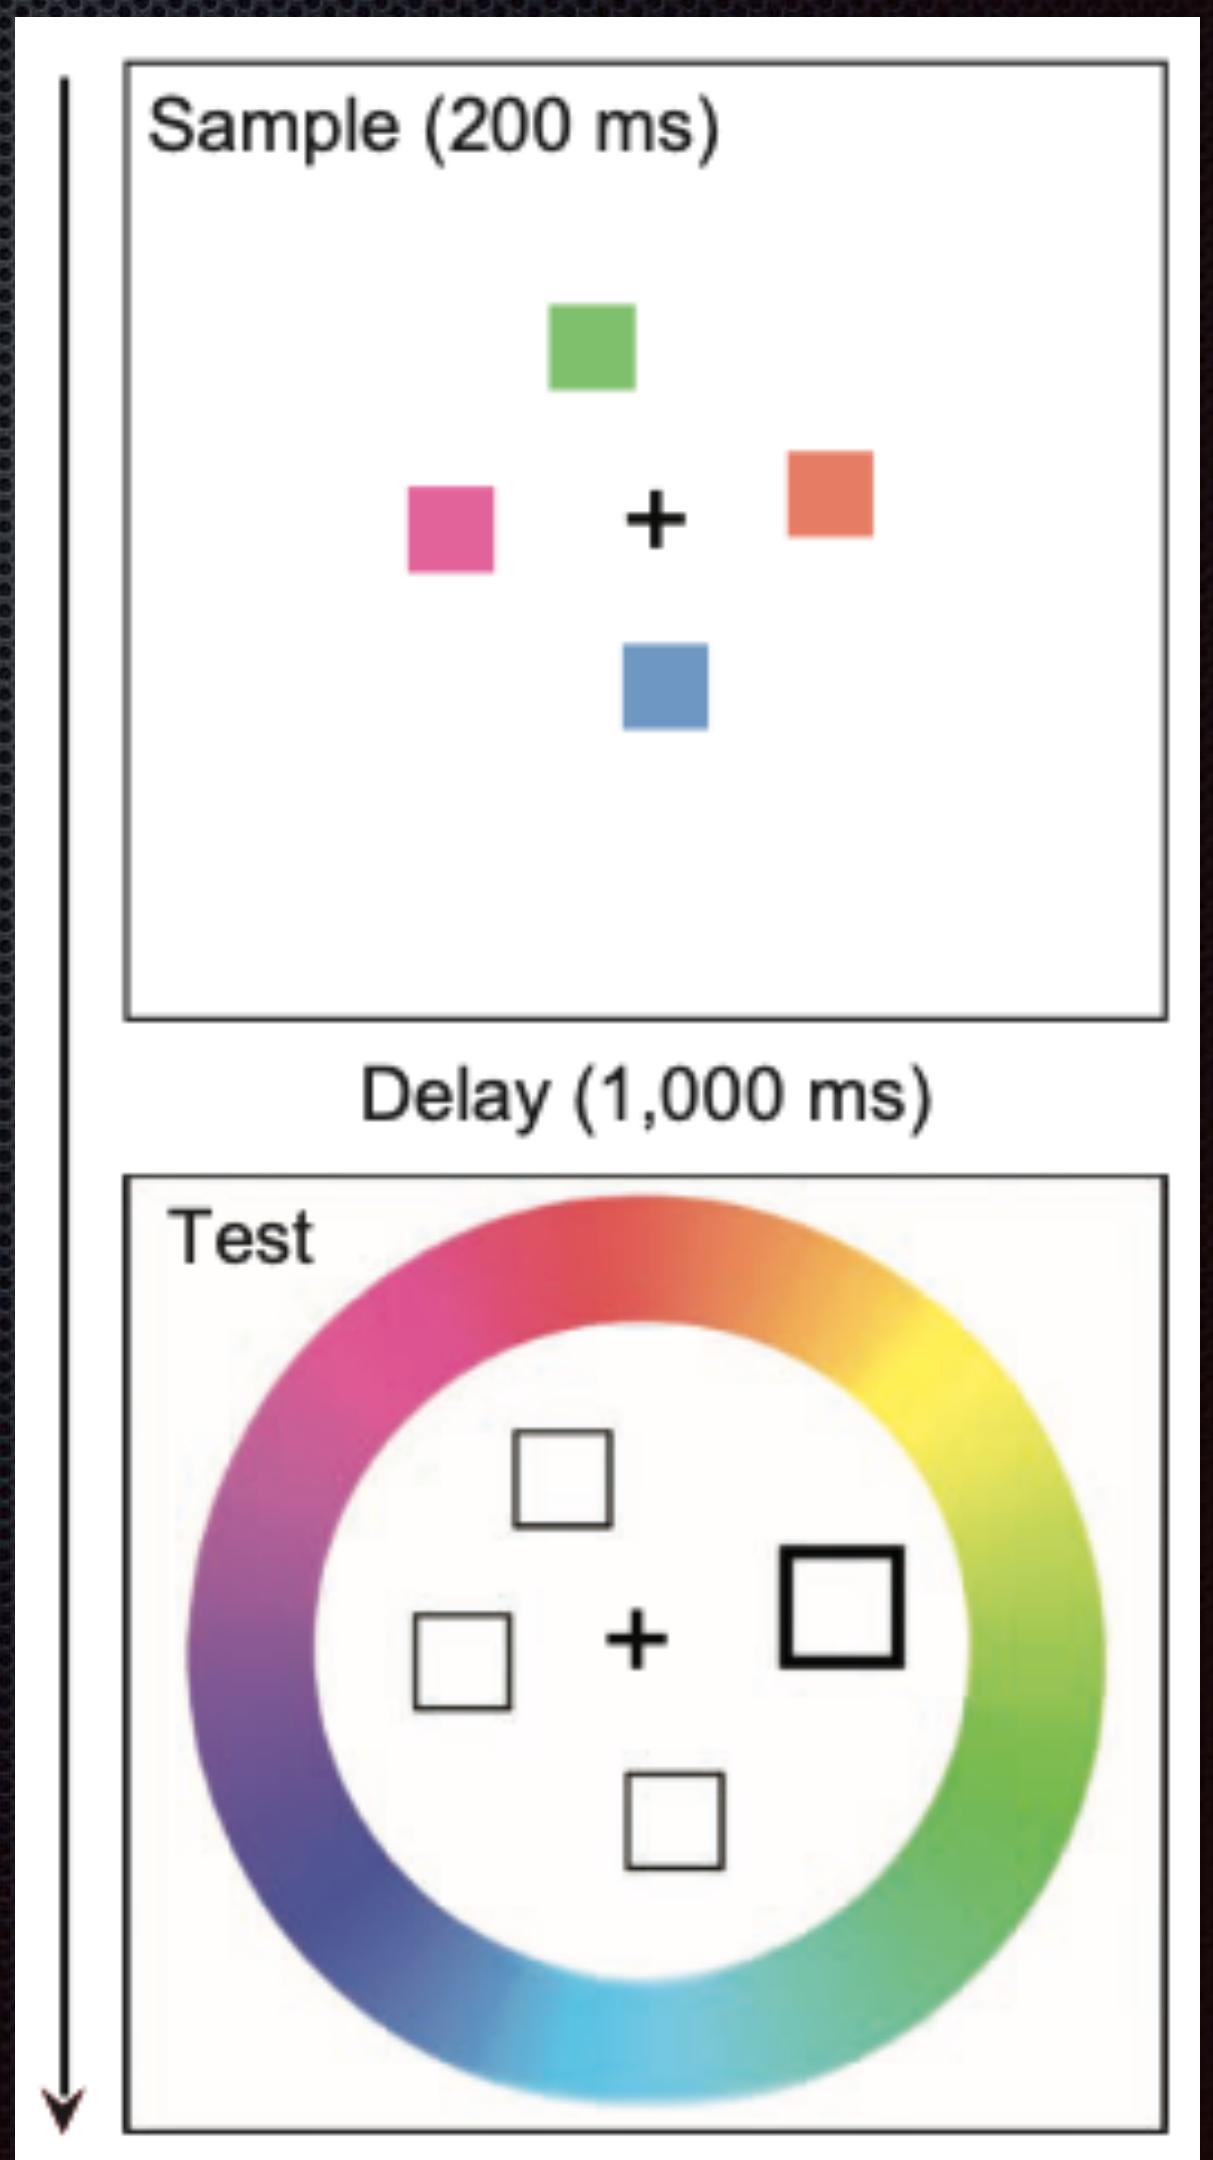
Měření podobnosti fotografií

- Proč? Motivace
- Jak? Metoda
- Takže? Příklady
- Ale... Diskuze

Proč?
Měření pomáhá



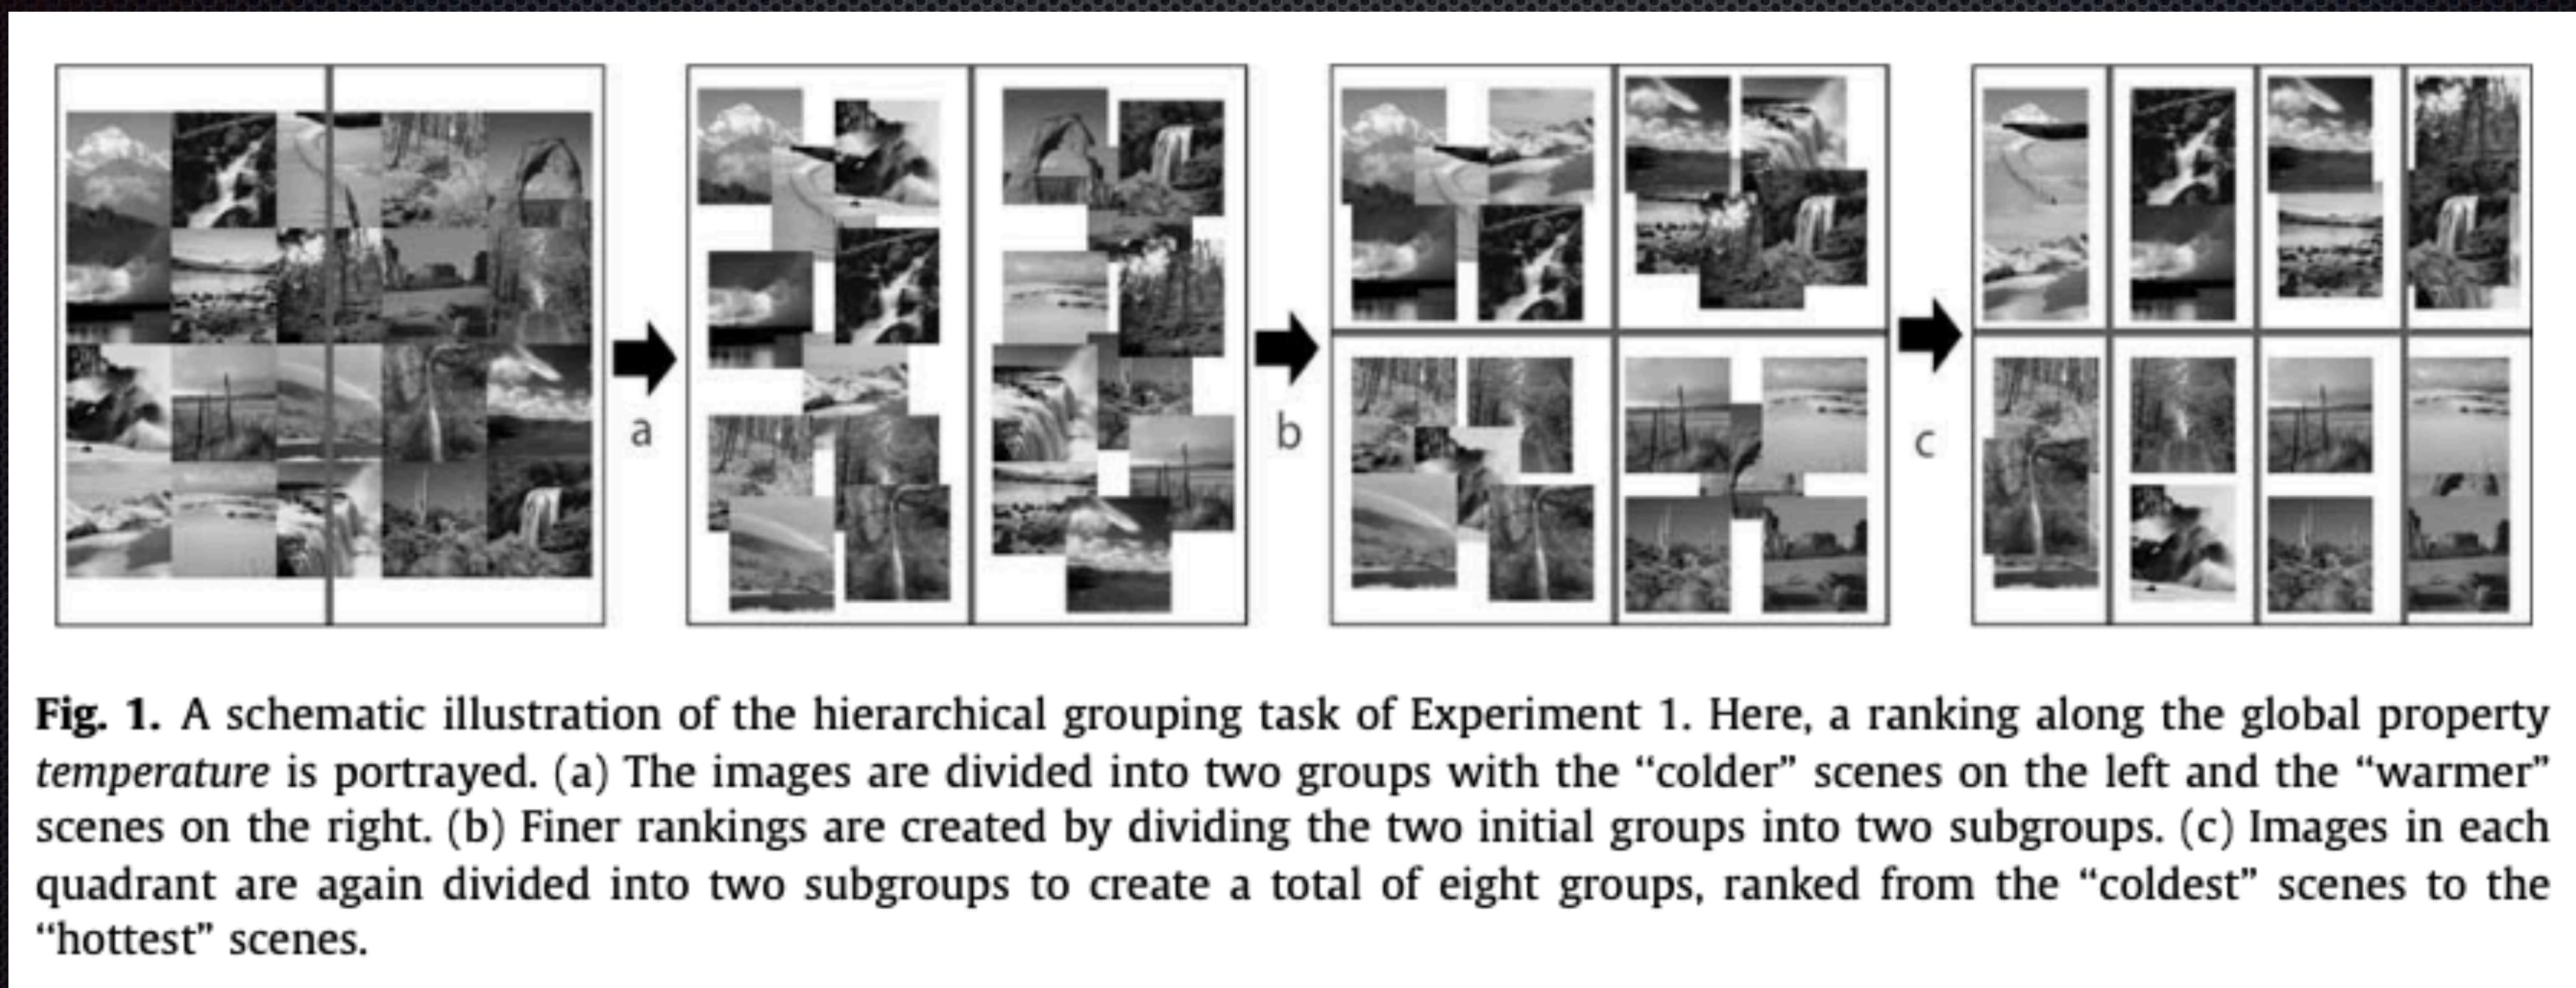
Delayed estimation paradigm



Zhang & Luck (2011)

Hodnocení (ratings)

- “Teplota scény”



Pseudoslova

- *milk* - *pilk*, *malk*, *mirk*, *milp*
- Které je lepší?
 - Lidské hodnocení
 - Edit distance / sousedé, bigram frequency

Asociační normy

- Lépe zachycují význam
- Vyžadují náročný sběr dat

Baby		
<u>No.</u>	<u>Response</u>	<u>Total</u>
1.	boy	162
2.	child	142
3.	cry	113
4.	mother	71
5.	girl	51
6.	small	43
7.	infant	27
8.	cute	21
9.	little	18
10.	blue	17
11.	diapers	14
12.	crib	13
13.	crying	13
14.	bed	11
15.	sitter	11

Shrnutí – měření

- Význam je lepší než formální podobnost
- Chceme rozšiřitelnost na nové podněty

Proč?
Potenciál



Kolik objektů pojme lidská mysl?

- 2500 fotografií objektů
- 5.5 h
- Detekce opakování
- 2AFC paměťový test



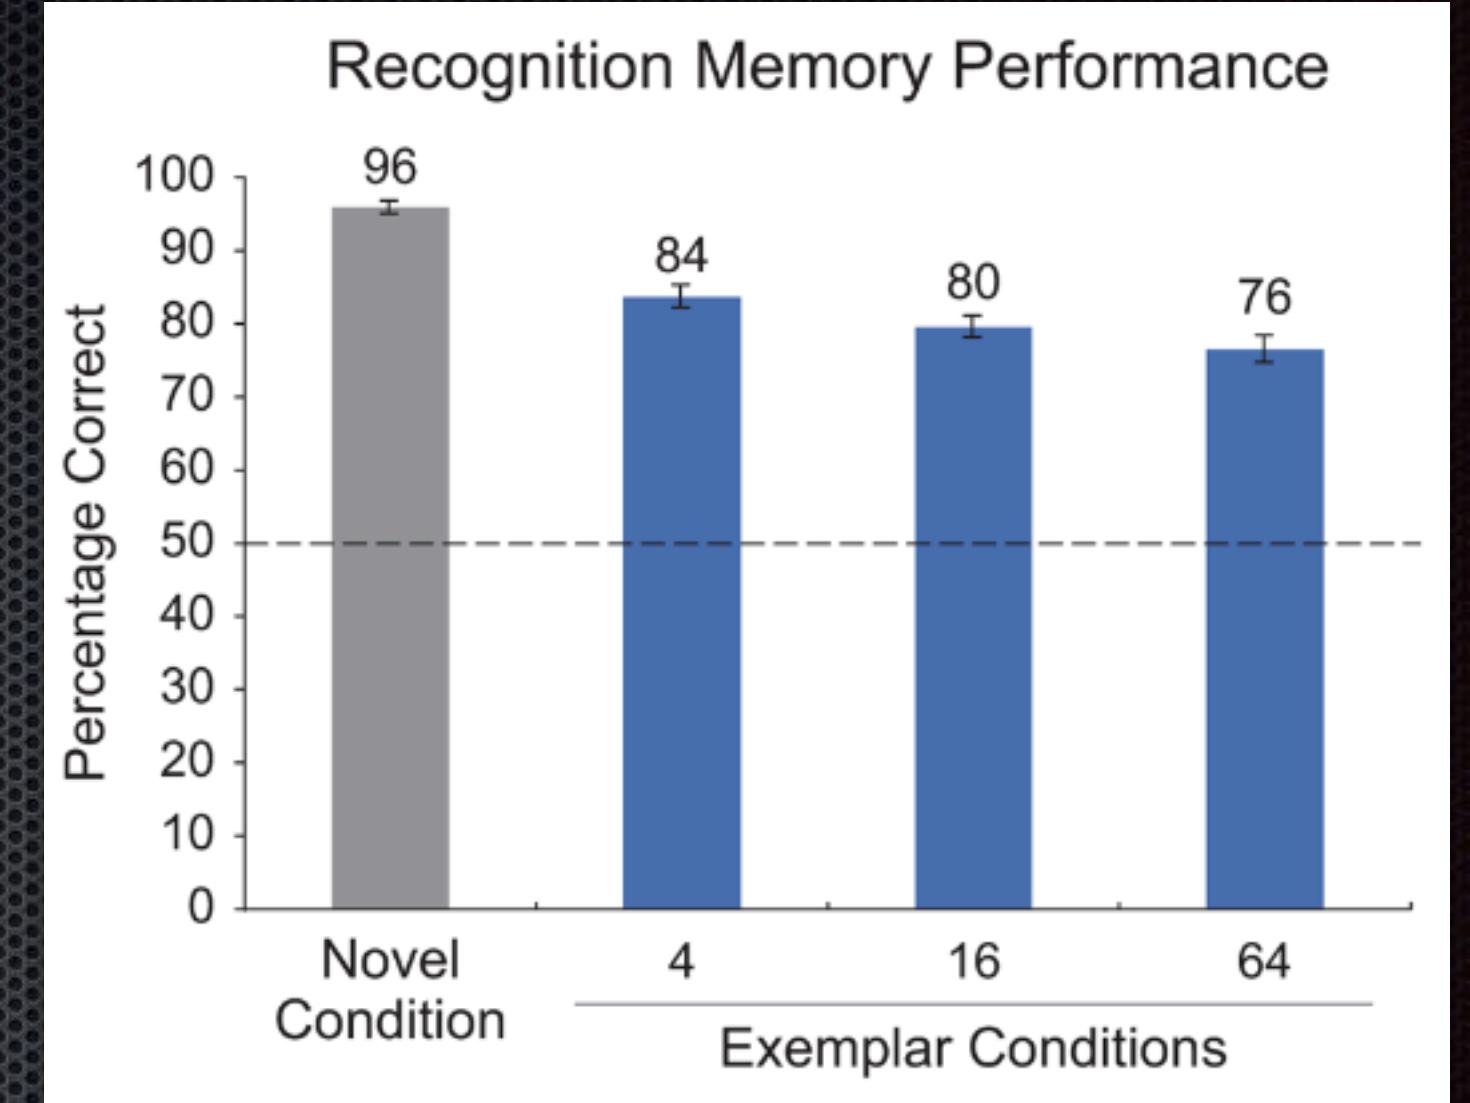
Skvělá paměť na fotografie

- Netýká se jen izolovaných objektů
 - 2800 fotografií za 5.5 h
 - Odlišné počty zástupců každé kategorie

Konkle et al. (2010)



Proč se nám obrázky v paměti pletou?

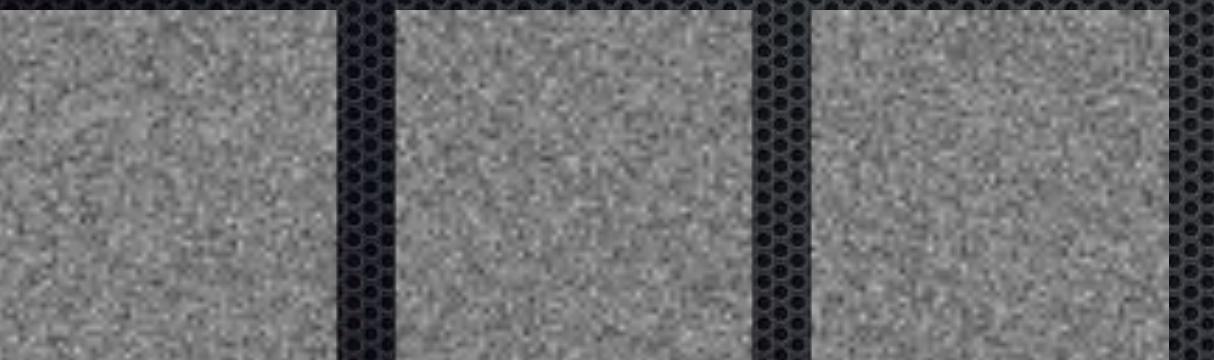


- Více zástupců → horší paměť
- **Význam** nebo **vizuální podobnost**? Mohou se nám plést různé kategorie?



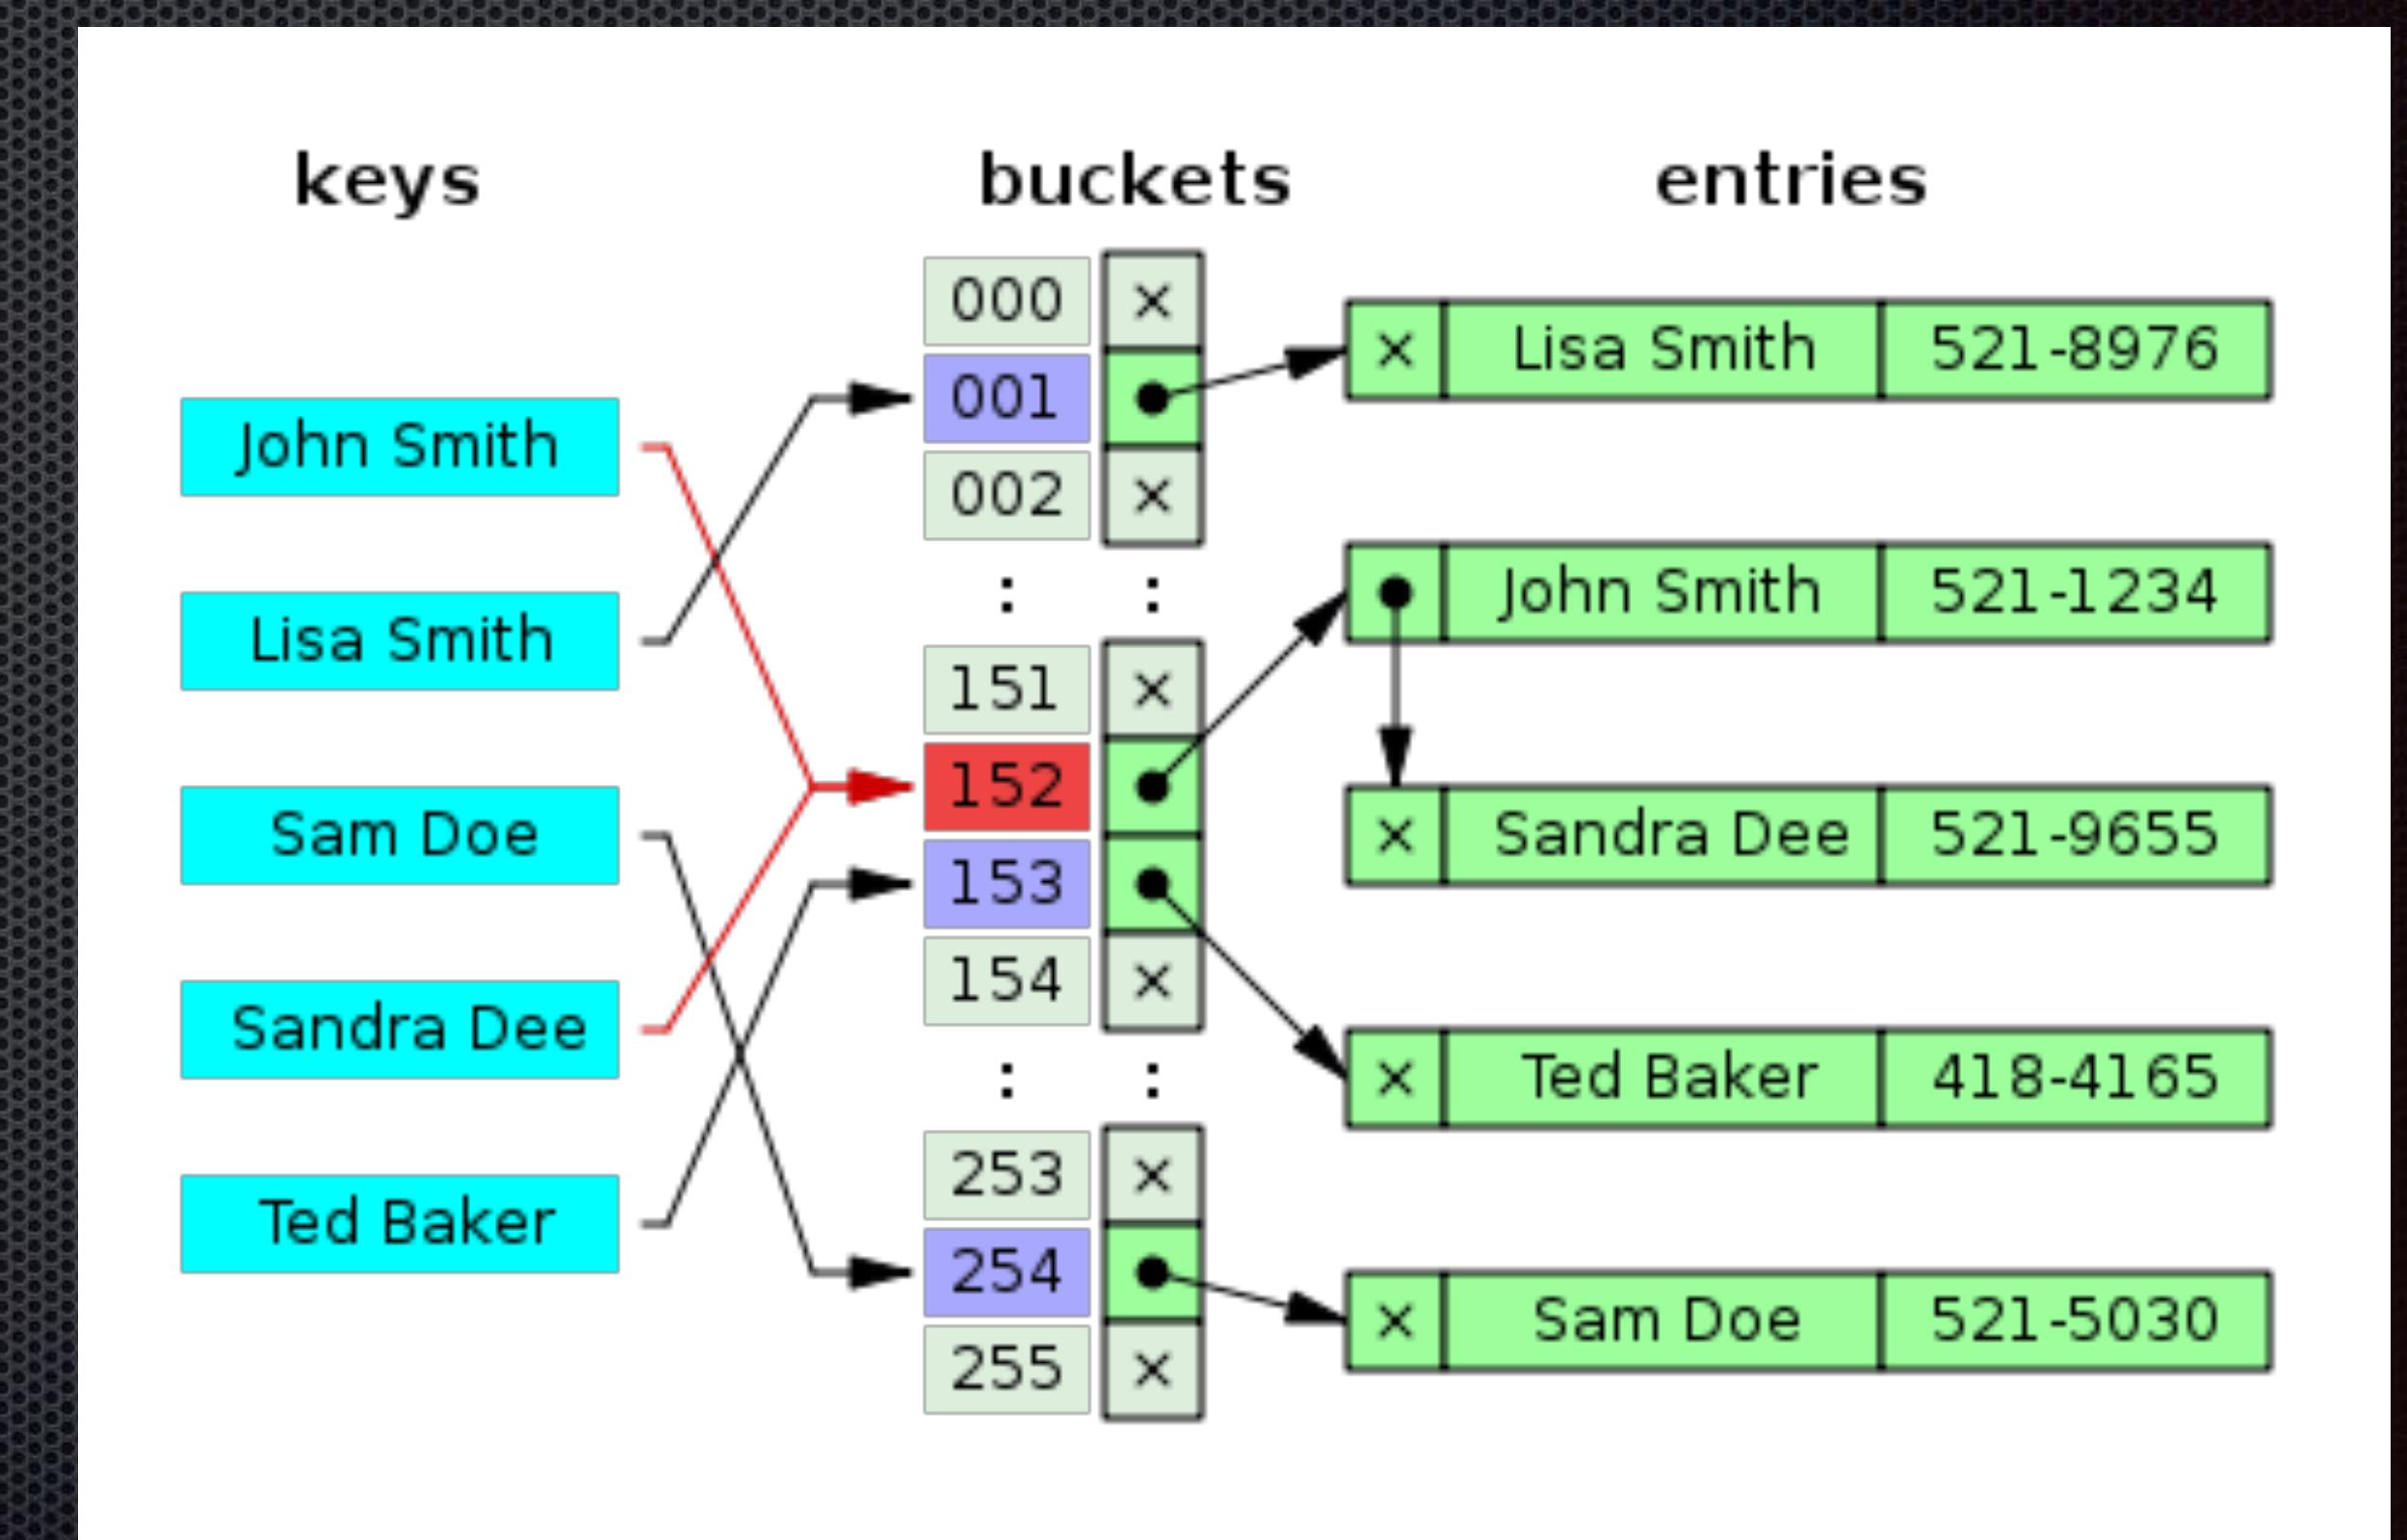
Informace v jedné fotografii

- 256×256 pixelů, 8 bitů/pixel ...
 - 10^{150000}
- Ale většina



Metafora Hash-table

- Používána pro odhad kapacity dlouhodobé paměti



Hash-table demo

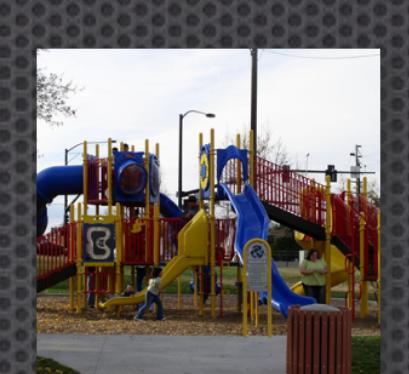


4009

125

2

...

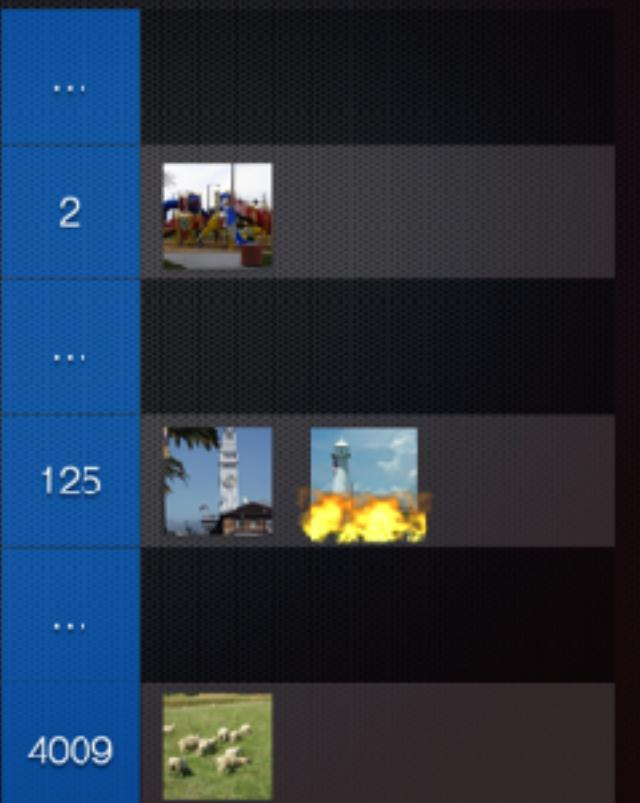


Kapacita

- Landauer (1986)
 - Vychází z předešlých studií (fotografie, slova, ...)
 - Sleduje počet podnětů a procenta chyb
 - Odhad kapacity paměti (pro odpovídající četnosti kolizí)

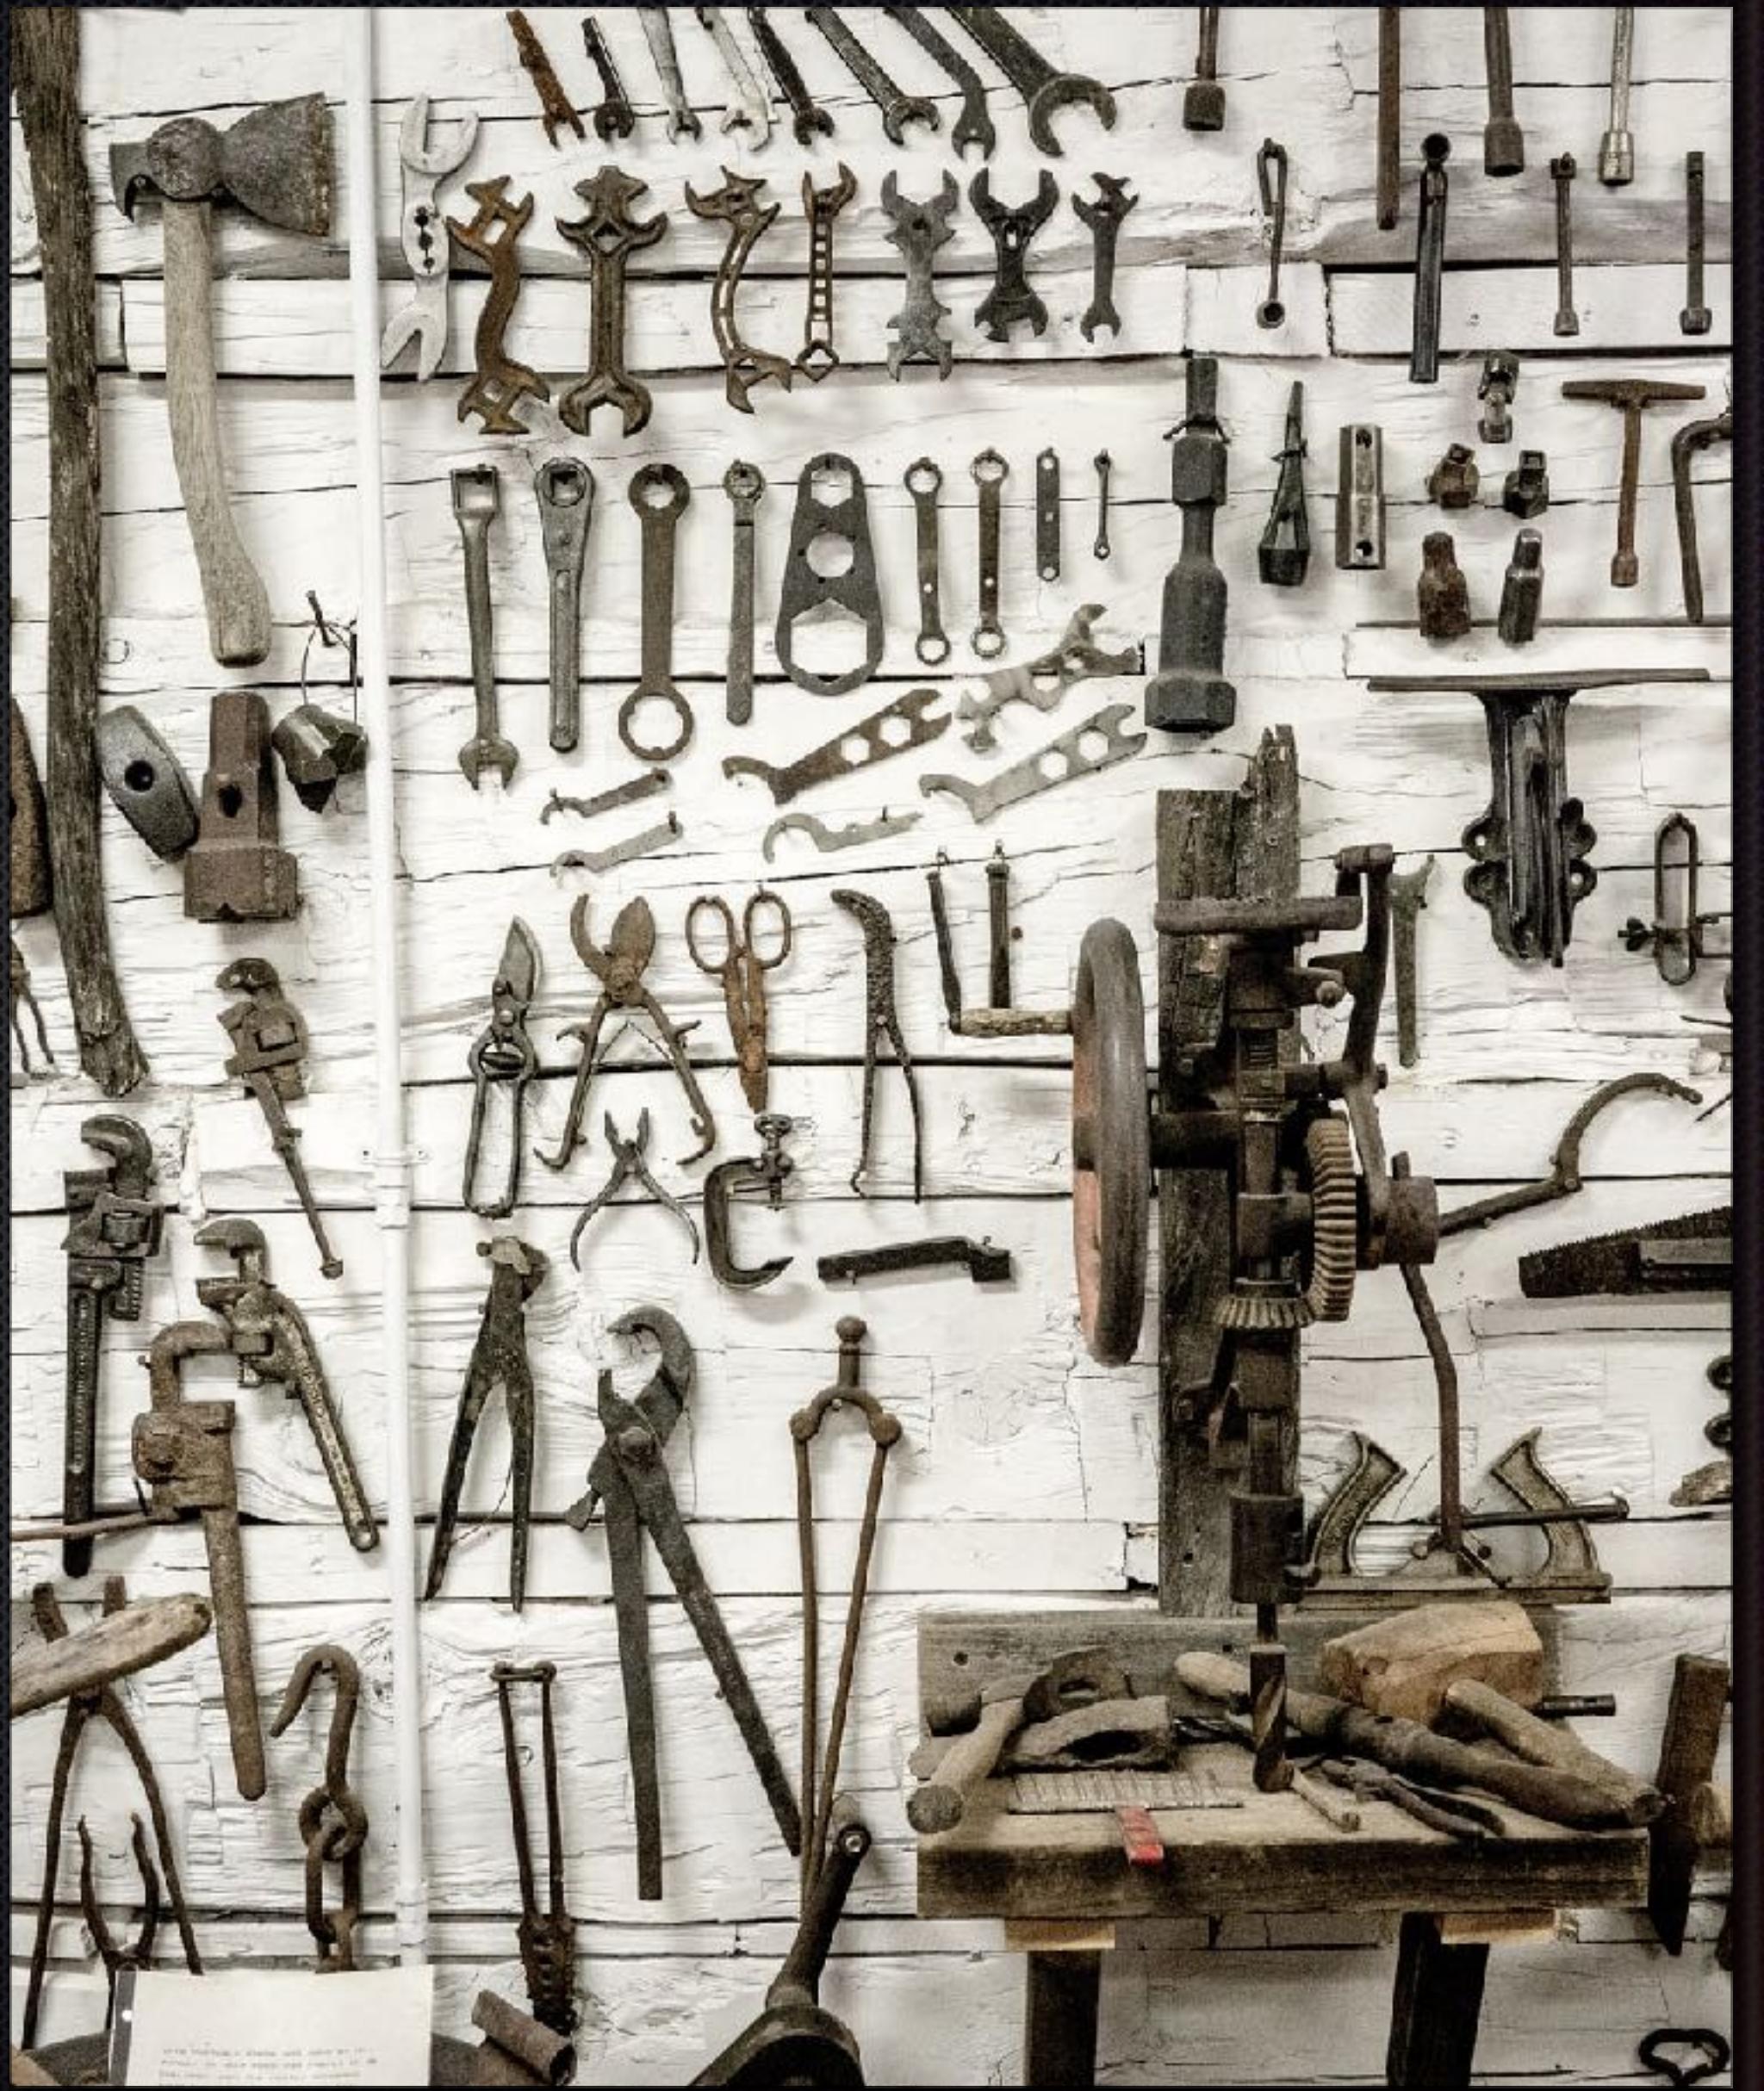
$$b = -\log_2(1 - (2p - 1)^{1/n})$$

Hash table demo

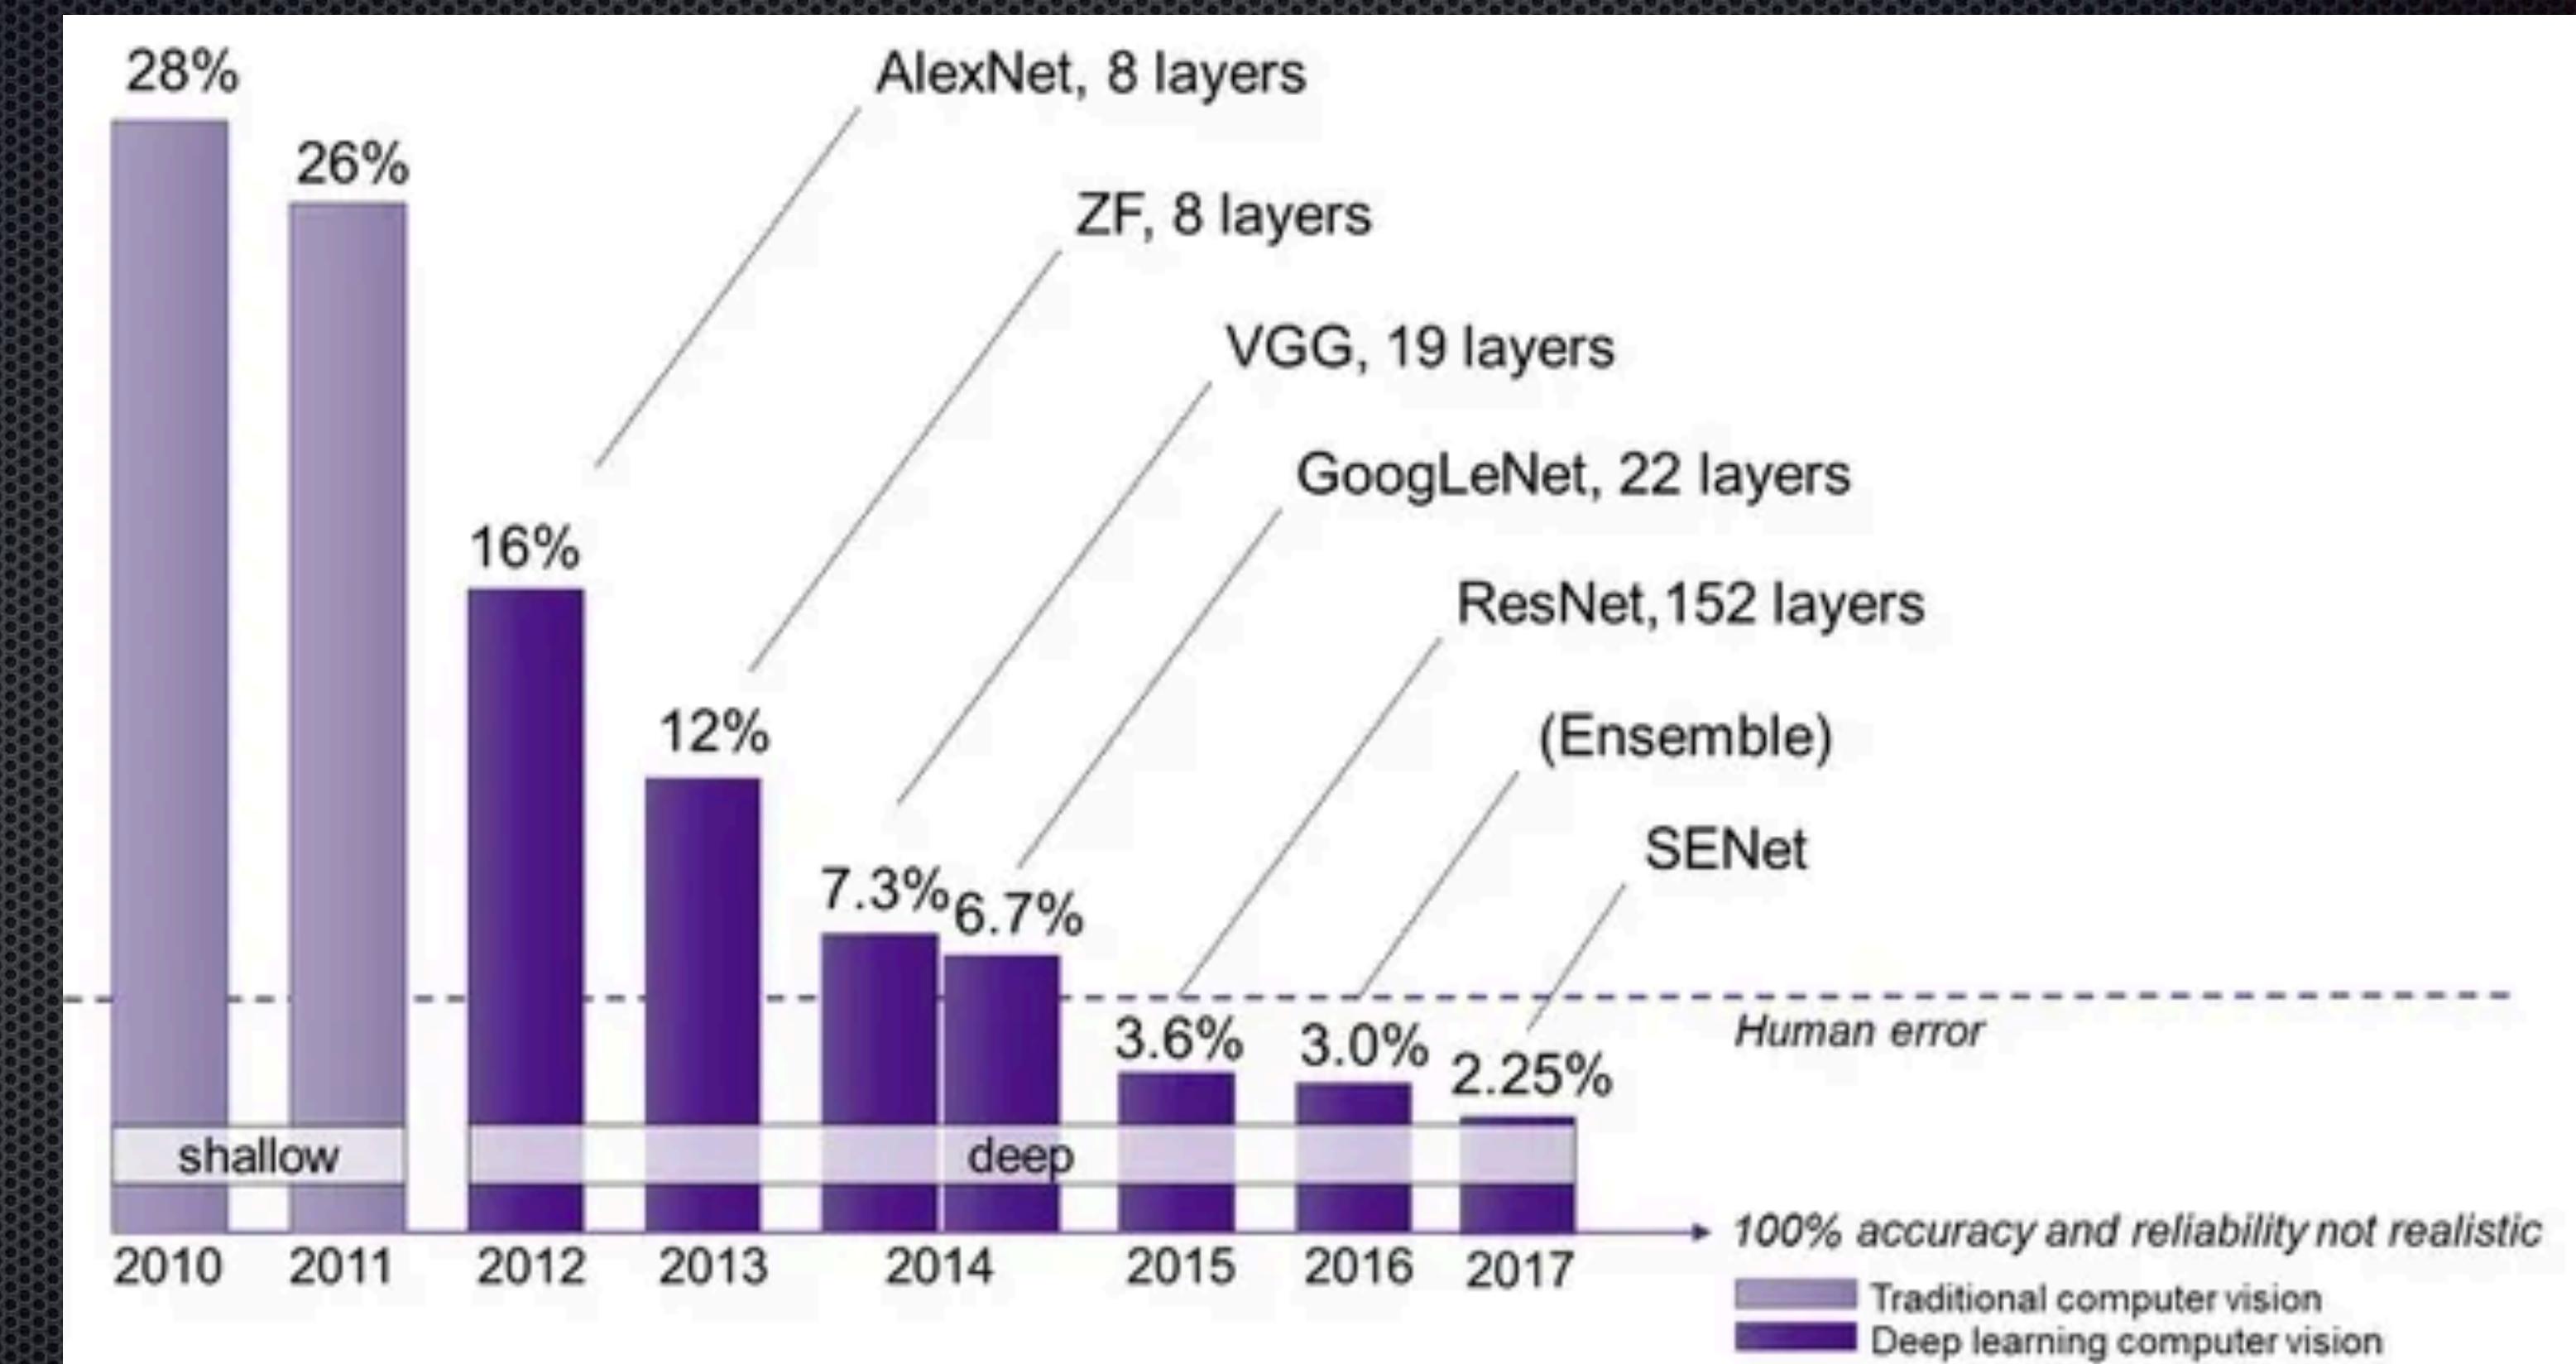


12 bits

Jak?
Metoda



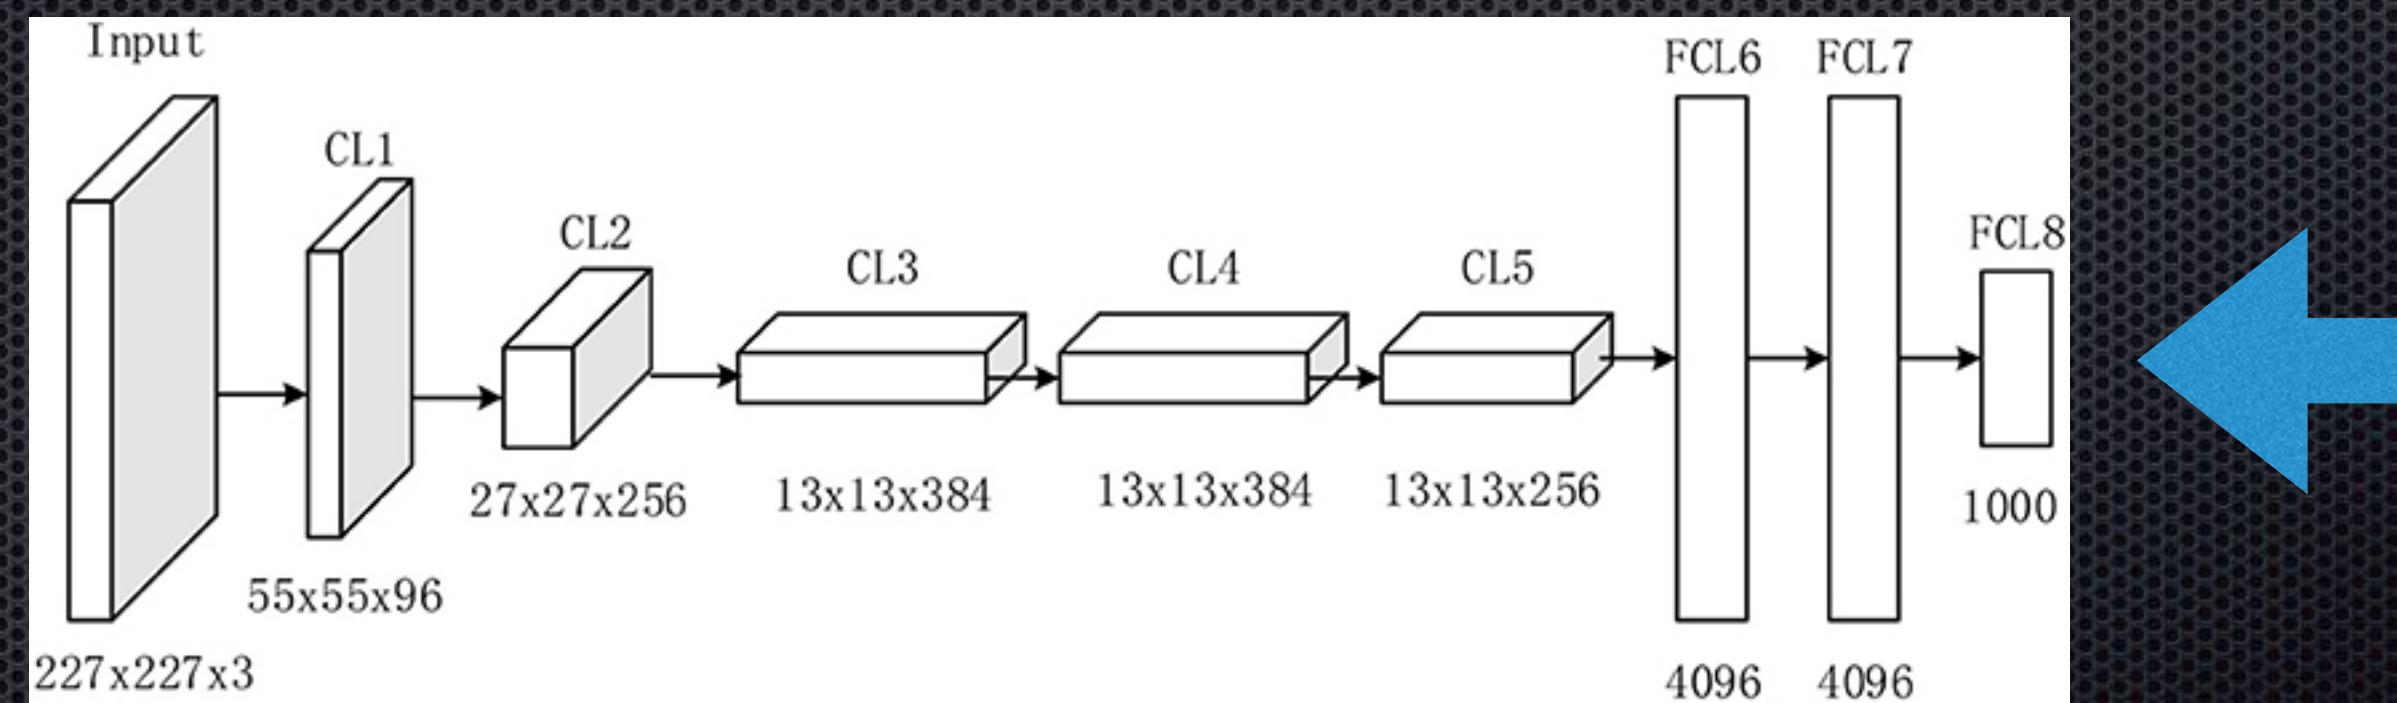
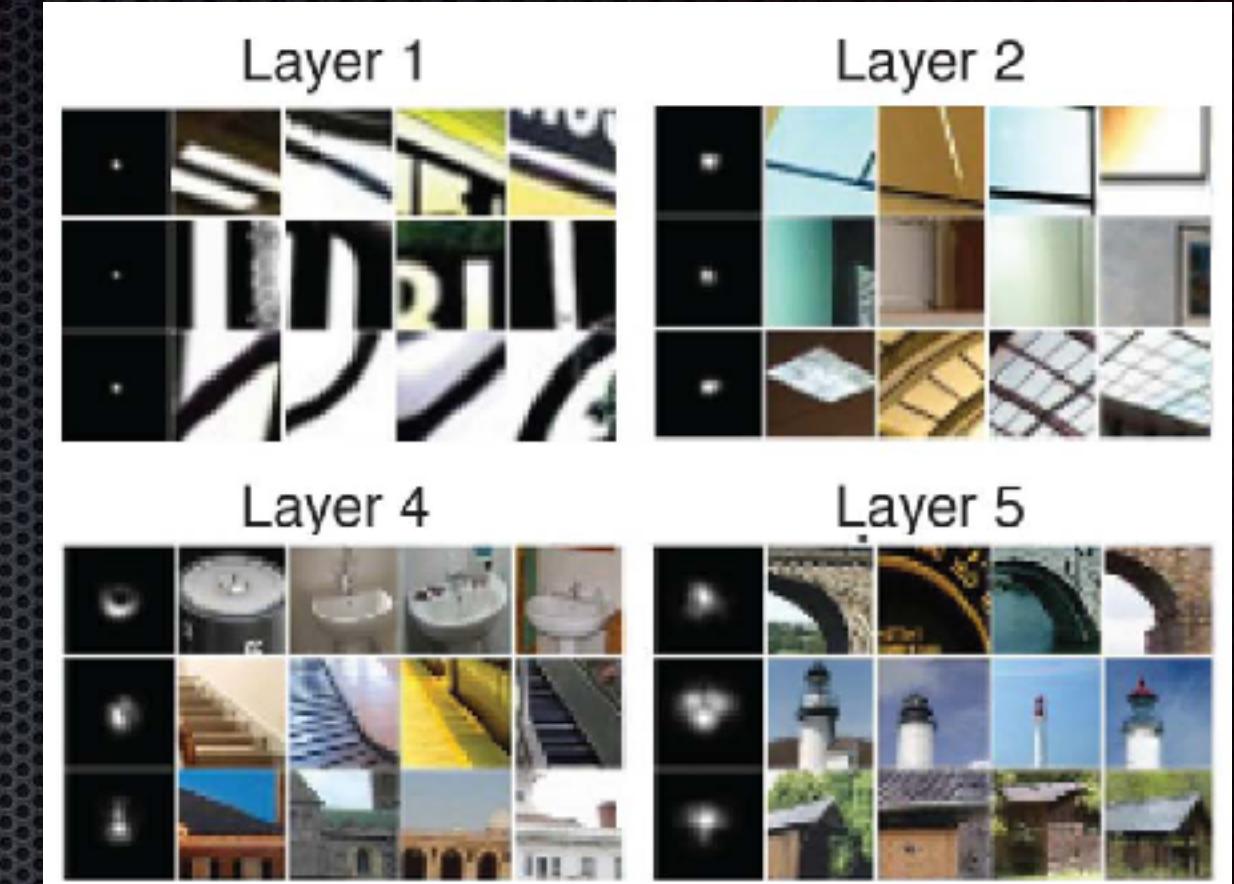
Convolutional neural networks



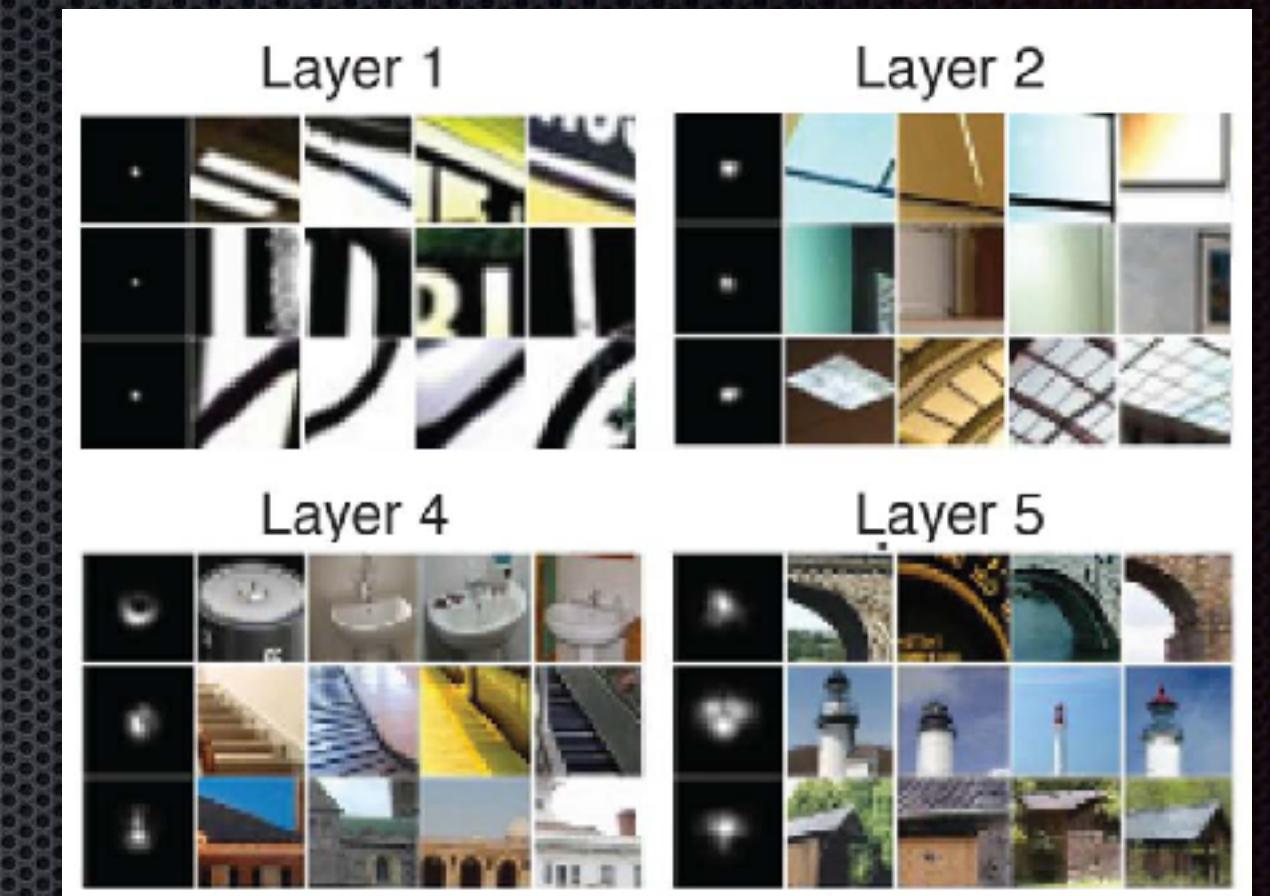
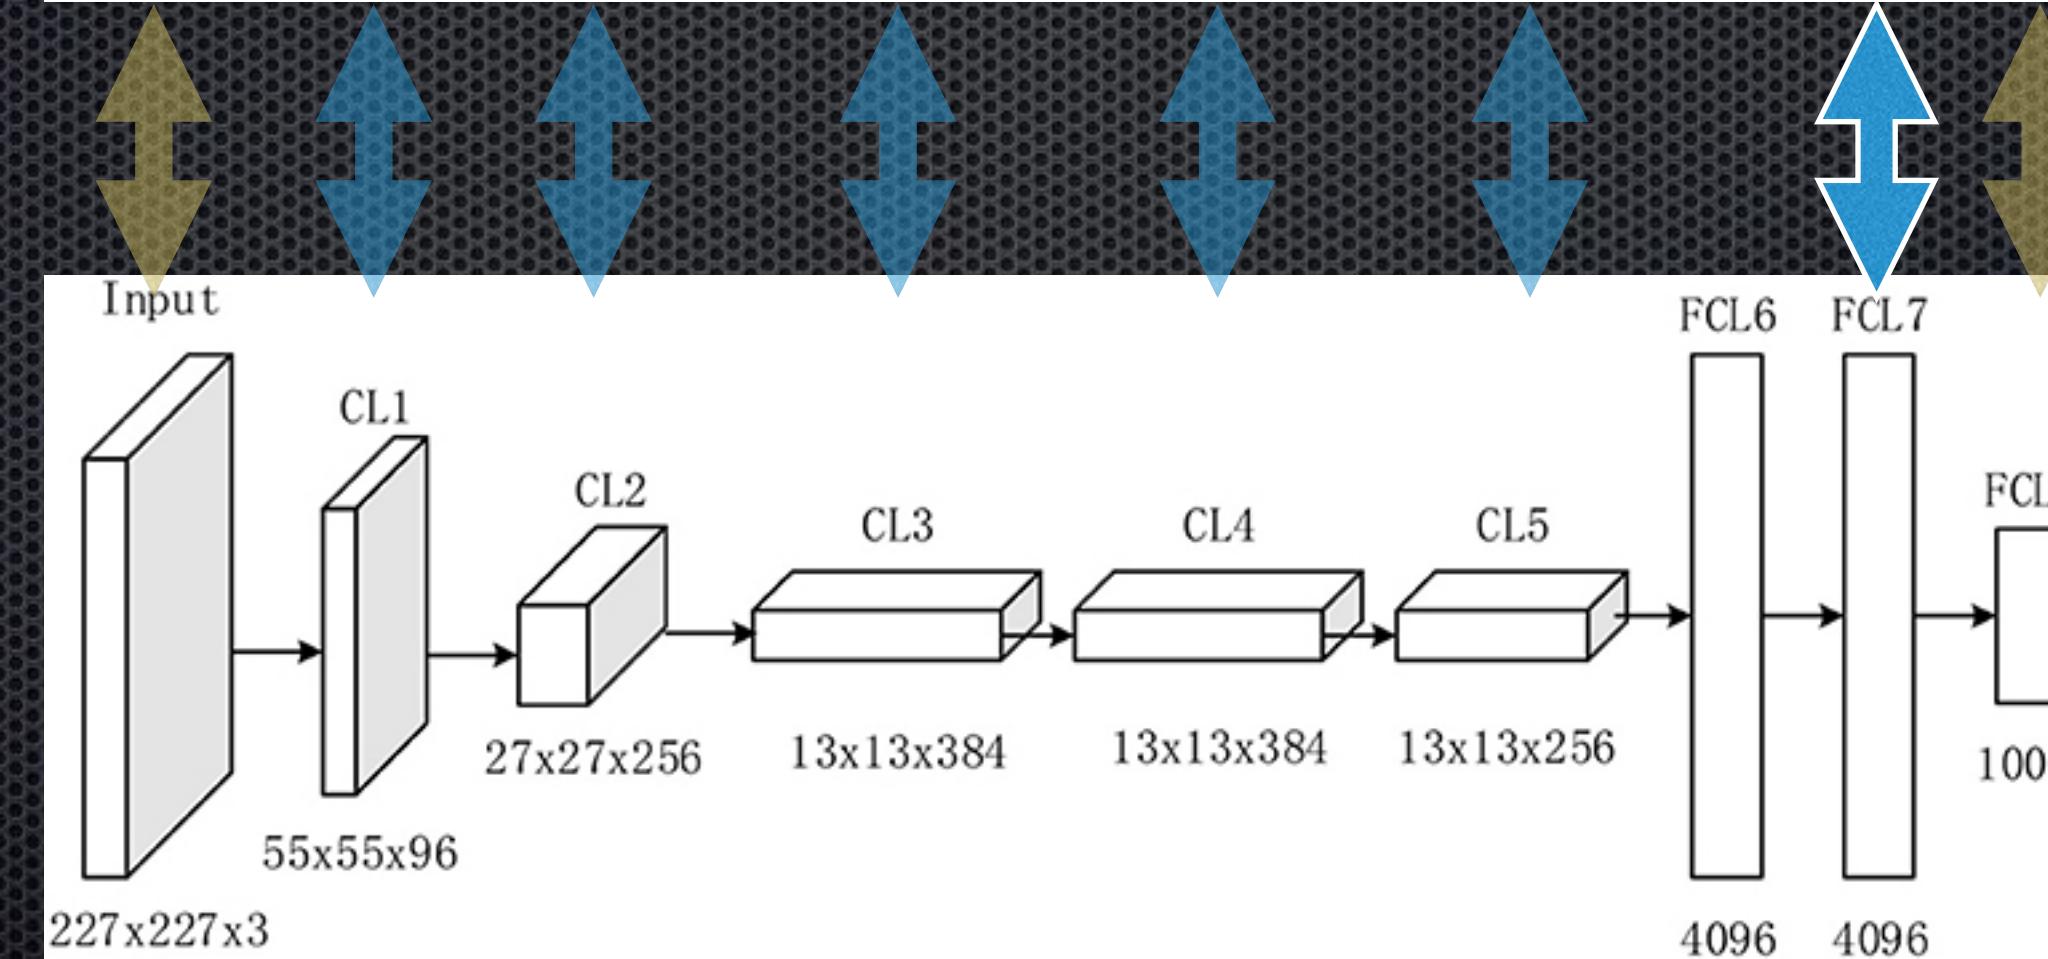
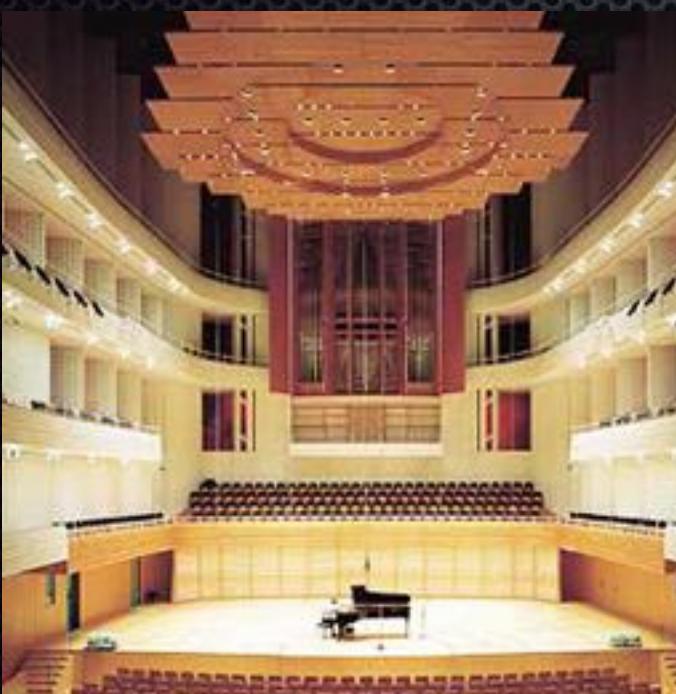
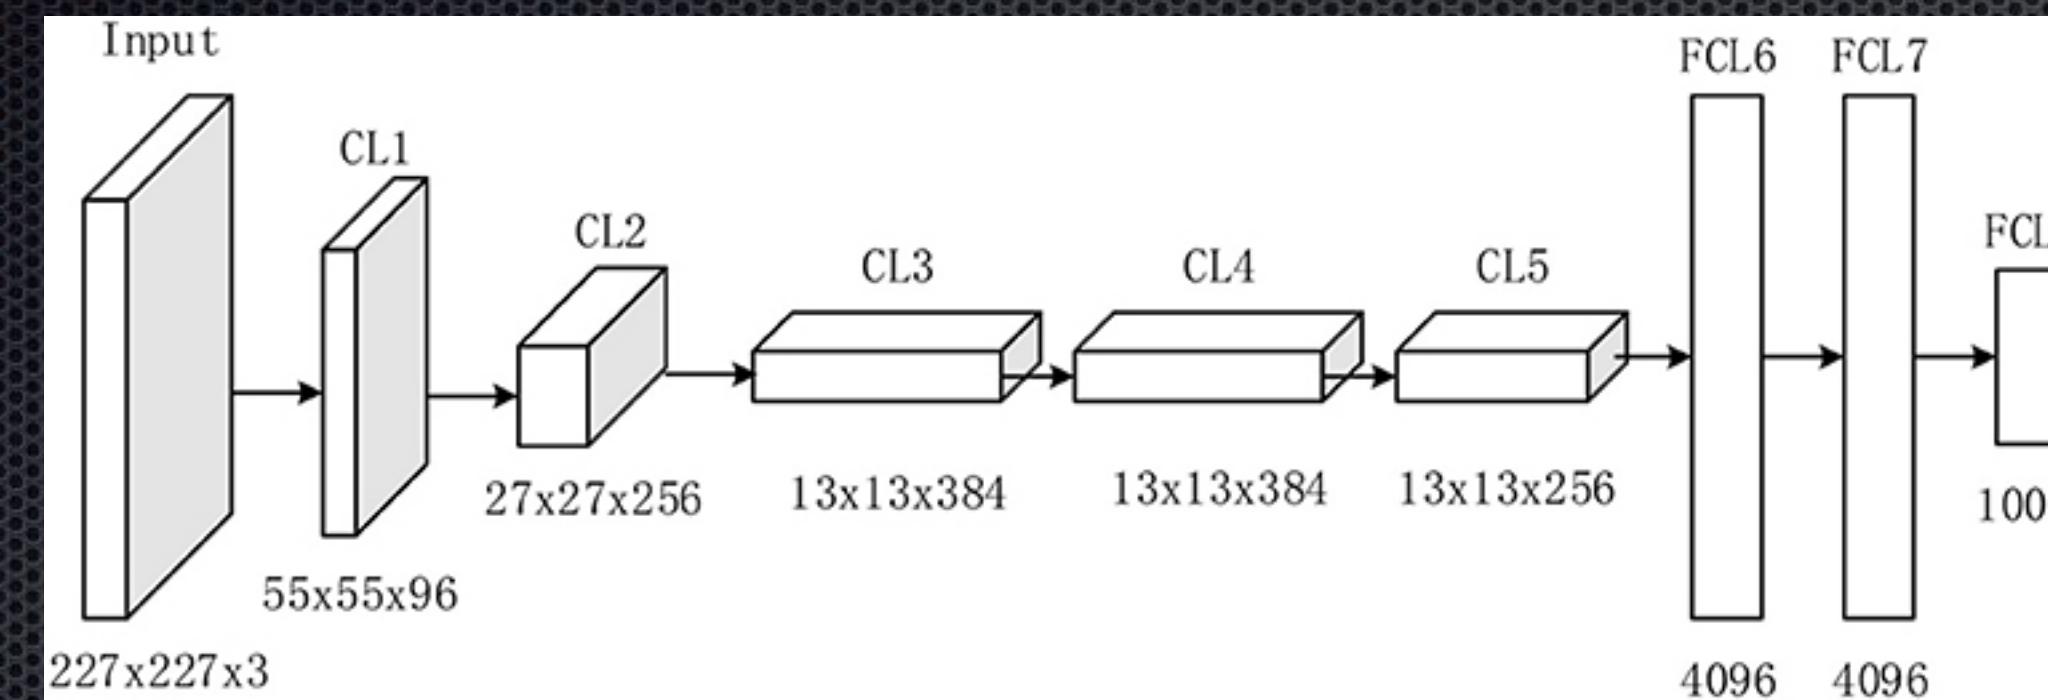
ImageNet Large Scale Visual Recognition Challenge

Architektura

- AlexNet / Places CNN
- Places - pre-trained CNN (Zhou et al., 2014),
2M fotografií, 205 kategorií



Párové srovnání podobnosti



CNN vs Brain

- **Předpokládáme zkušenosť u obou systémů**
 - CNN trénovaná ke kategorizaci objektov/scén
 - Mozek trénuje celý život
- Viz Cichy & Kaiser (2019)



Takže?

Příklady



Příklady

- Podobnost a paměťový výkon (Lukavský & Děchtěrenko, 2017)
- Vizuální analogie DRM paradigmatu (Děchtěrenko, Lukavský, Štipl, 2021)
- Předvídání change-blindness obtížnosti (unpublished)

Podobnost a paměťový výkon

- Korelační studie zaměřená na **paměť na fotografie** a **vizuální podobnost**
- 3 experimenty ($N = 3 \times 40$)
- 400 až 960 obrázků vybraných ze sady 2048 obrázků
 - 64 kategorií
- Paměťový test (“old/new”)

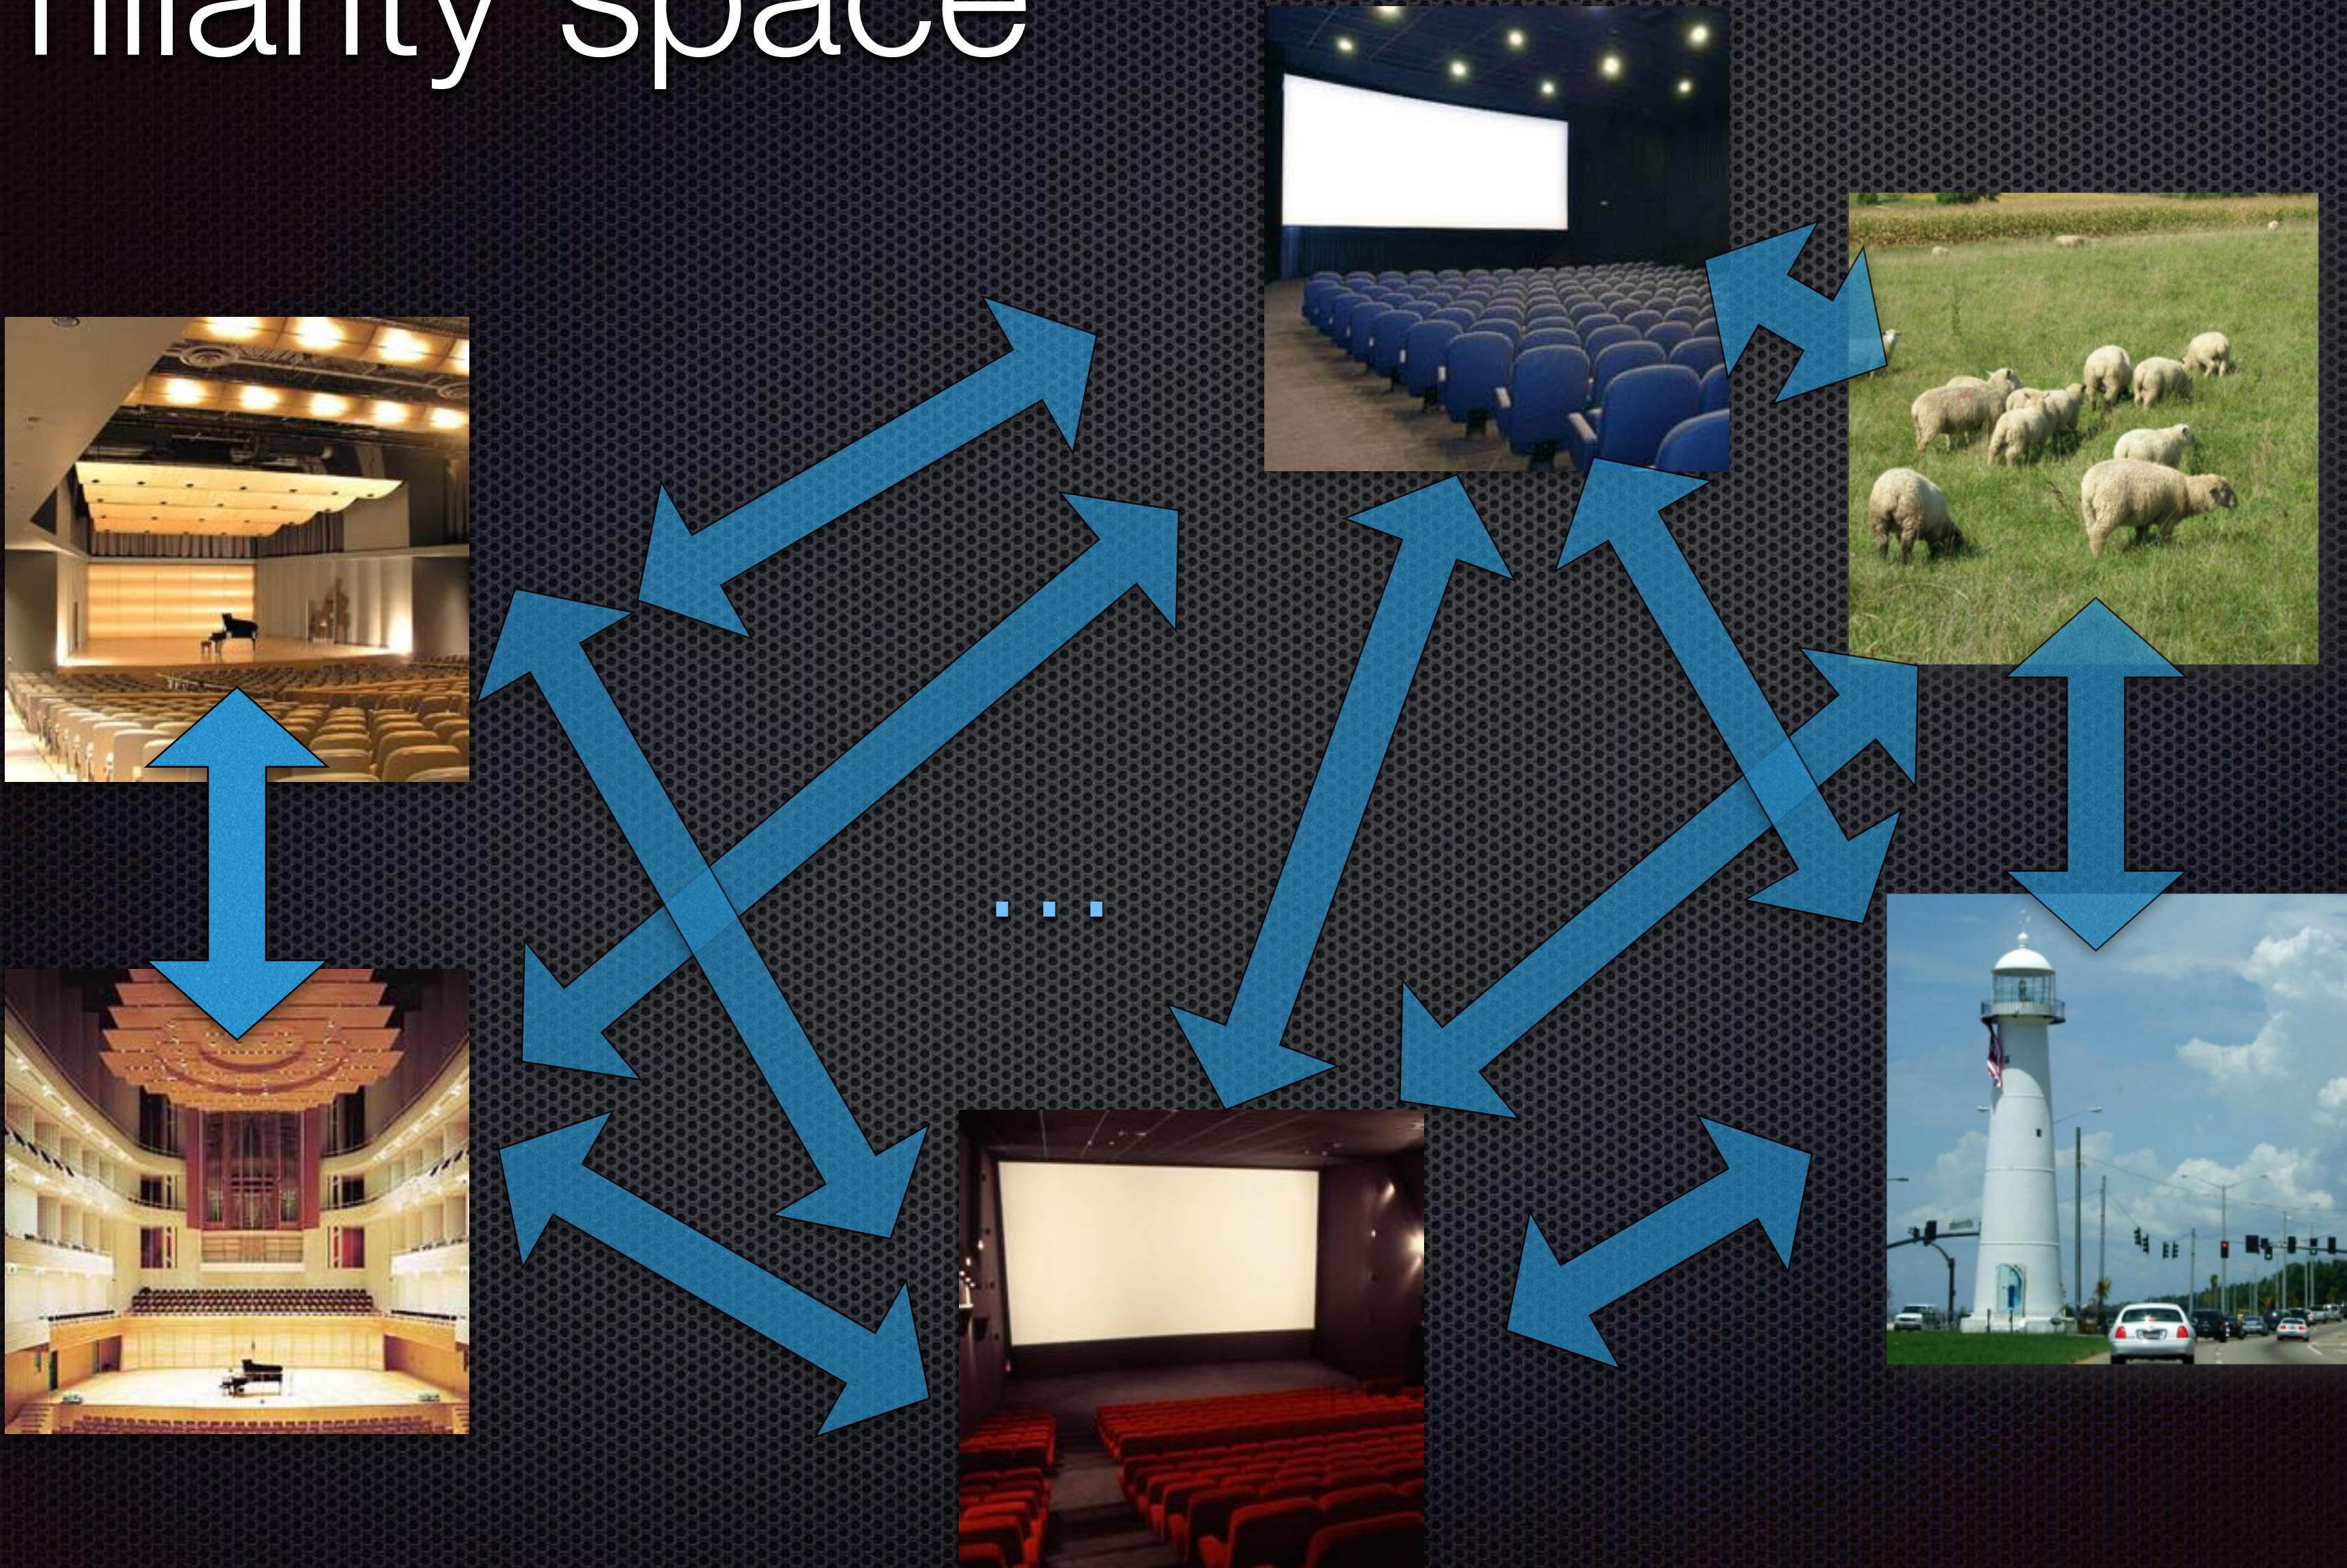
Atten Percept Psychophys (2017) 79:2044–2054
DOI 10.3758/s13414-017-1375-9



Visual properties and memorising scenes: Effects of image-space sparseness and uniformity

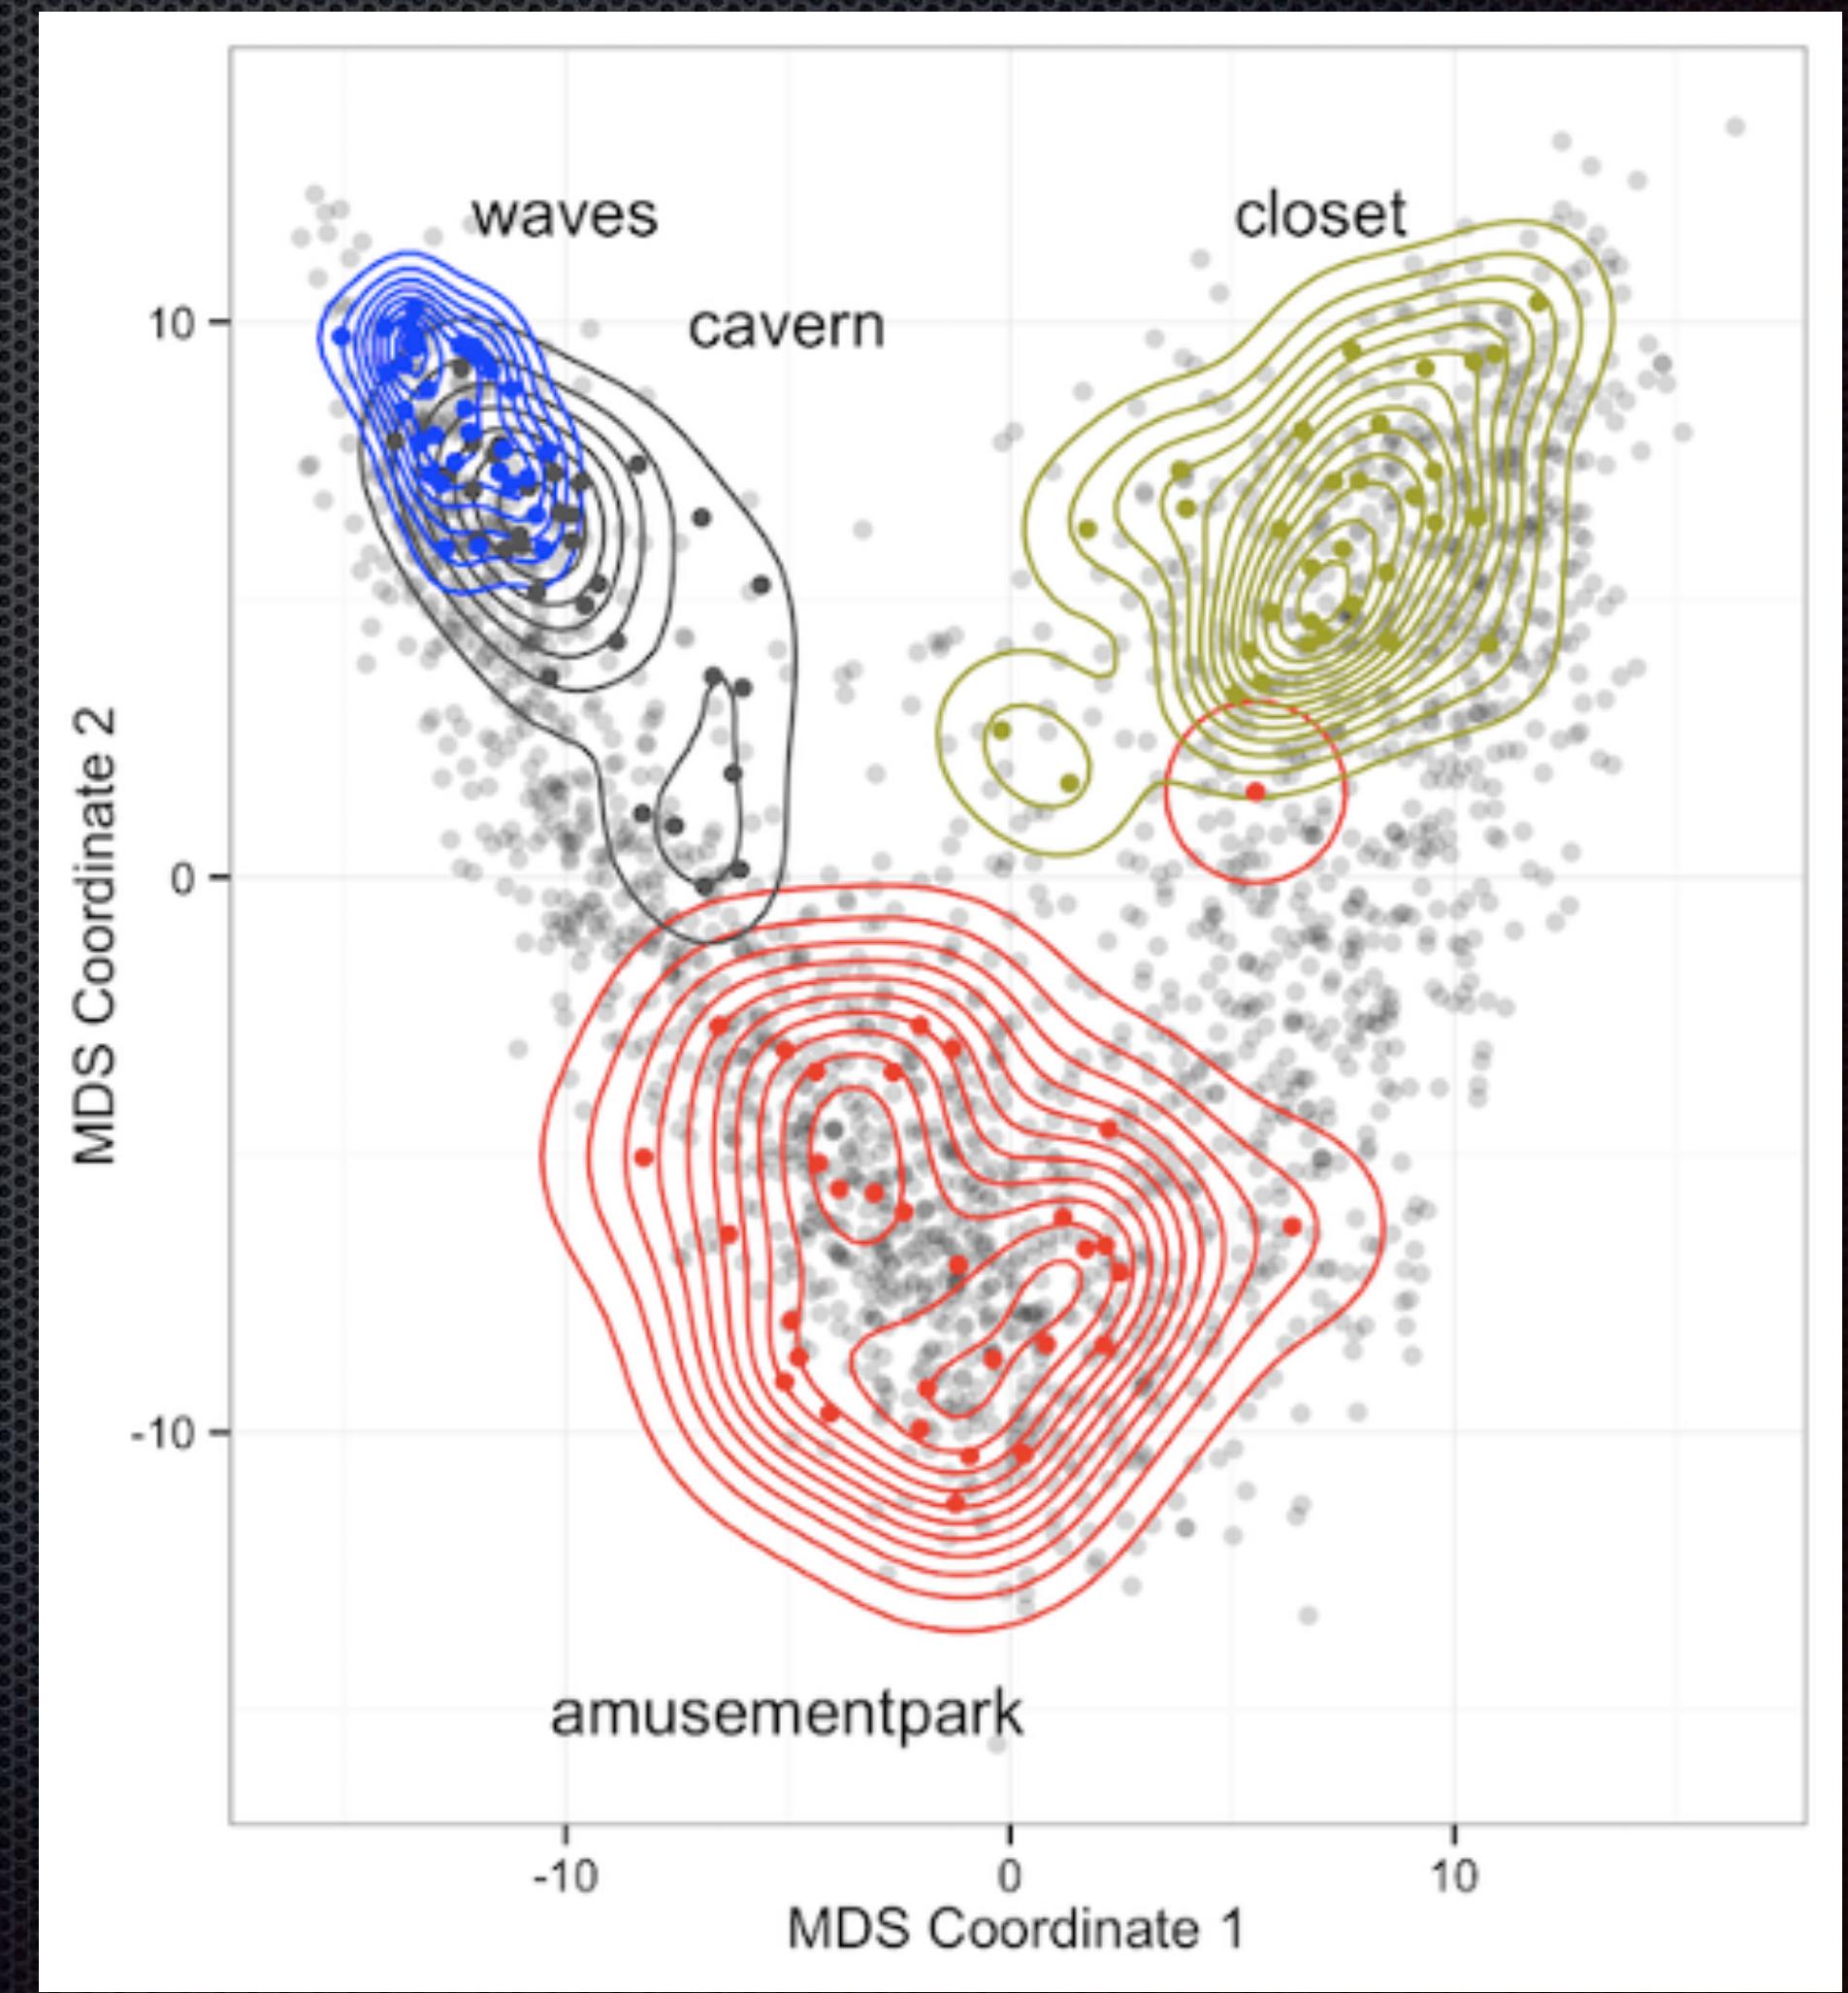
Jiří Lukavský¹ · Filip Děchtěrenko^{1,2}

Similarity space

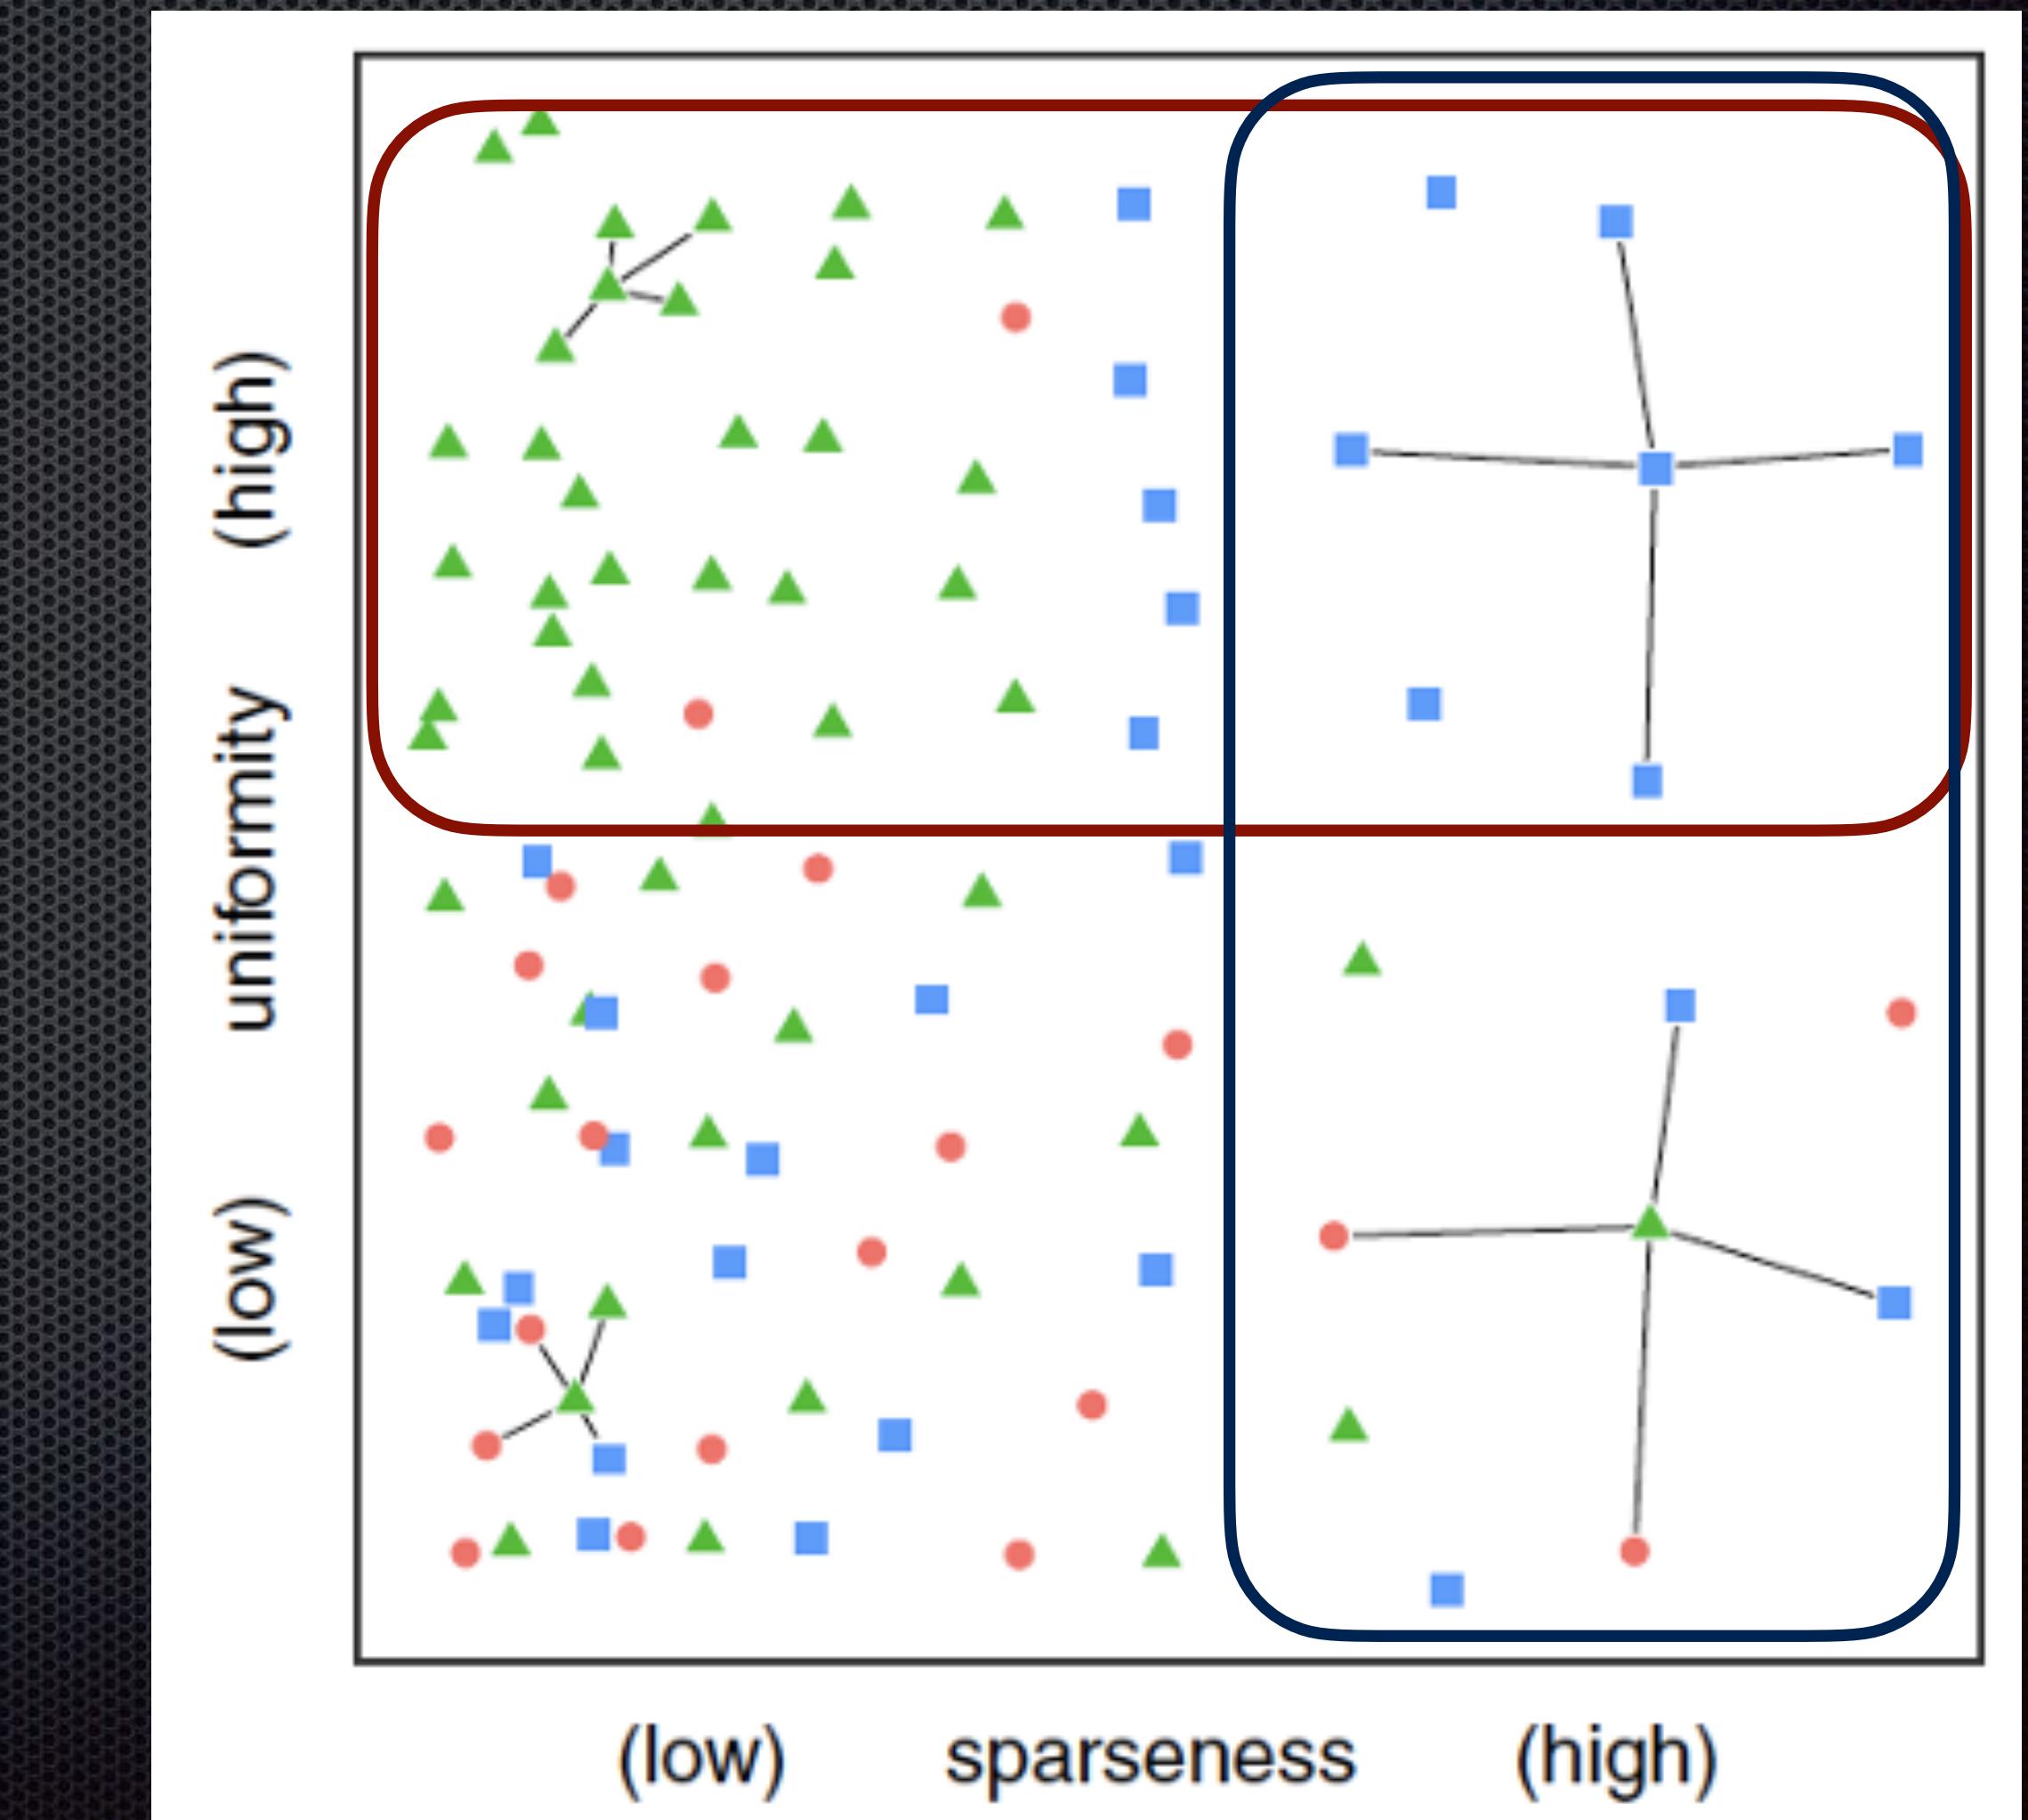
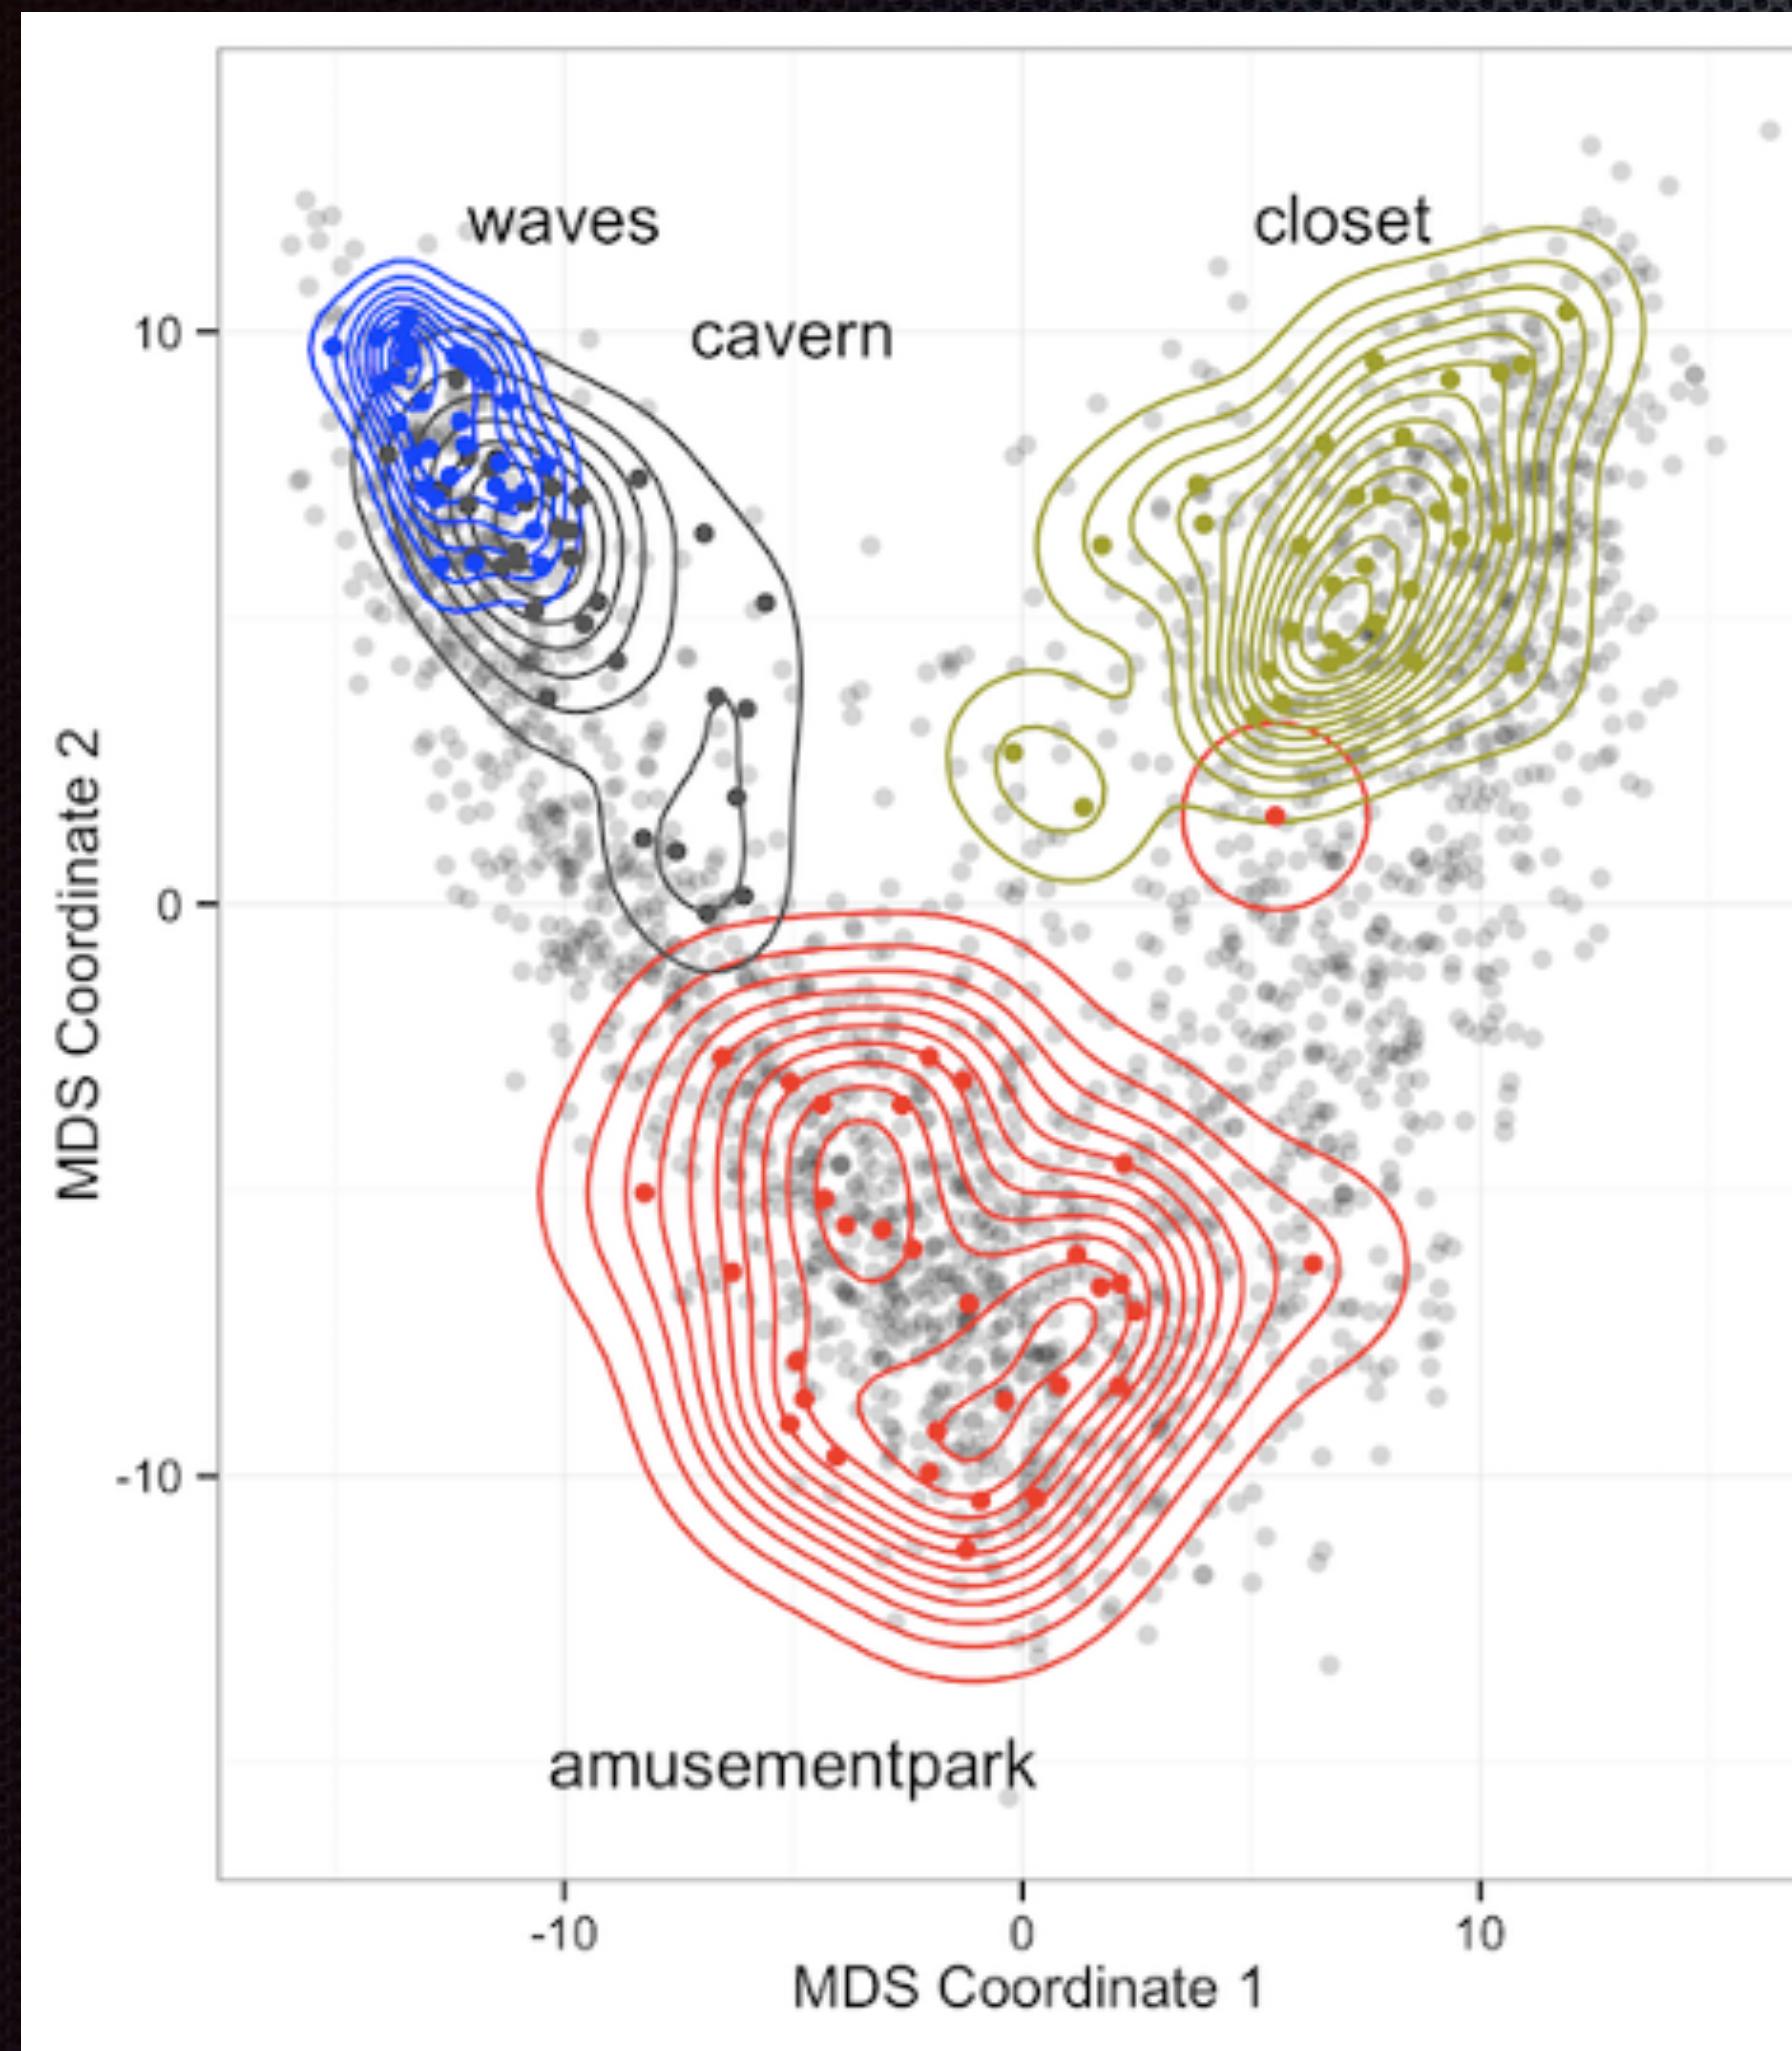


Similarity space

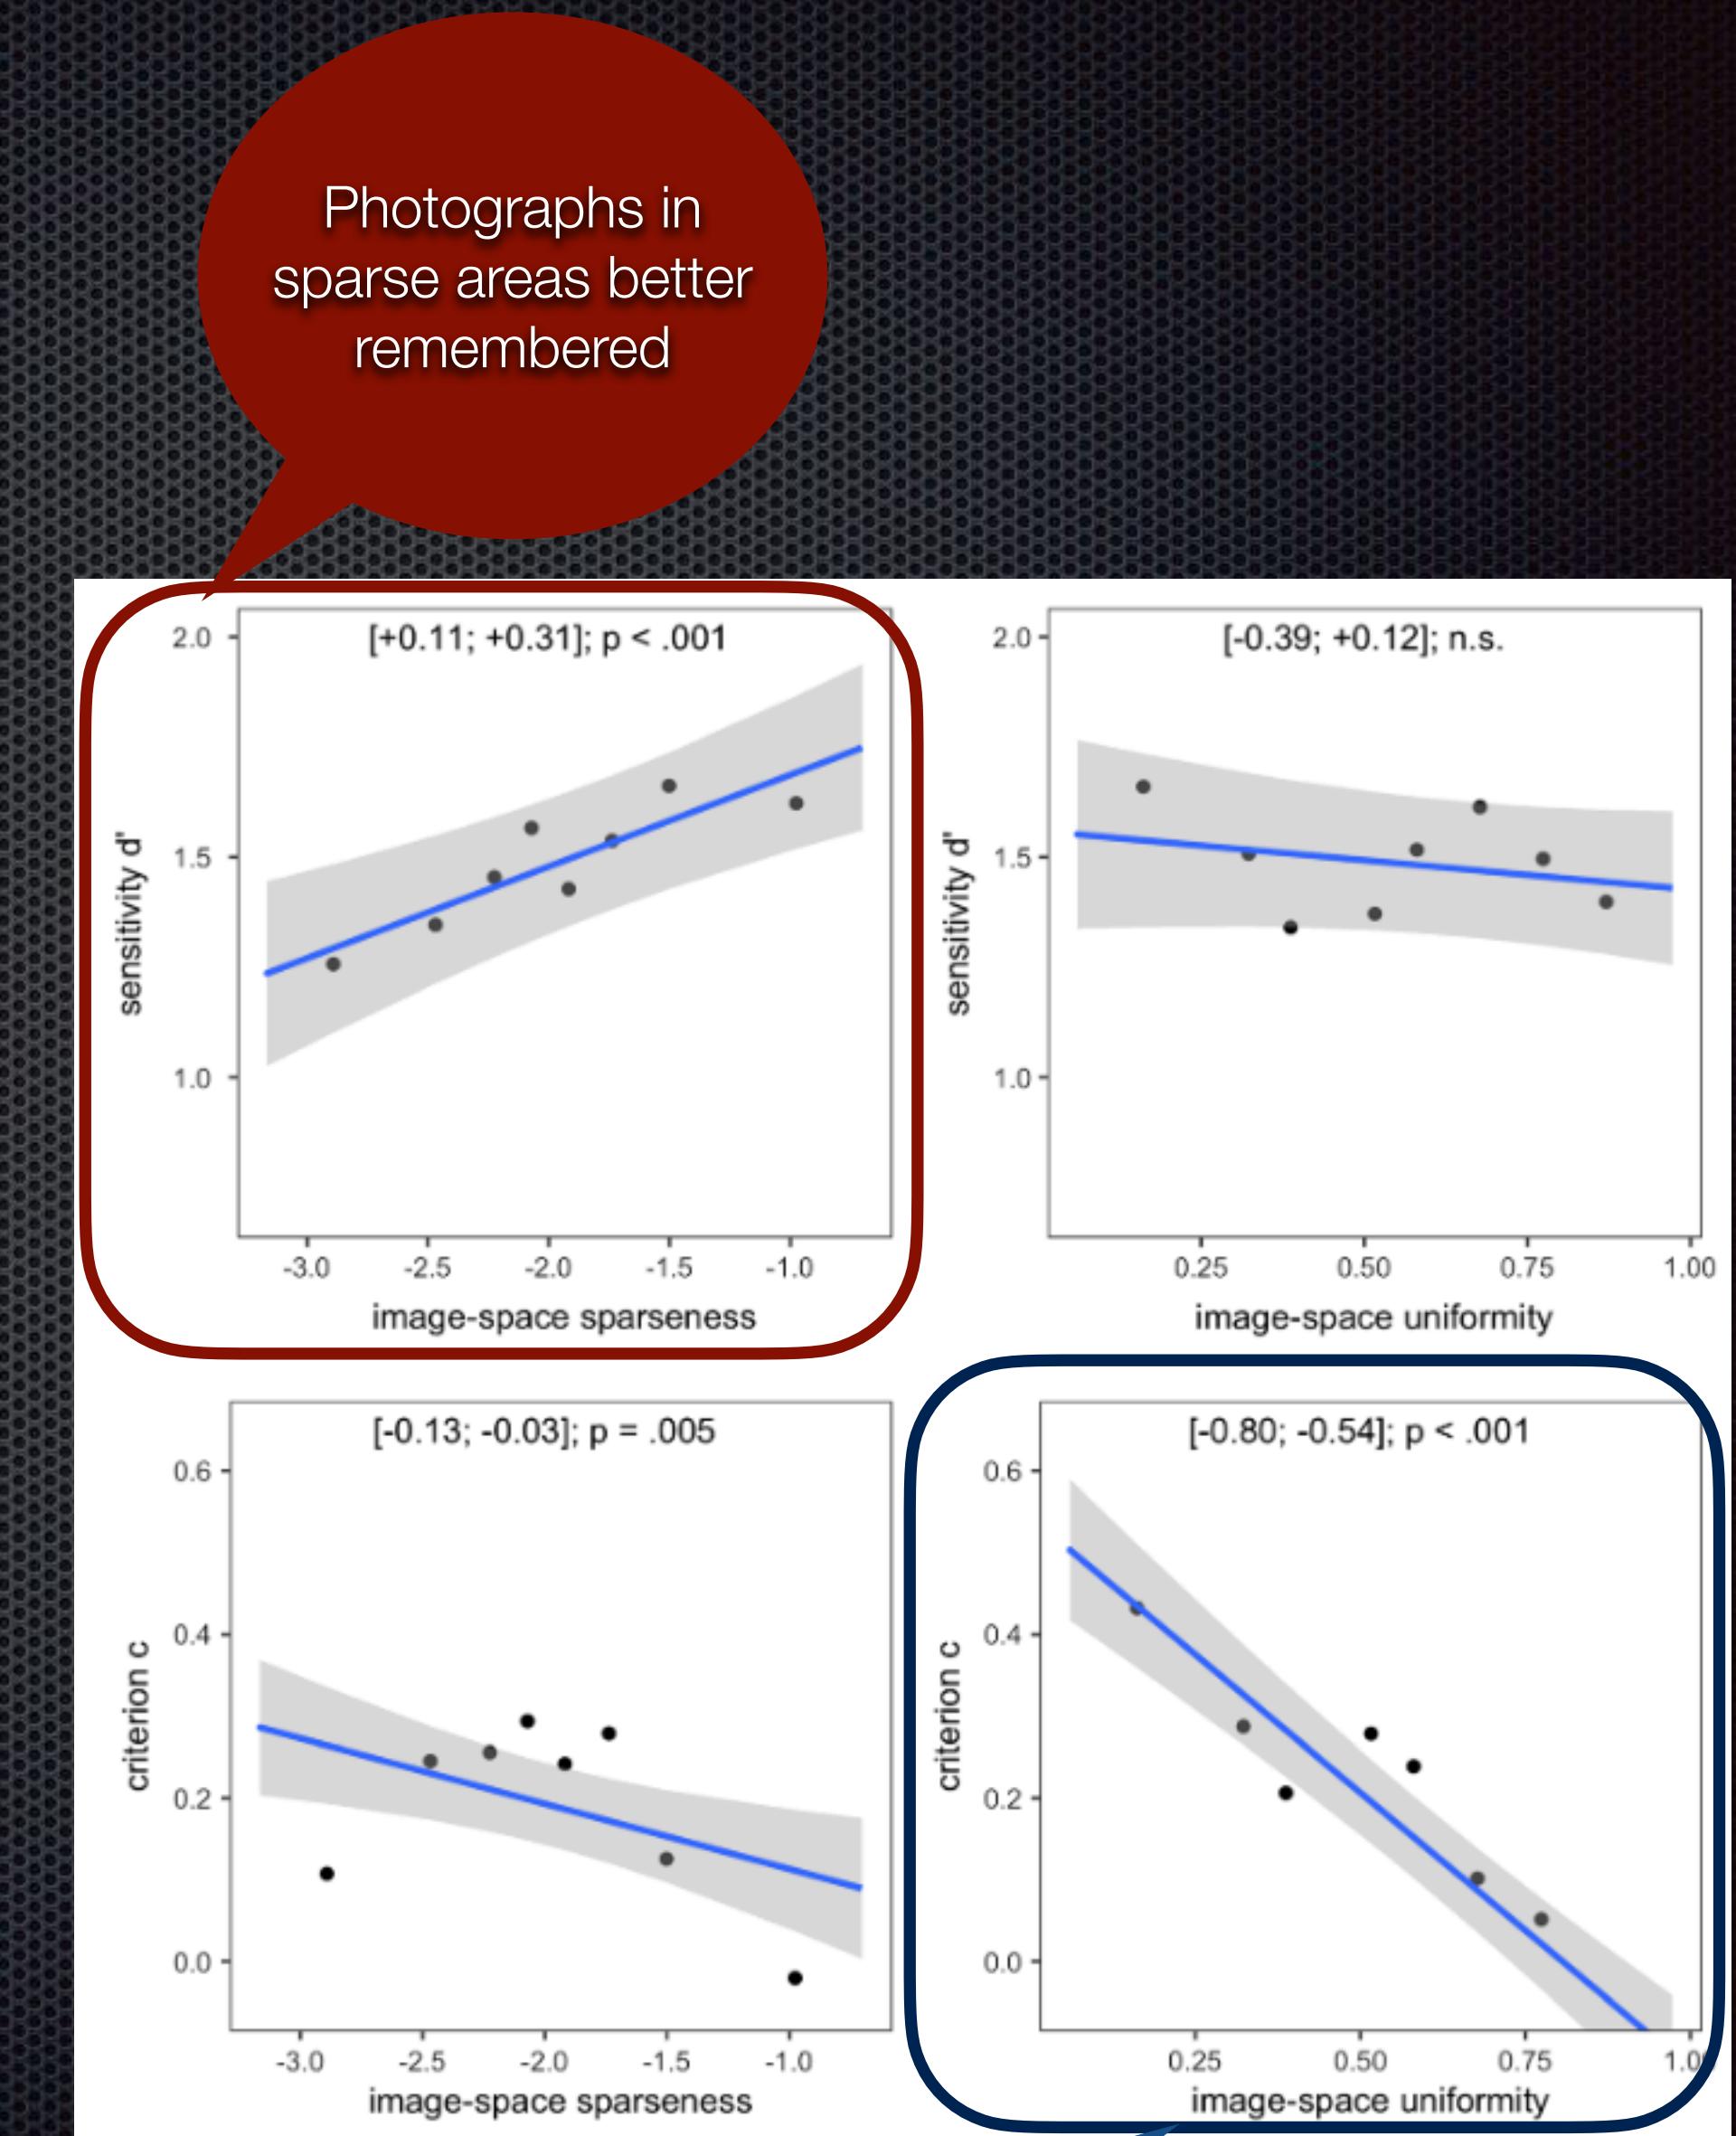
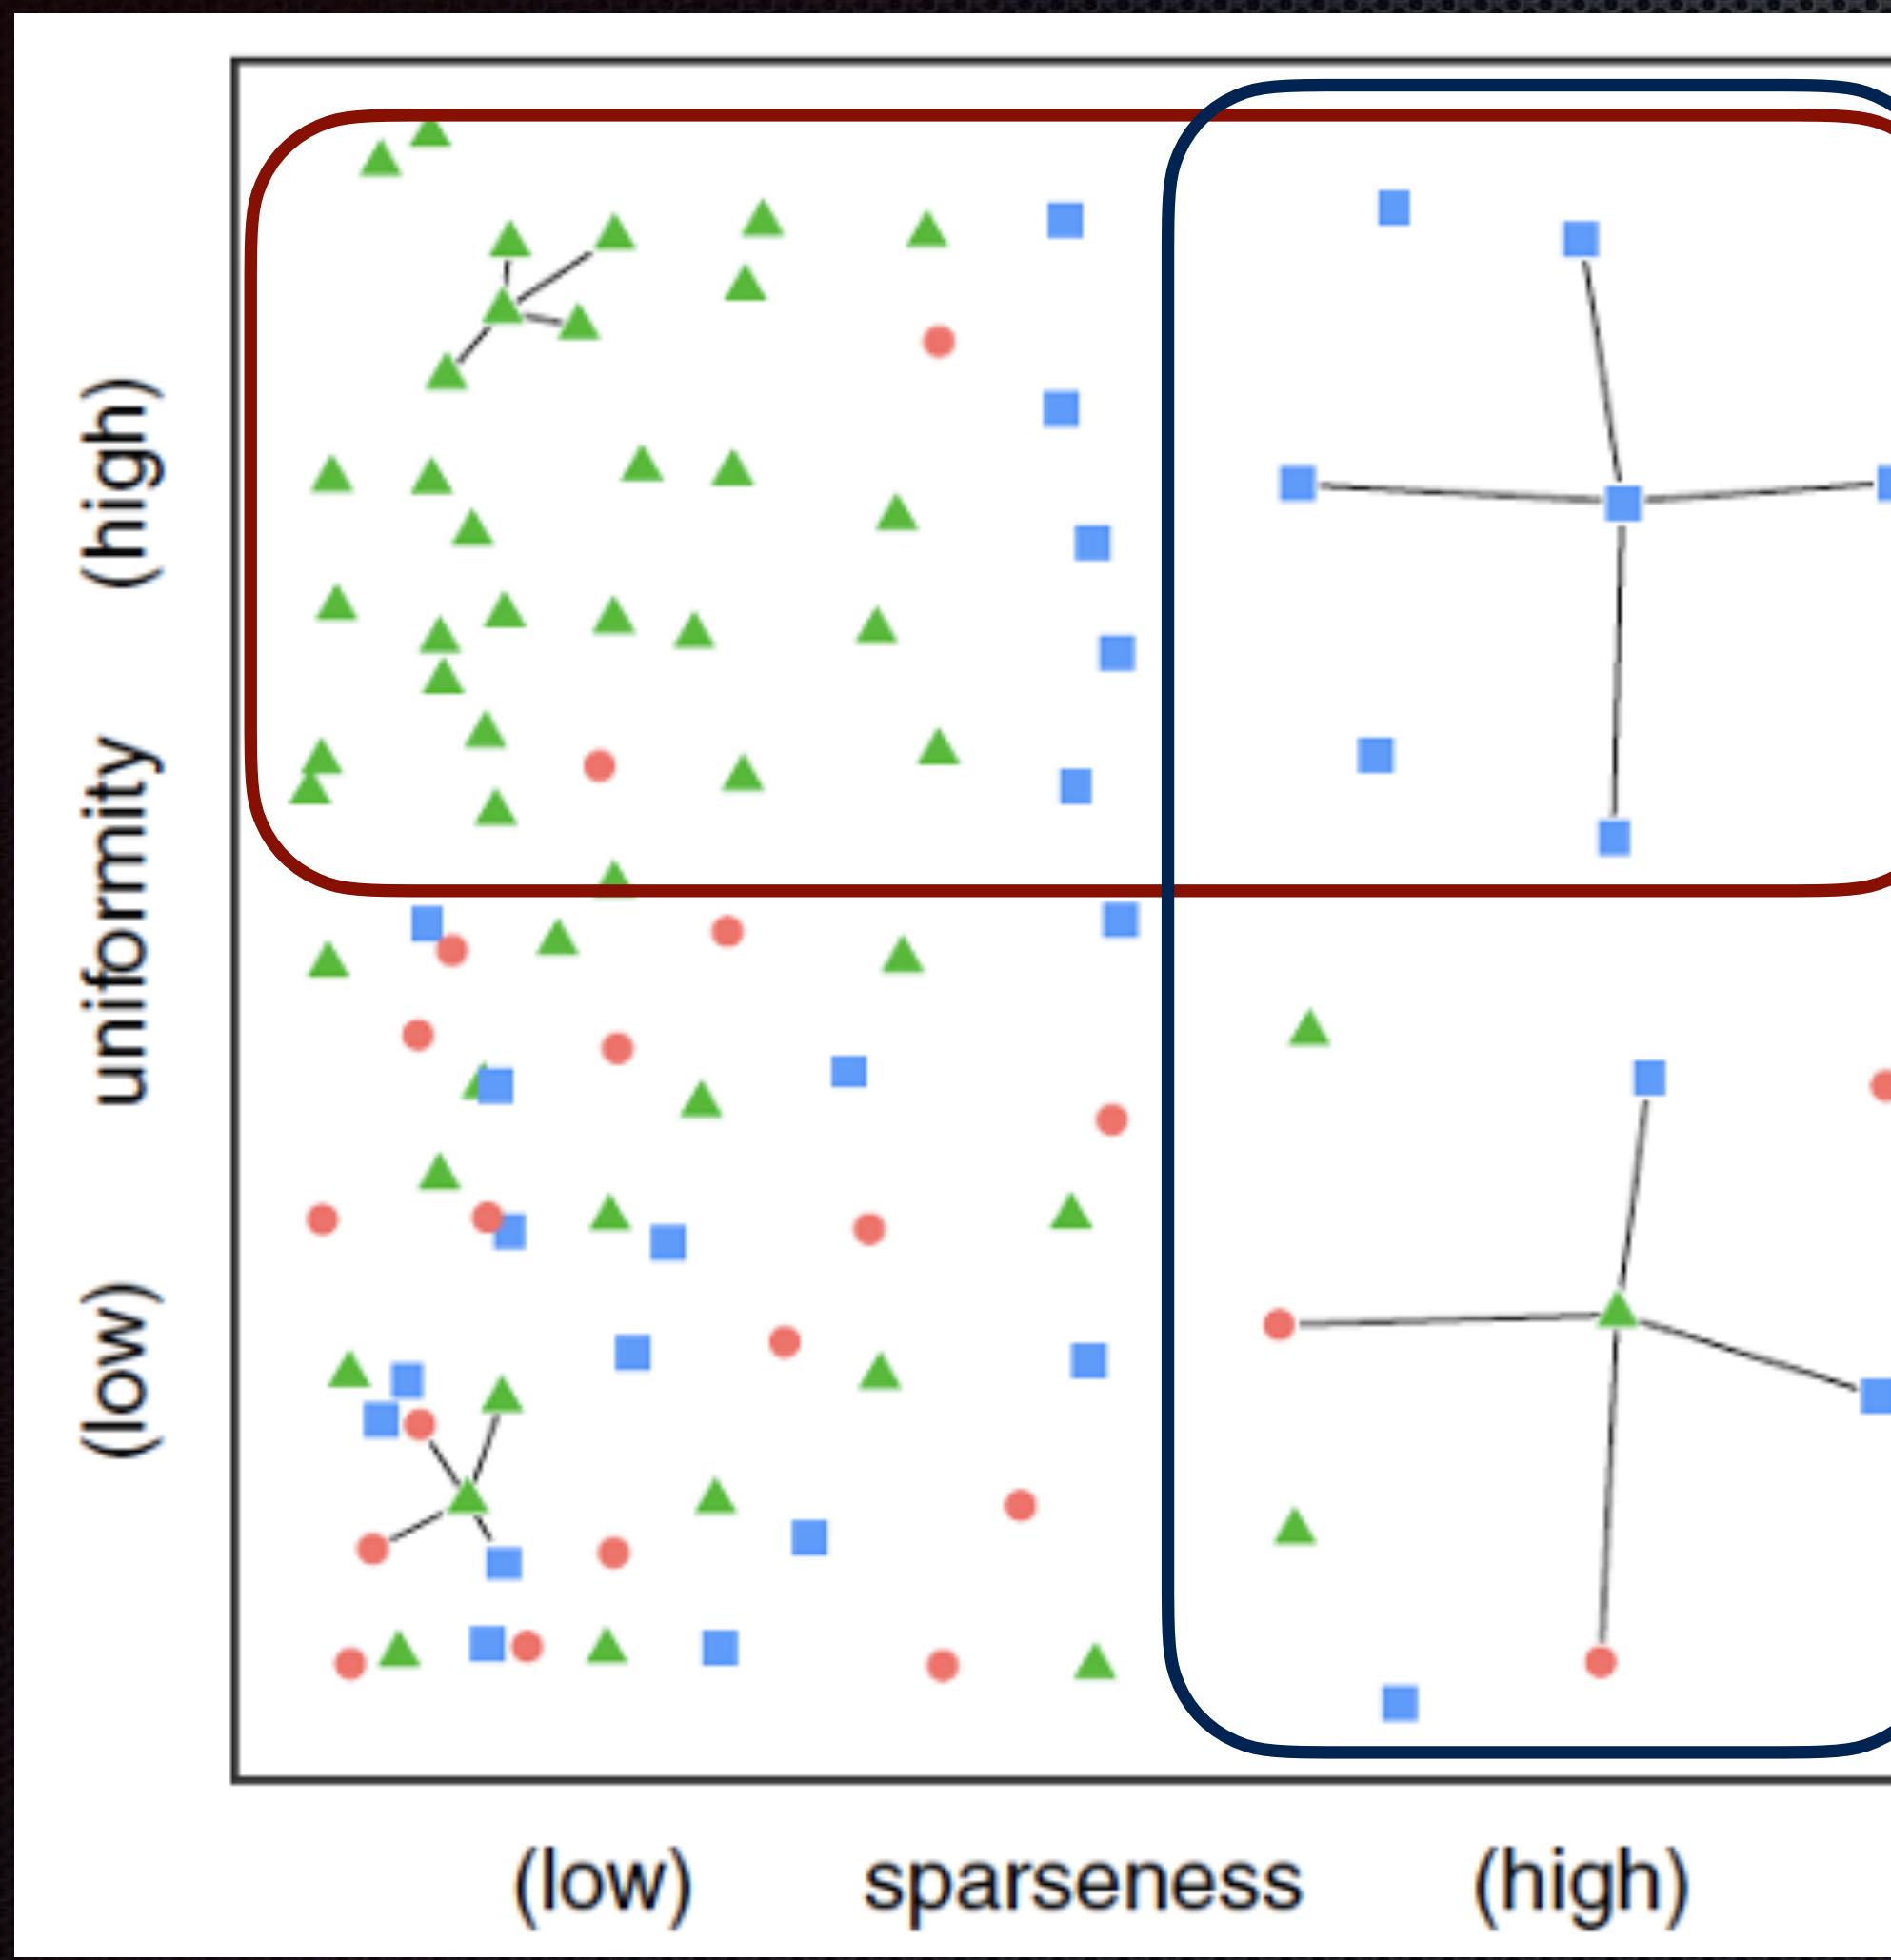
- Velké množství dimenzí
- Říká distribuce/vzdálenost obrázků něco o paměťovém výkonu?



Hypotézy



Výsledky



Photographs in sparse areas better remembered

Uniformity leads to false alarms

Svádění lidí k chybám

- Visual version of DRM paradigm
- DRM: 12 slov, všechny silně asociované, chybí centrální asociace
 - nemocný, sestřička, lék, nemocnice, chirurg, ... (doktor)
- **Dá se něco takového zopakovat s obrázky?**

(Deese, 1959; Roediger & McDermott, 1995)

Vision Research 178 (2021) 48–59

Contents lists available at ScienceDirect

 ELSEVIER

Vision Research

journal homepage: www.elsevier.com/locate/visres

False memories for scenes using the DRM paradigm

Filip Děchťárek ^{a,b,*}, Jiří Lukavský ^{a,b}, Jiří Štípl ^b

^a Institute of Psychology, Czech Academy of Sciences, Hybernská 8, 110 00 Prague, Czech Republic

^b Faculty of Arts, Charles University, Malostranské nám. 20, 110 00 Prague, Czech Republic



Výběr obrázků

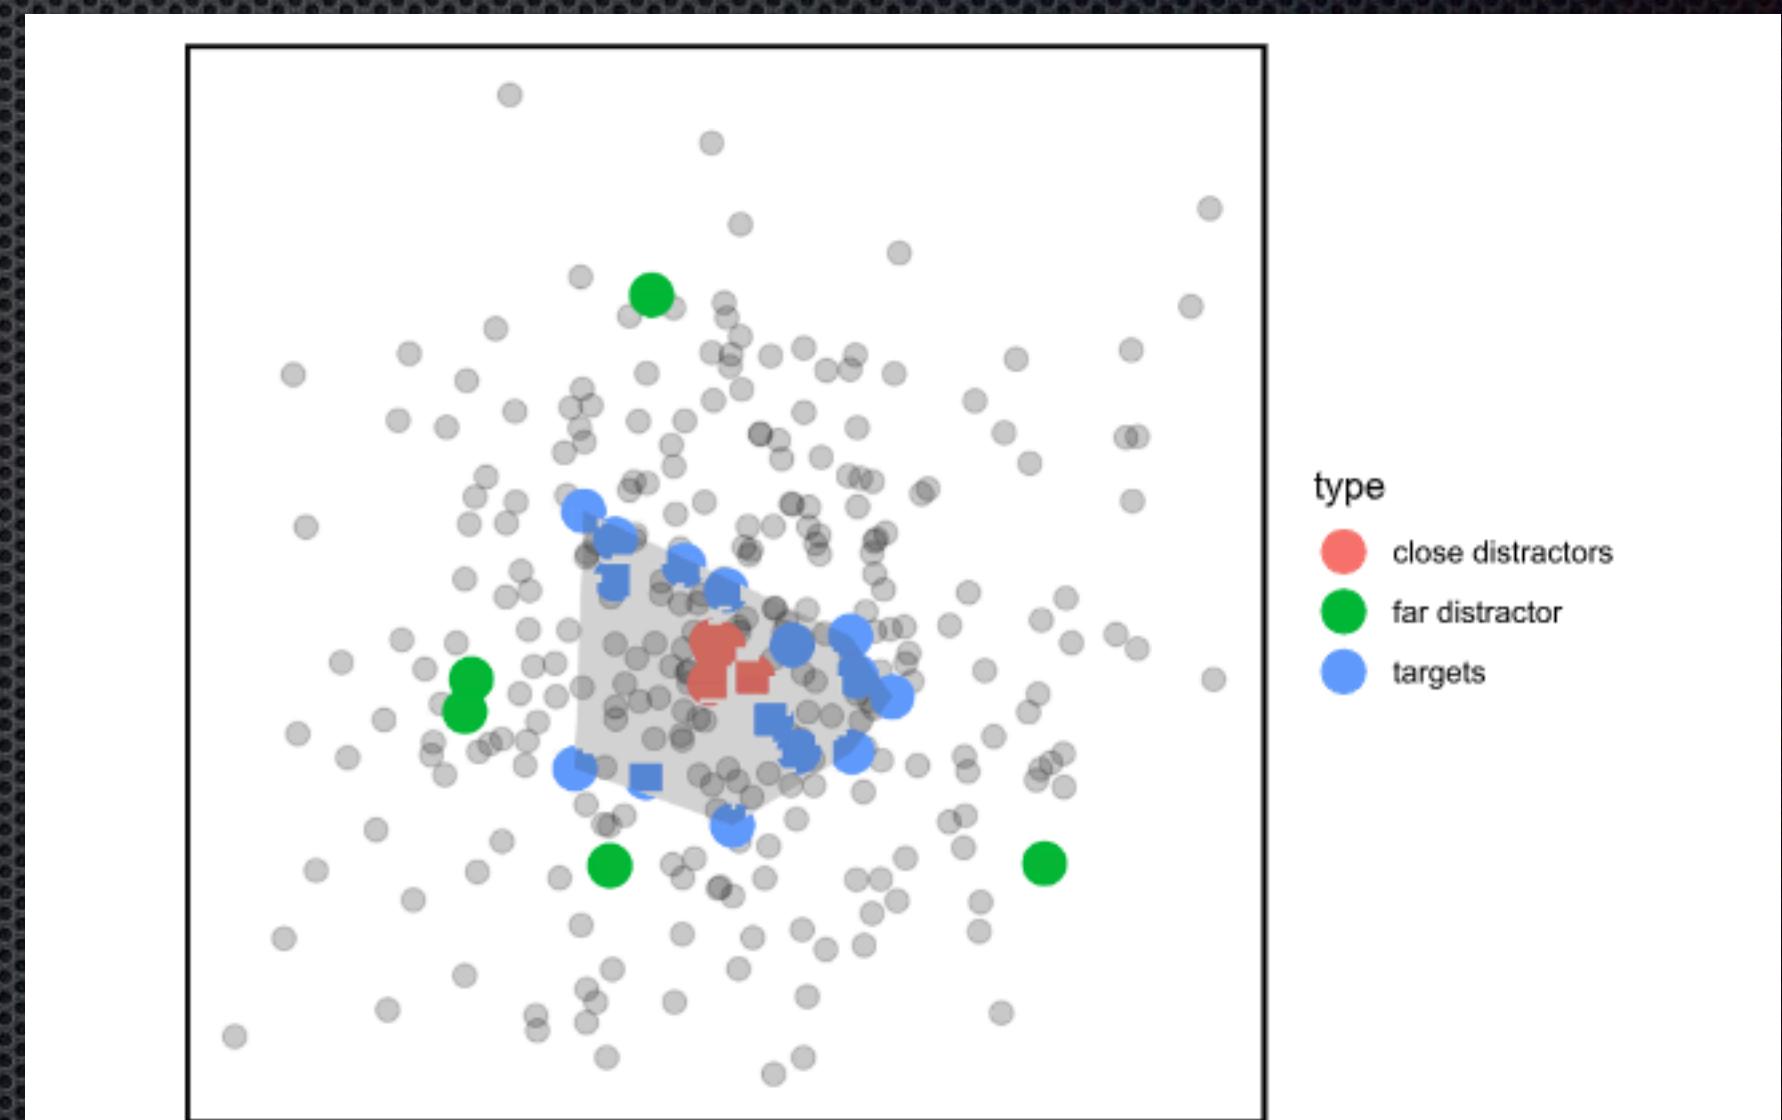
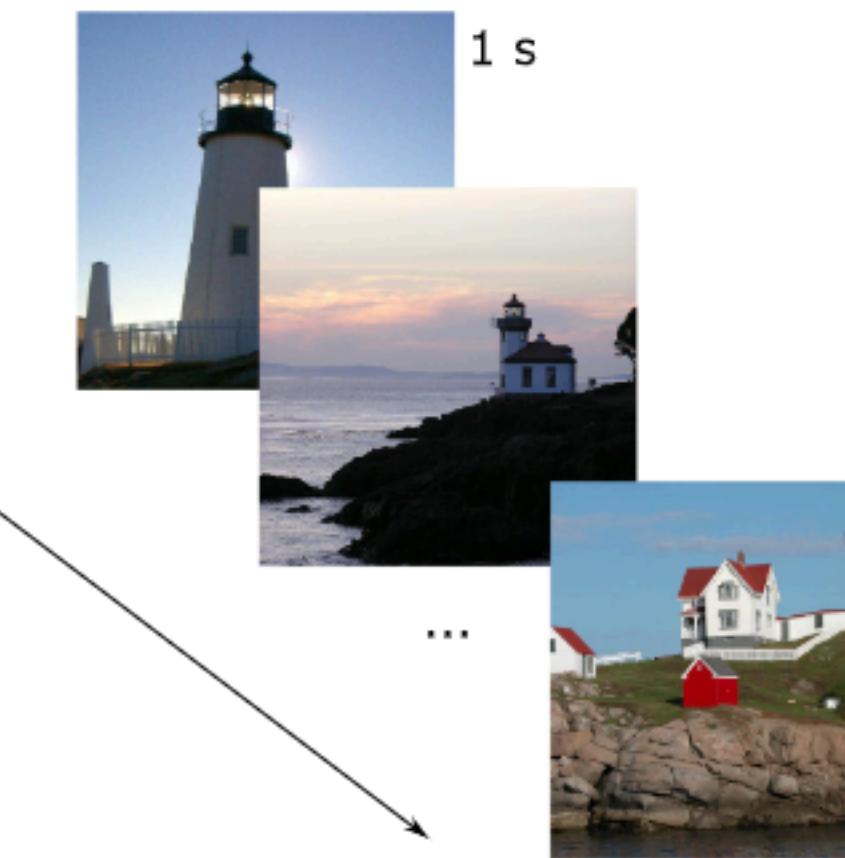


Fig. 5. Schema of the experimental design. Each point denotes one scene. Blue dots are randomly selected targets from the closer group and shaded areas represent virtual polygons formed by the targets. Red dots represent close distractors selected as the closest exemplars to the center of the targets. Green dots represent far distractors selected from the farther scenes. (For interpretation of the references to color in this figure legend, the reader is referred to the web version of this article.)

Podněty

training block (n=15)



...

testing block (5 + 5 + 5)



targets



close distractors



far distractors



Výsledky

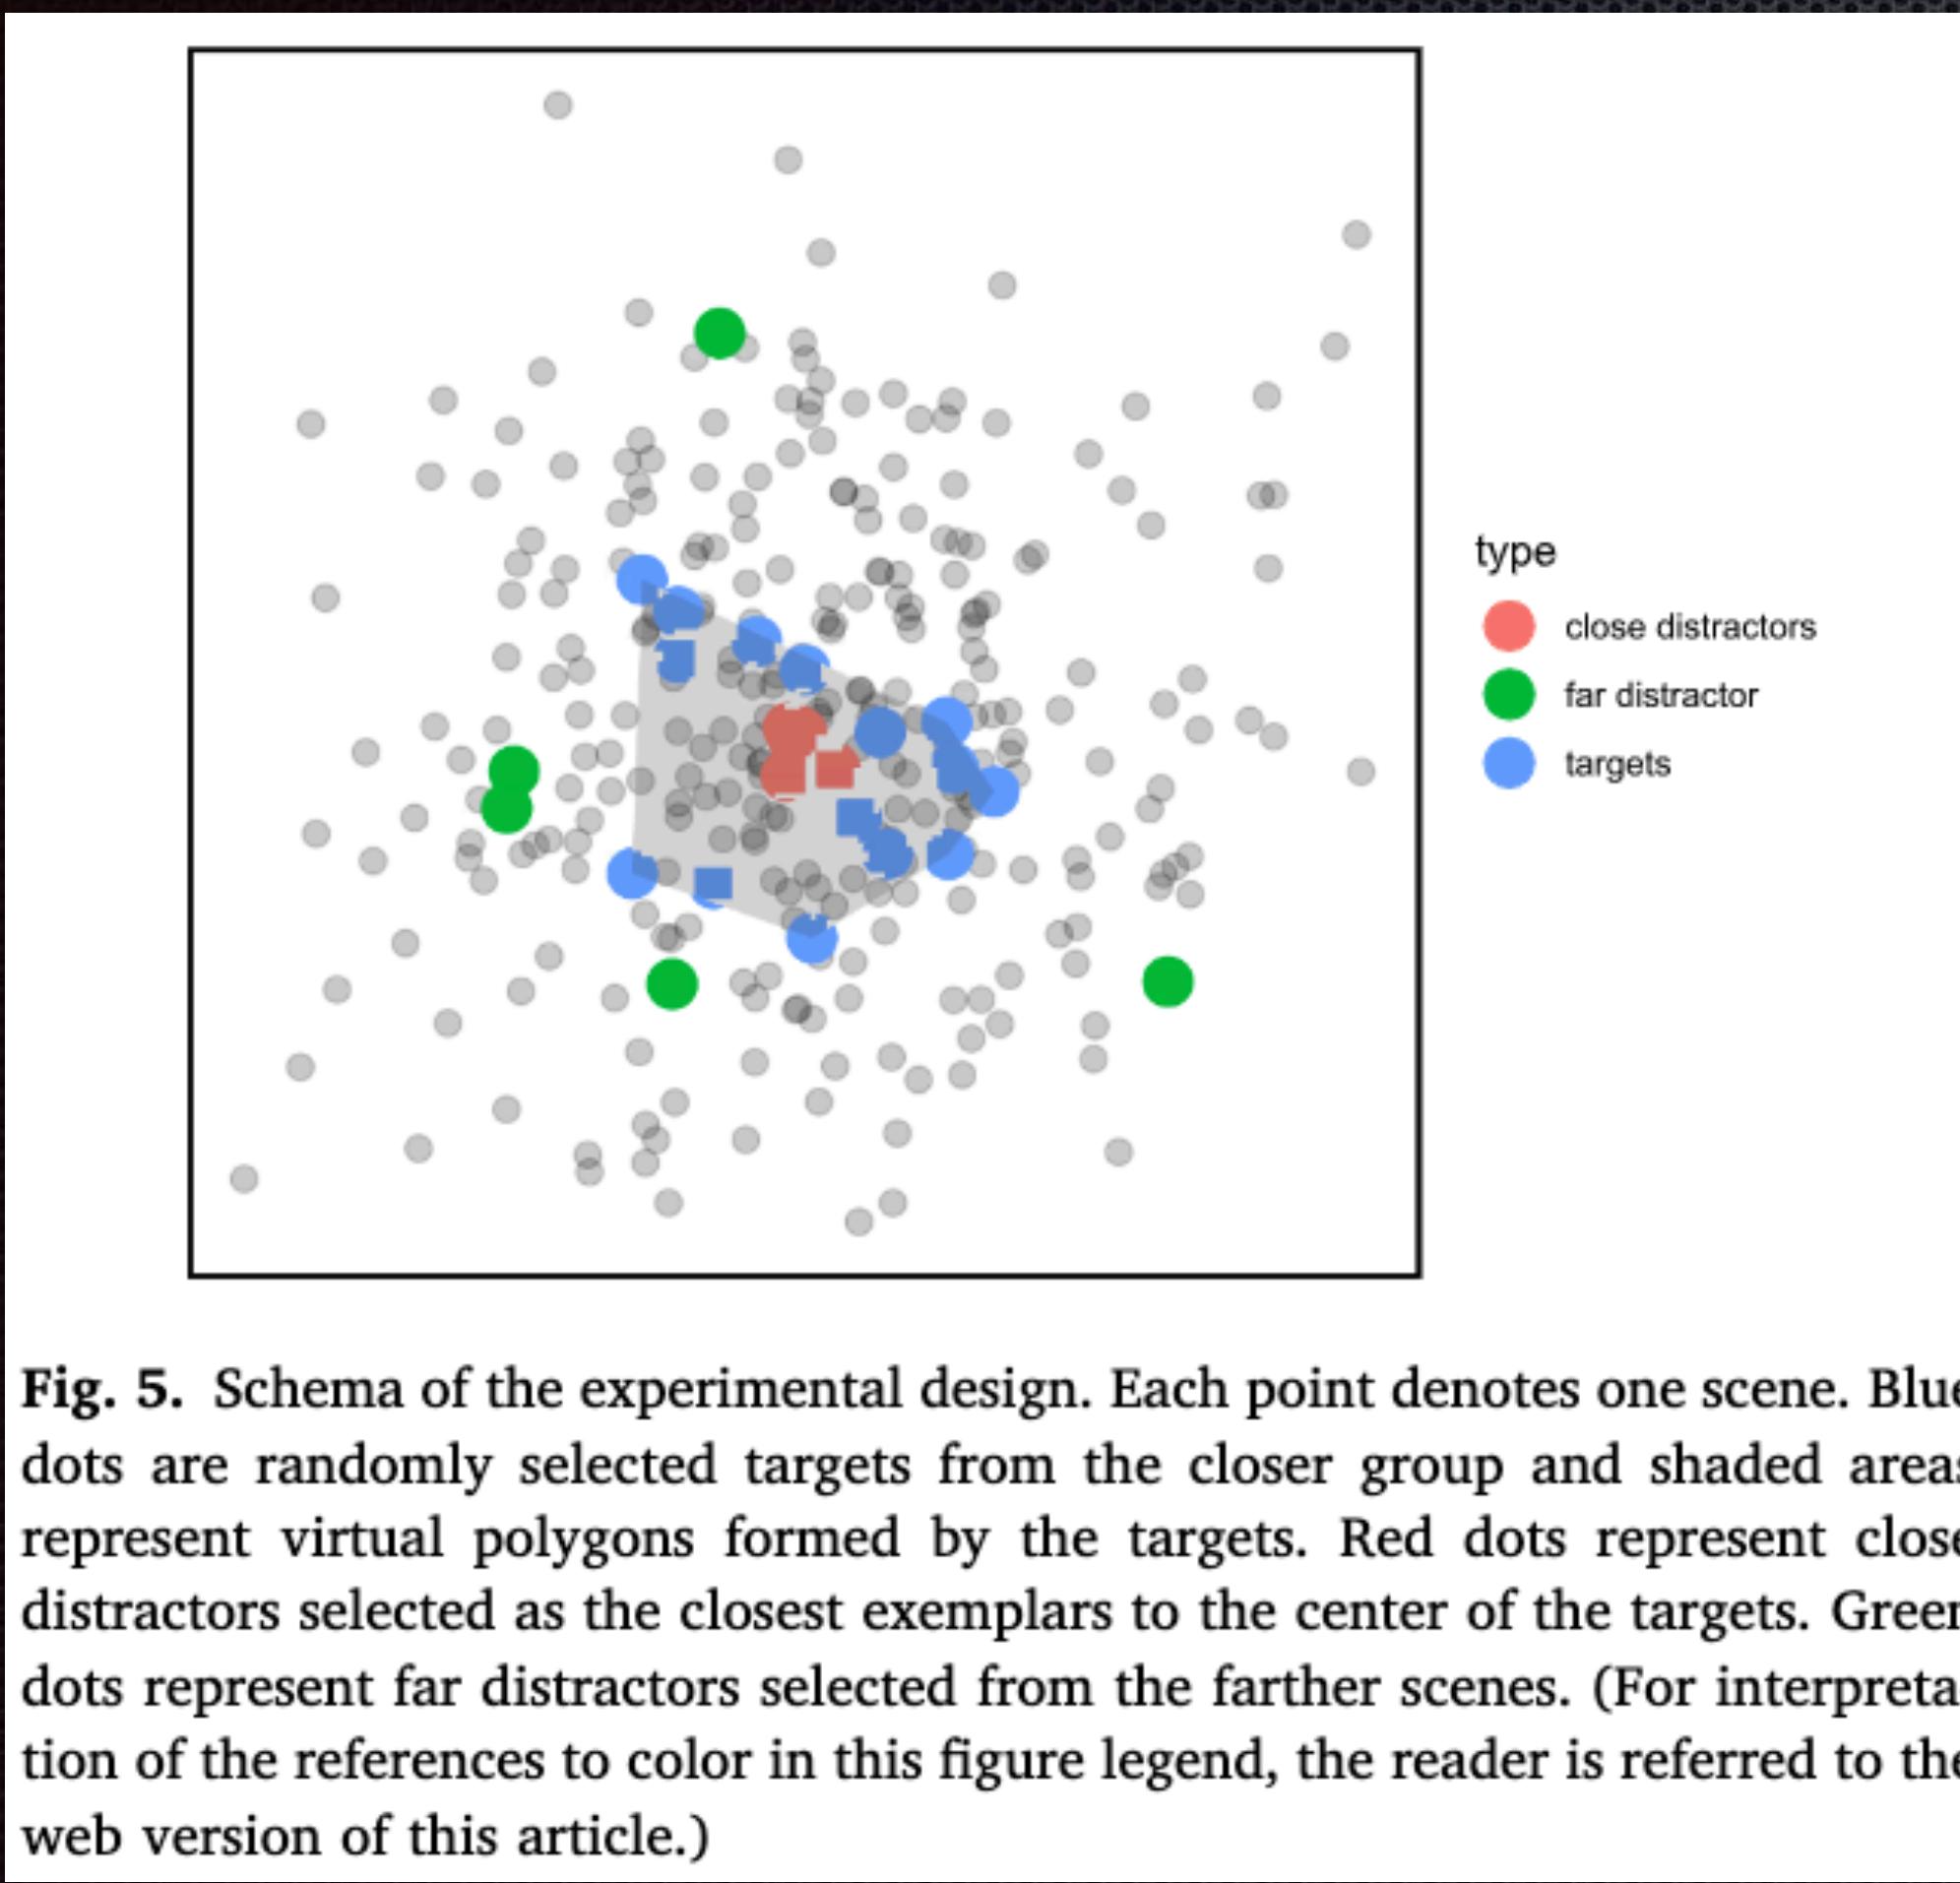
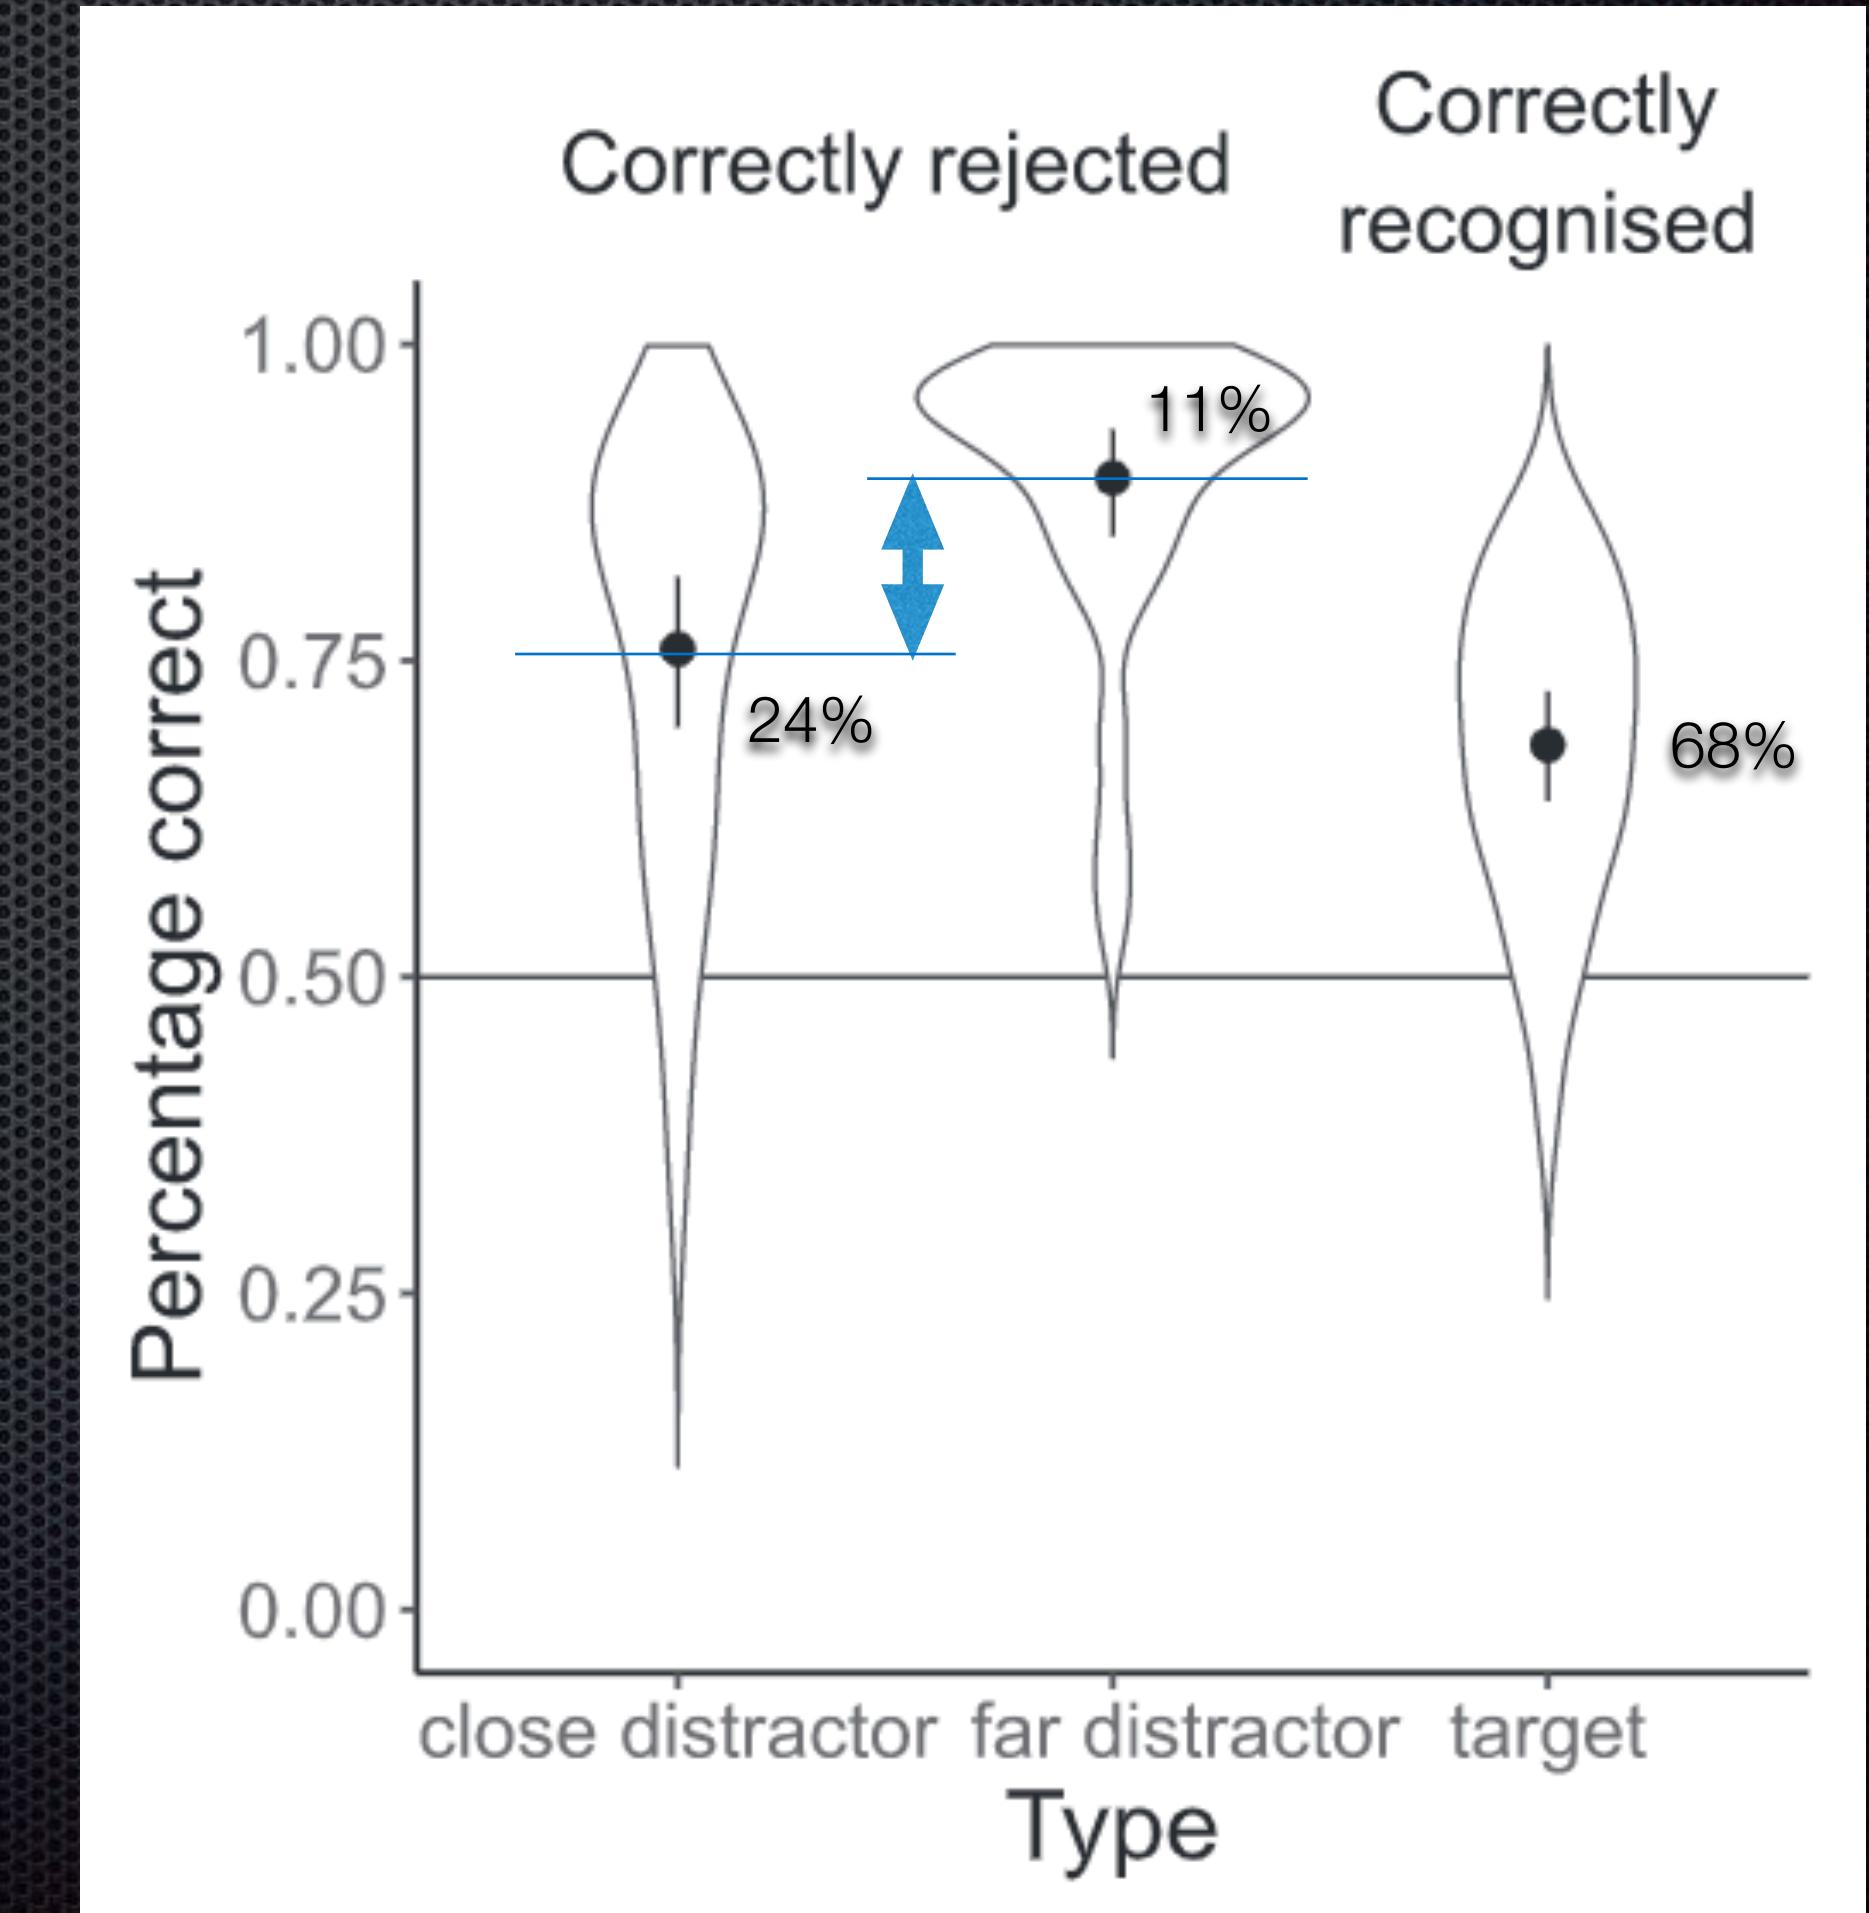


Fig. 5. Schema of the experimental design. Each point denotes one scene. Blue dots are randomly selected targets from the closer group and shaded areas represent virtual polygons formed by the targets. Red dots represent close distractors selected as the closest exemplars to the center of the targets. Green dots represent far distractors selected from the farther scenes. (For interpretation of the references to color in this figure legend, the reader is referred to the web version of this article.)



Change detection

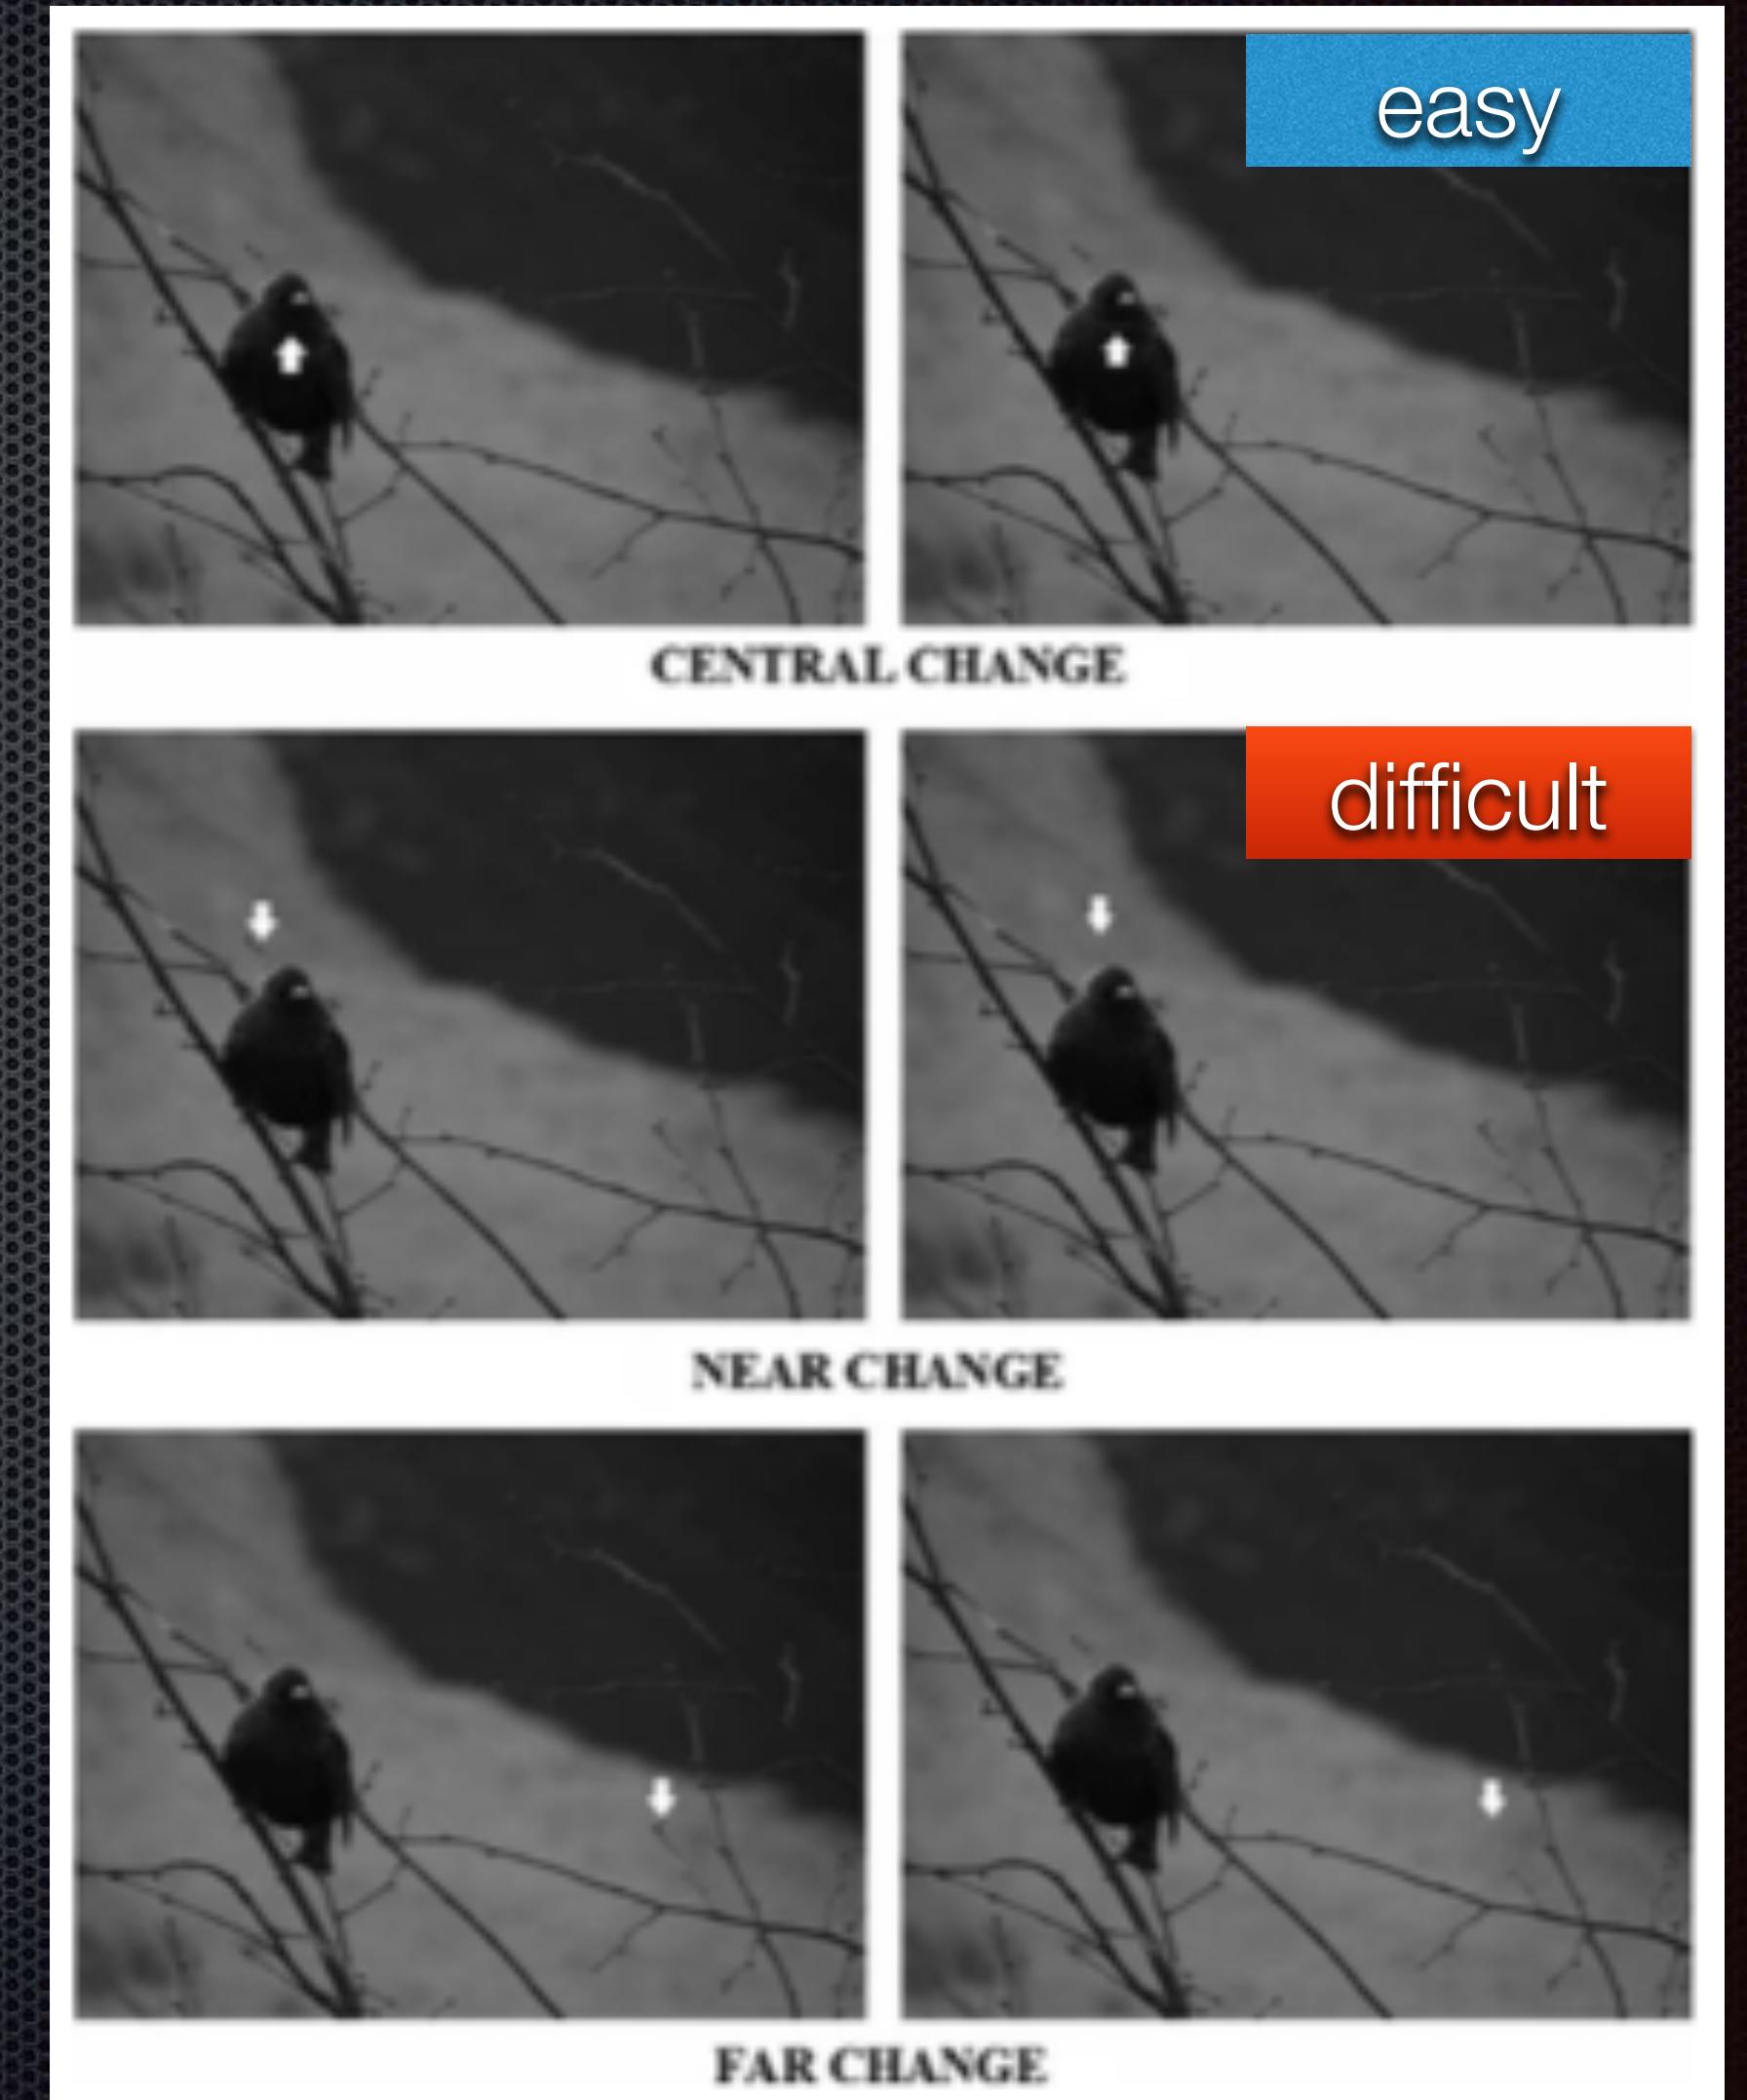


Správná odpověď



Faktory ovlivňující výkon

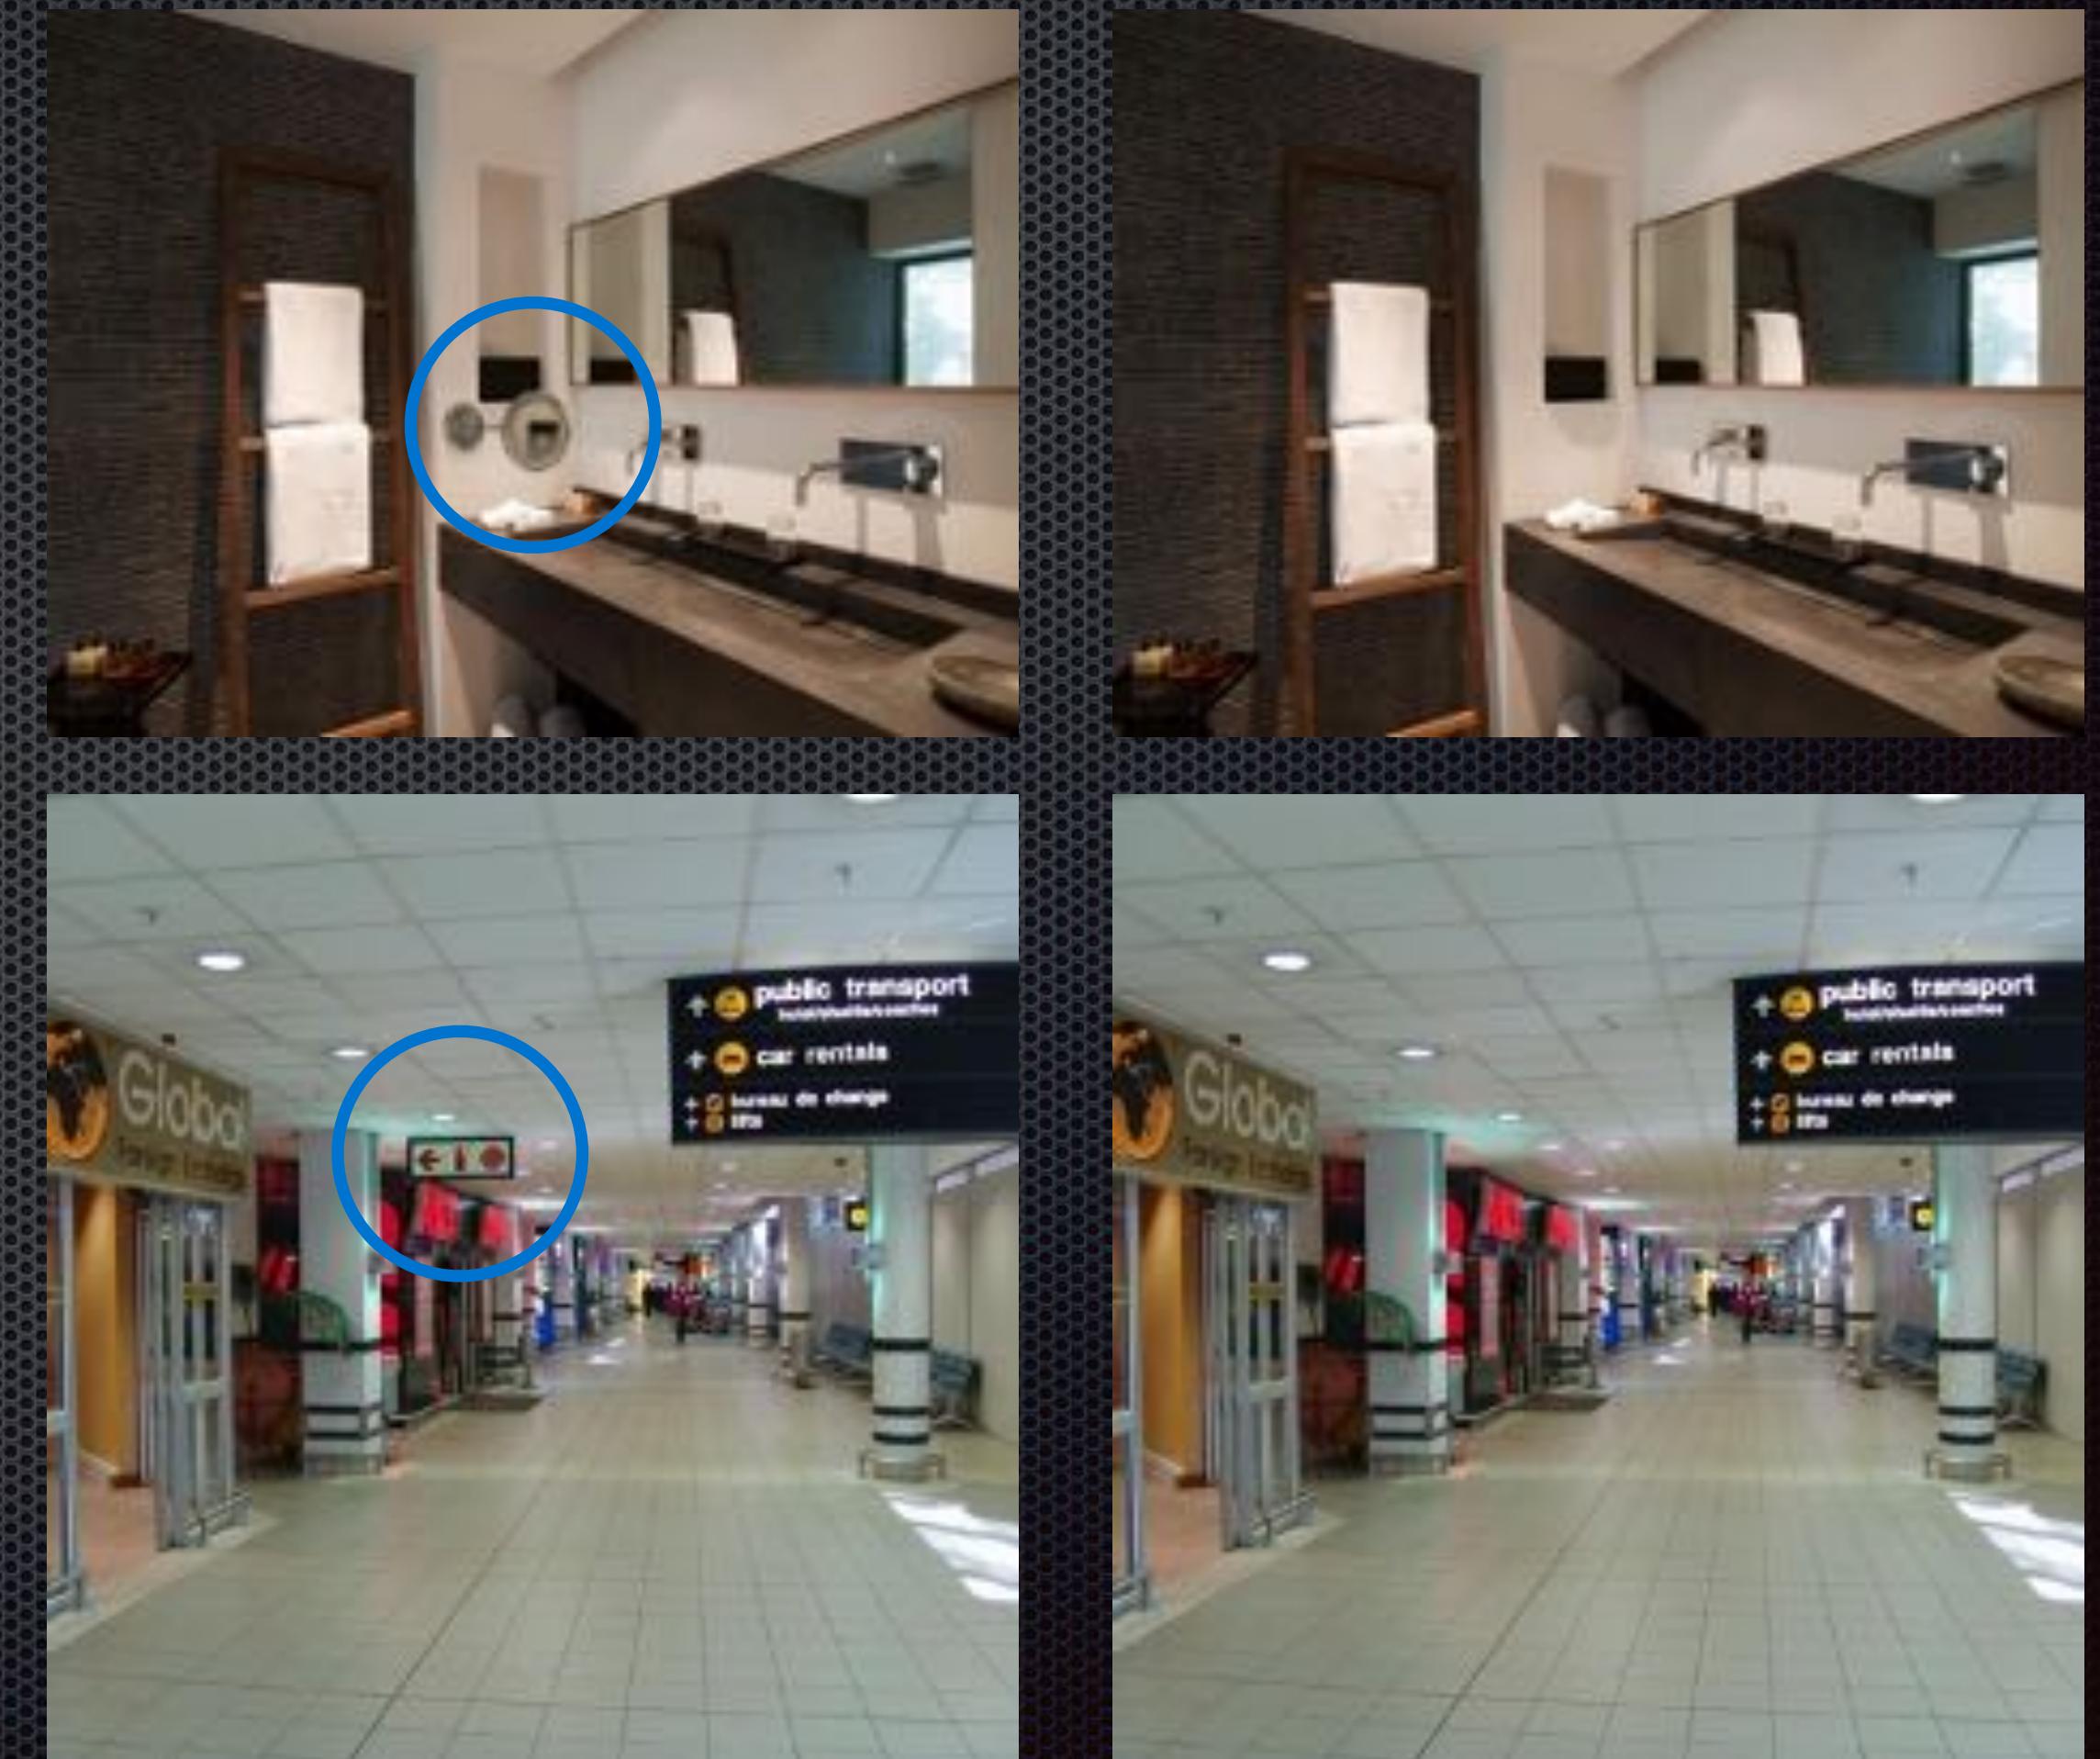
- Slabý nebo žádný efekt
 - Velikost
 - Ekcentricita
- Vzdálenost od hlavní figury



Utochkin (2011)

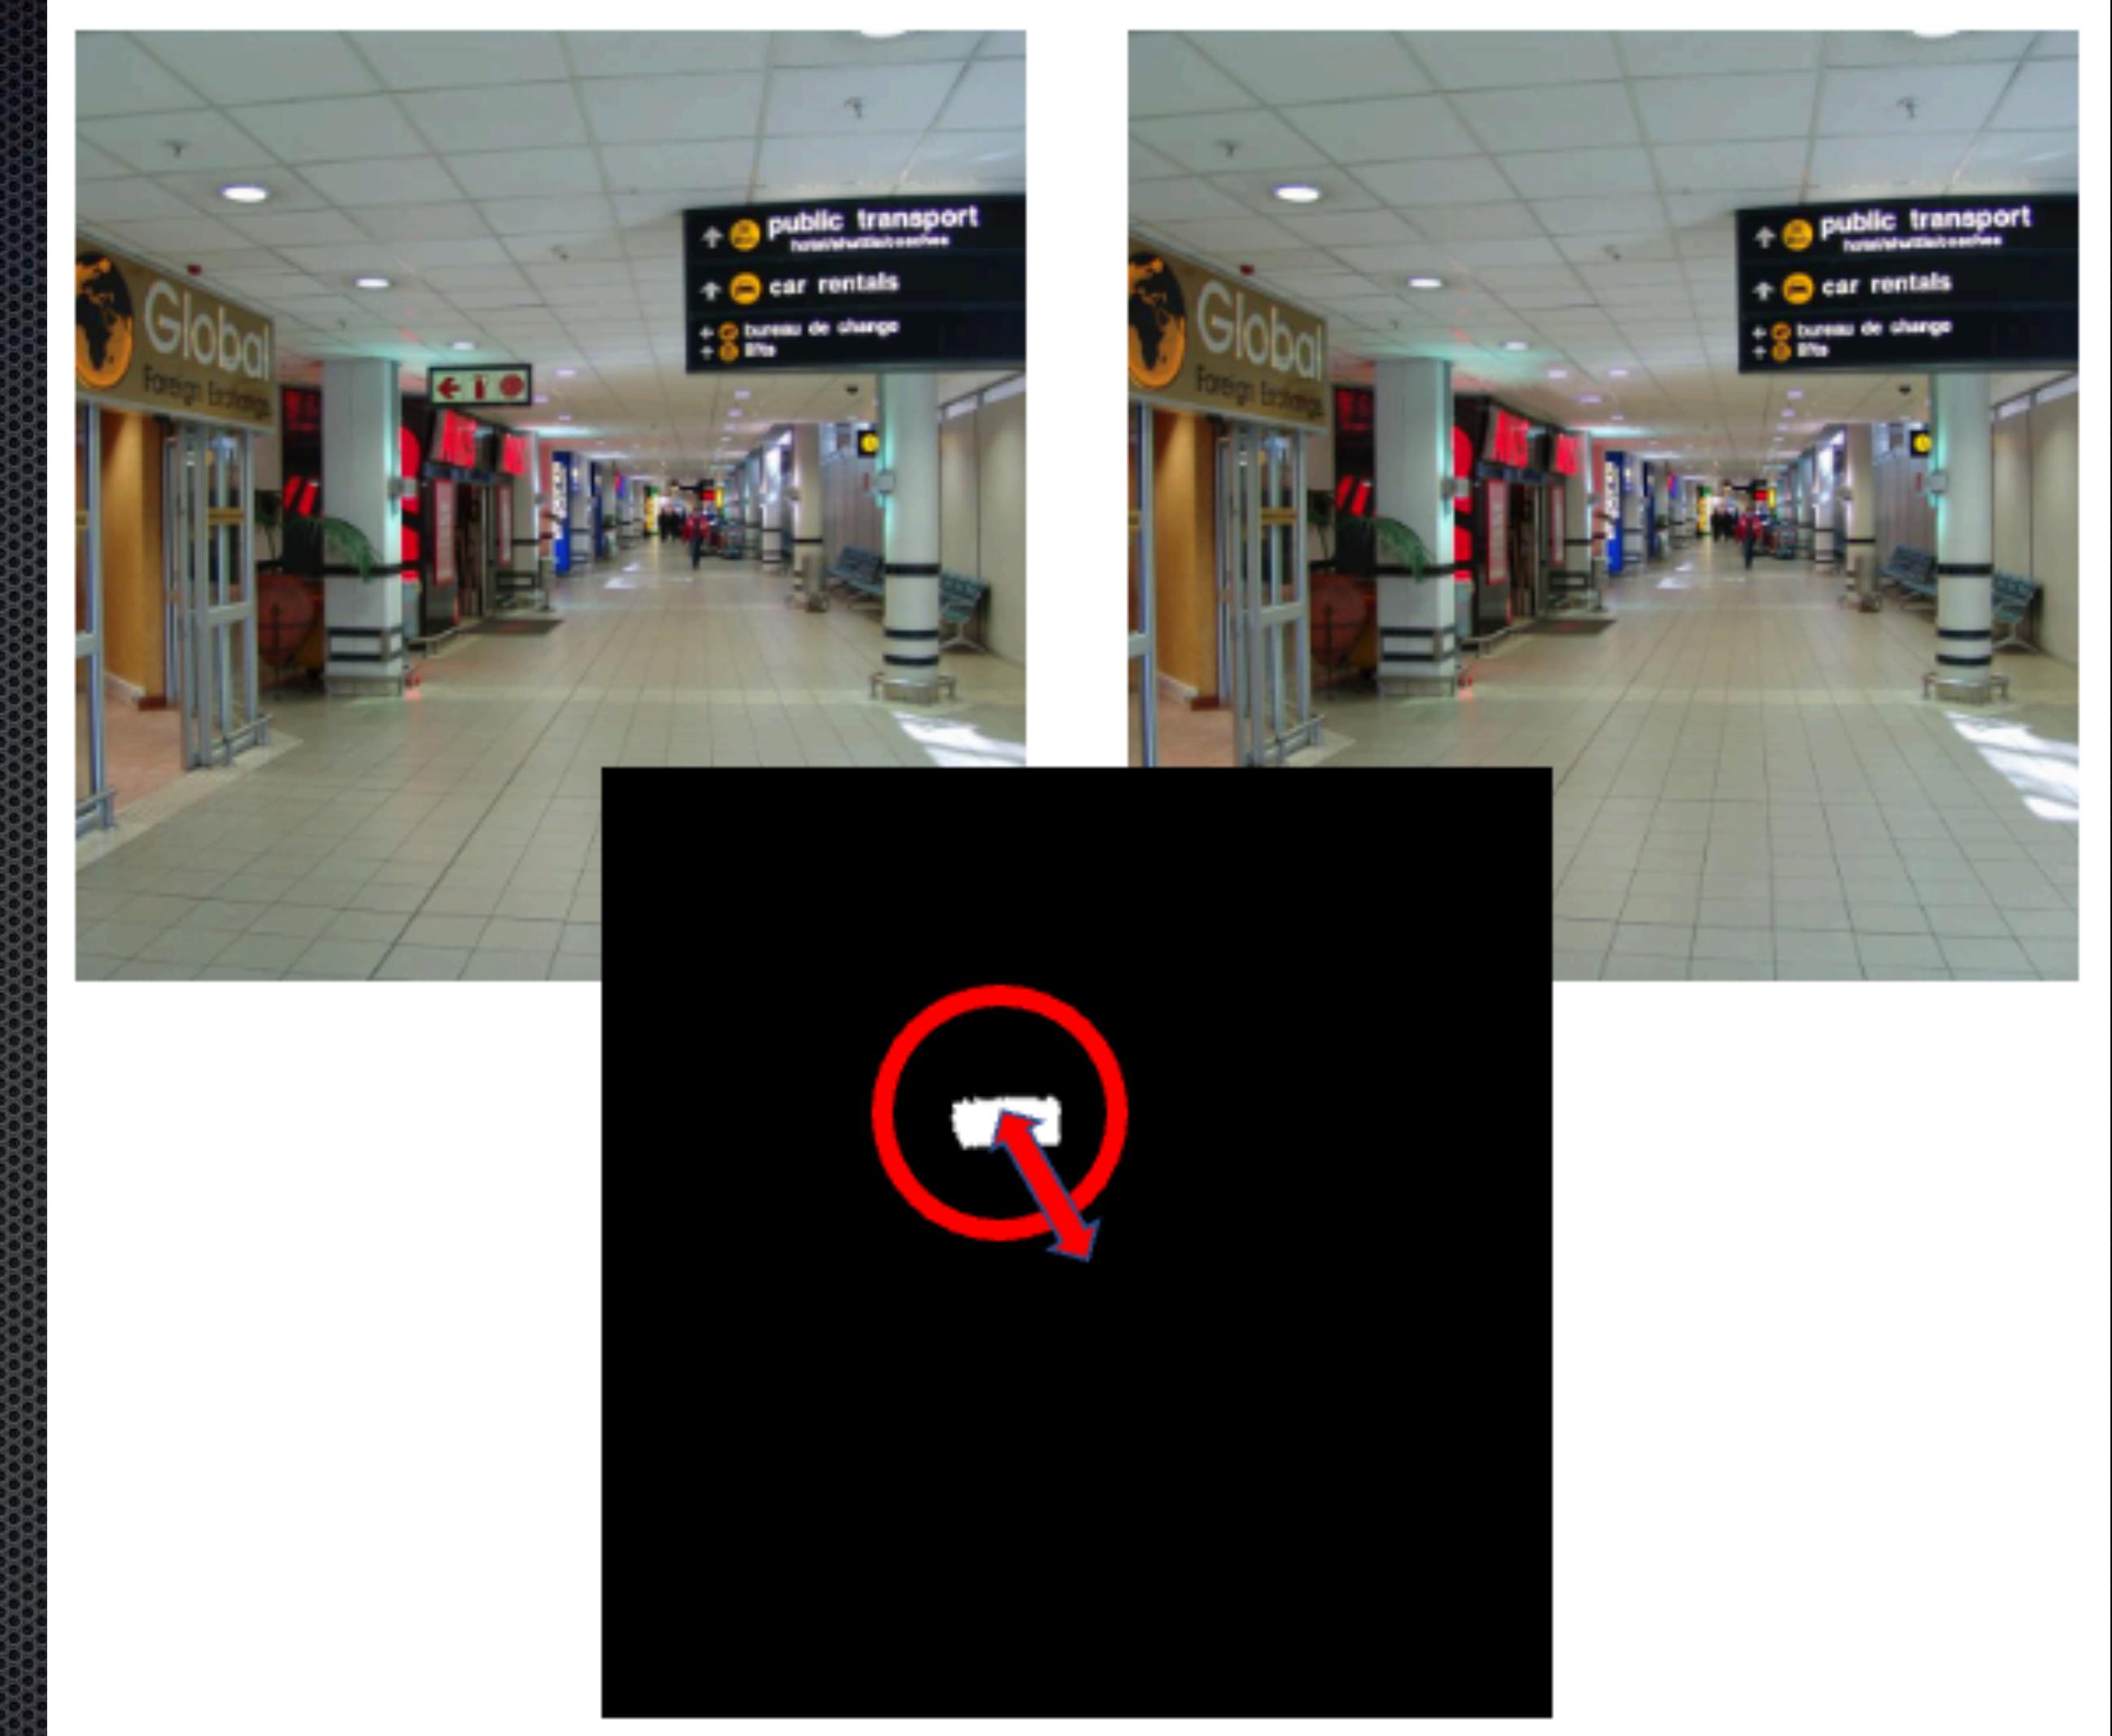
Change detection

- CBDatabase
 - 128 párů, N=13
 - 1024×768
- CBmemo
 - 128 párů, N=40
 - 700×700



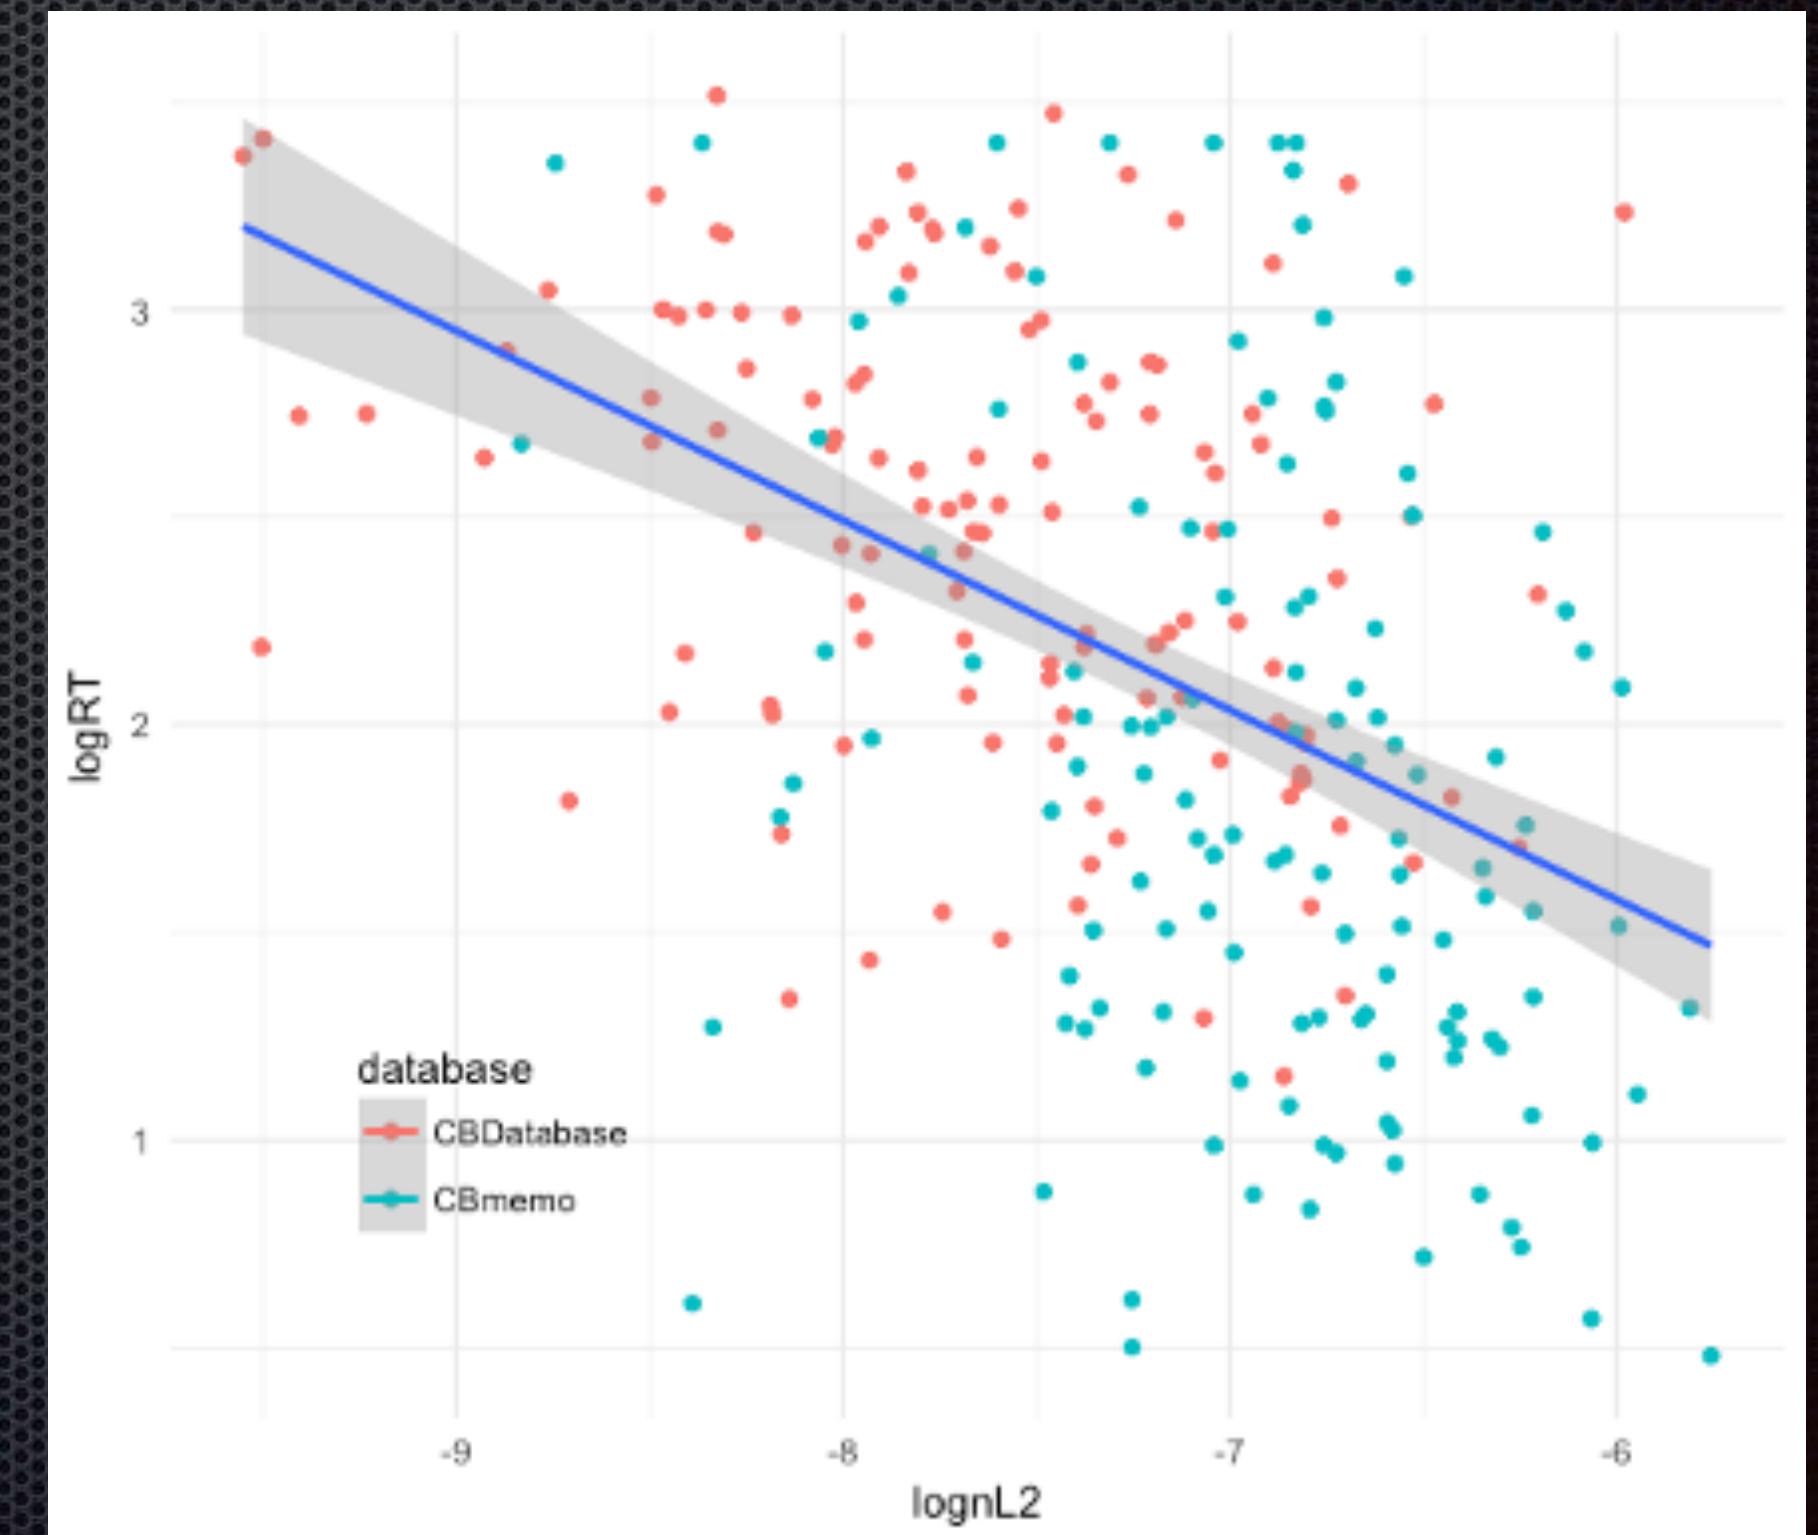
Proměnné

- Grafické faktory
 - Plocha
 - Ekcentricita
- Změna obsahu
- L2 distance přes PlacesCNN



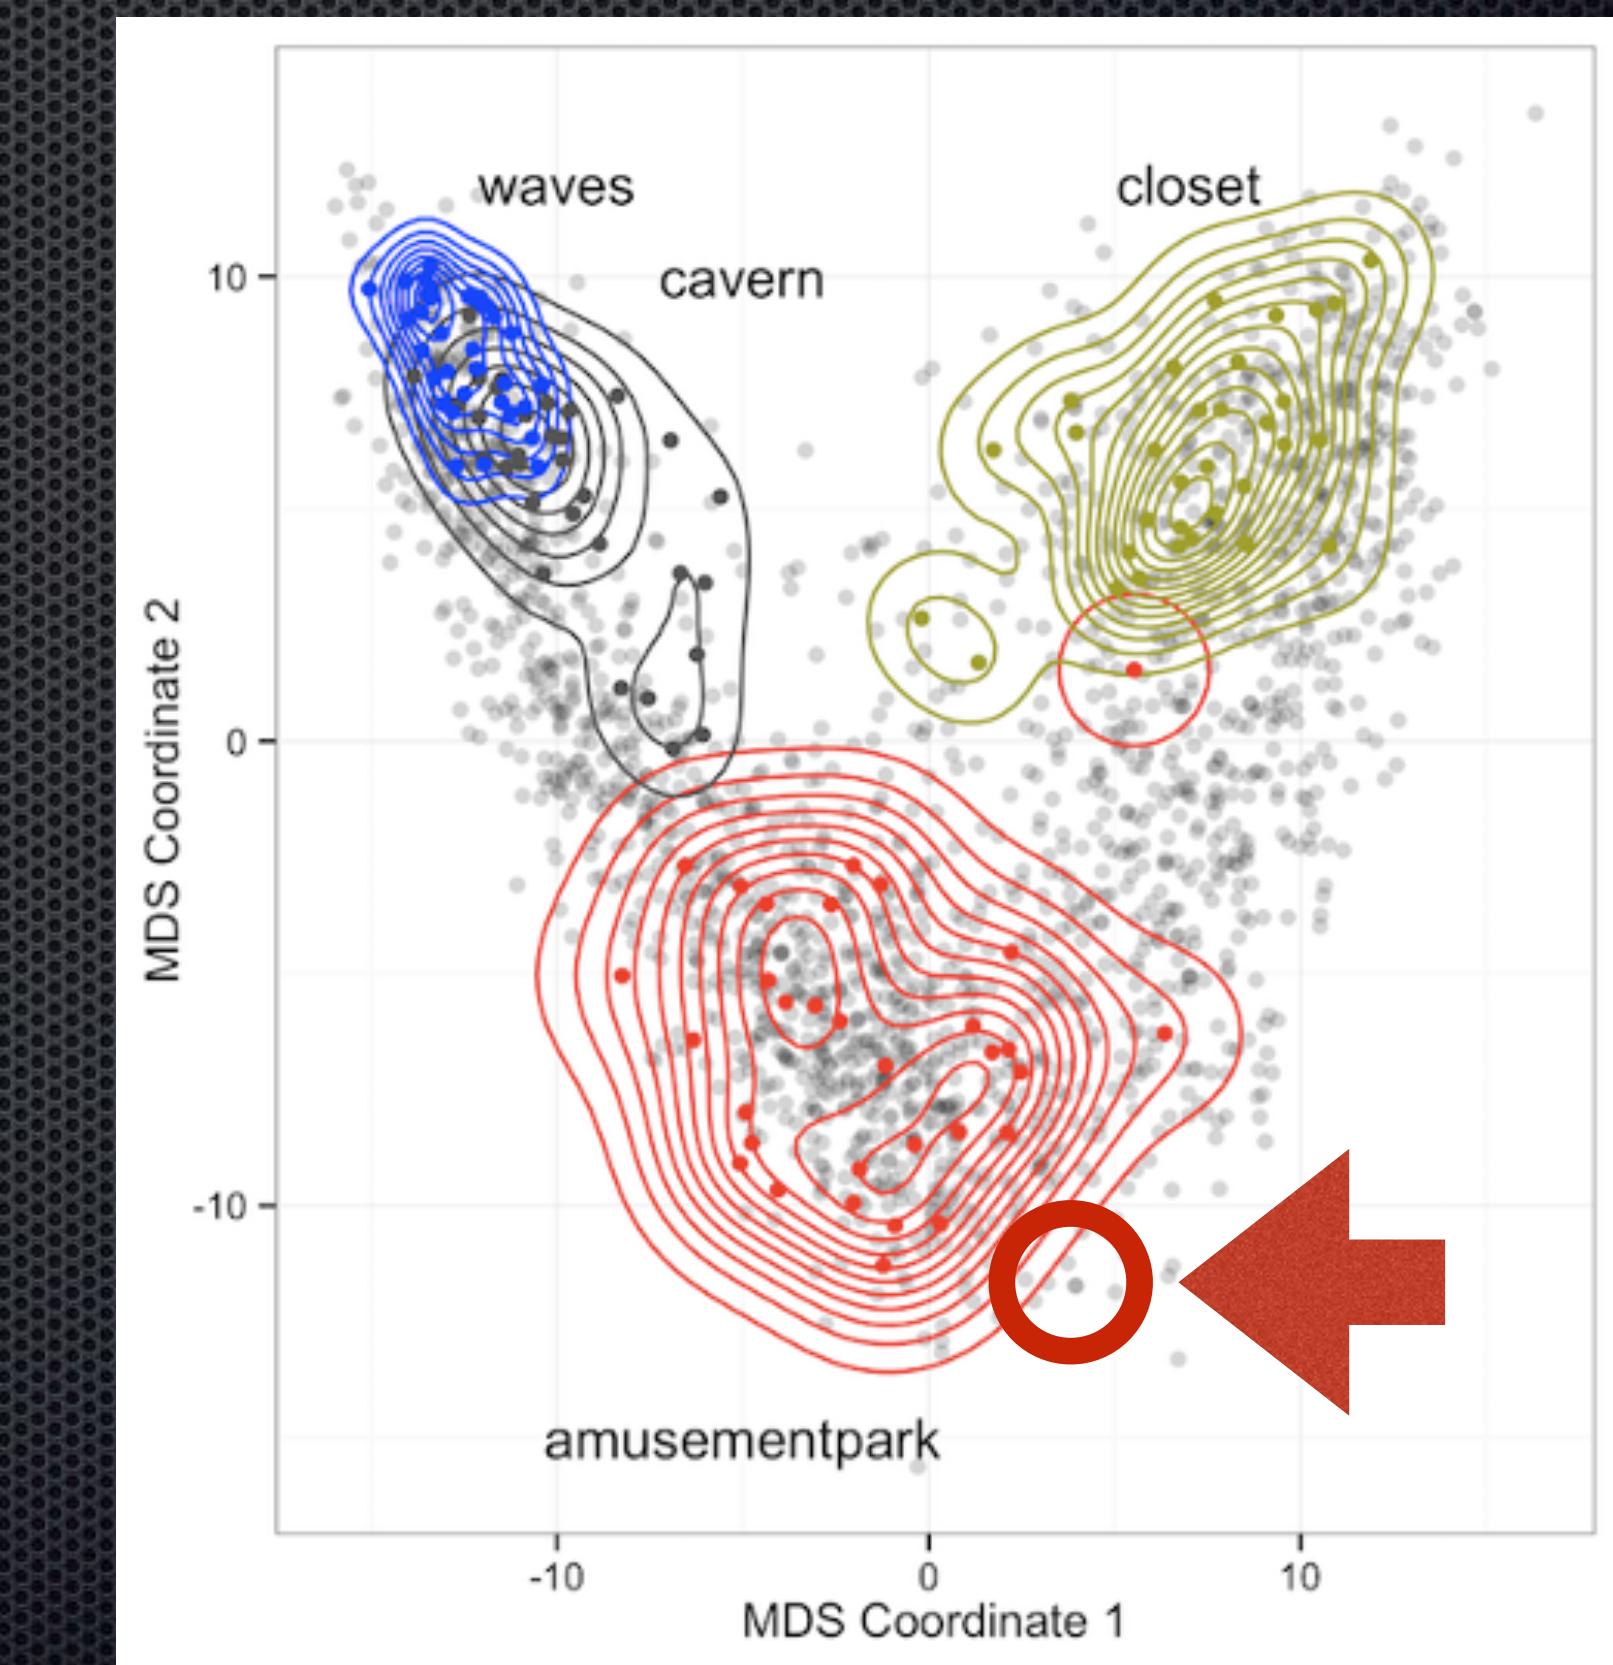
Je možné předvídat časy detekce z rozdílu obrázků?

- $r = -0.460$ ($R^2 = 0.209$)
- Lepší prediktor než plocha změny nebo ekcentricita ($R^2 = 0.077$)
- Velké množství nevysvětlené variability



Srovnání

Hash table demo

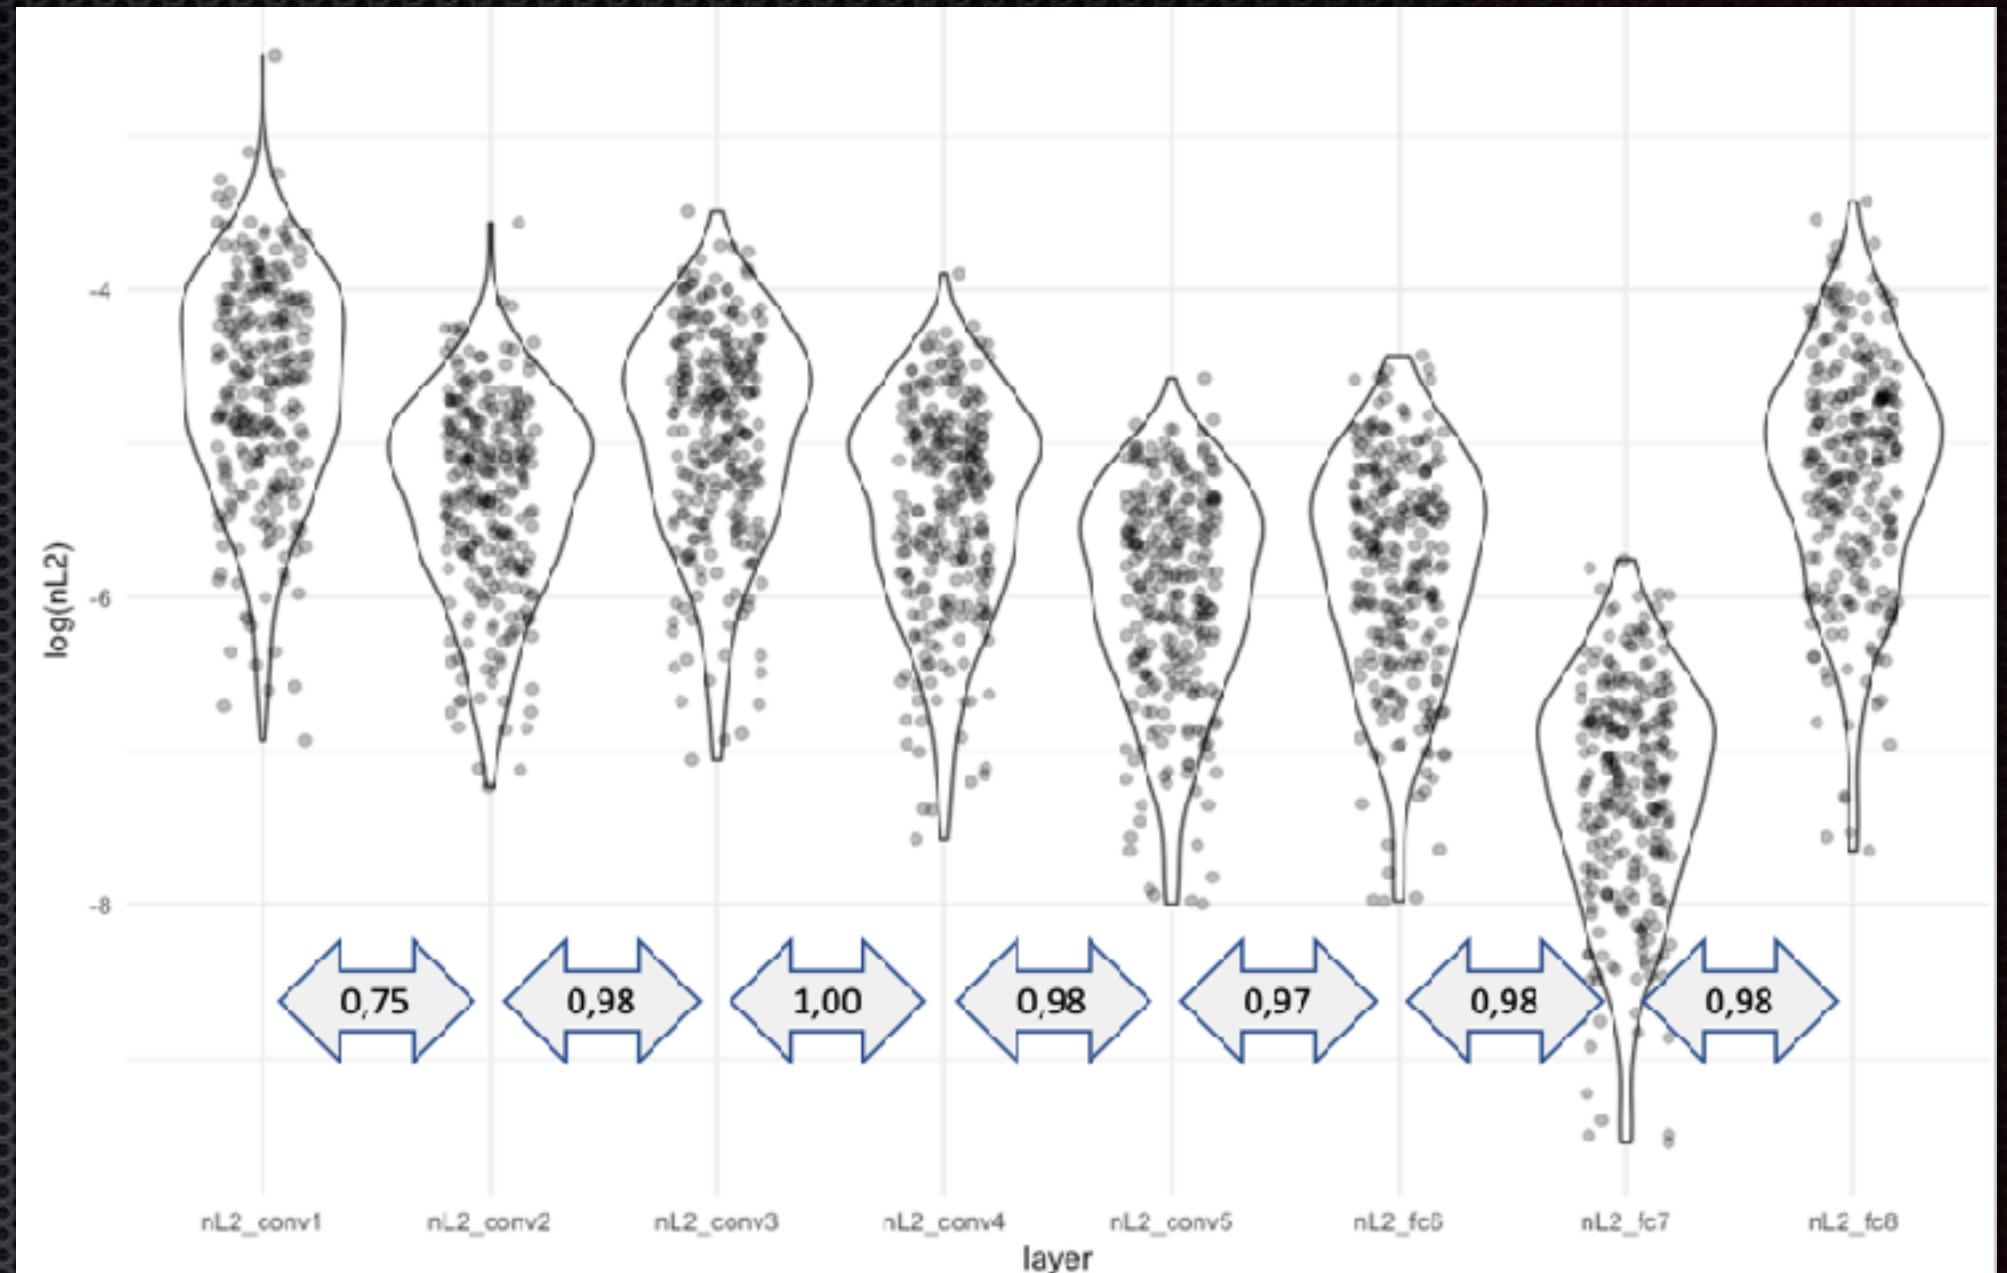


Ale...
Diskuze



AlexNet je středověk!

- AlexNet je jen jedna z možností
- Nestavíme na specifických vlastnostech AlexNetu
 - Pouze předpokládáme existenci vrstev a jejich hierarchii
 - Řada výsledků je replikovatelná pomocí jiných přístupů
 - GIST, jiné vrstvy

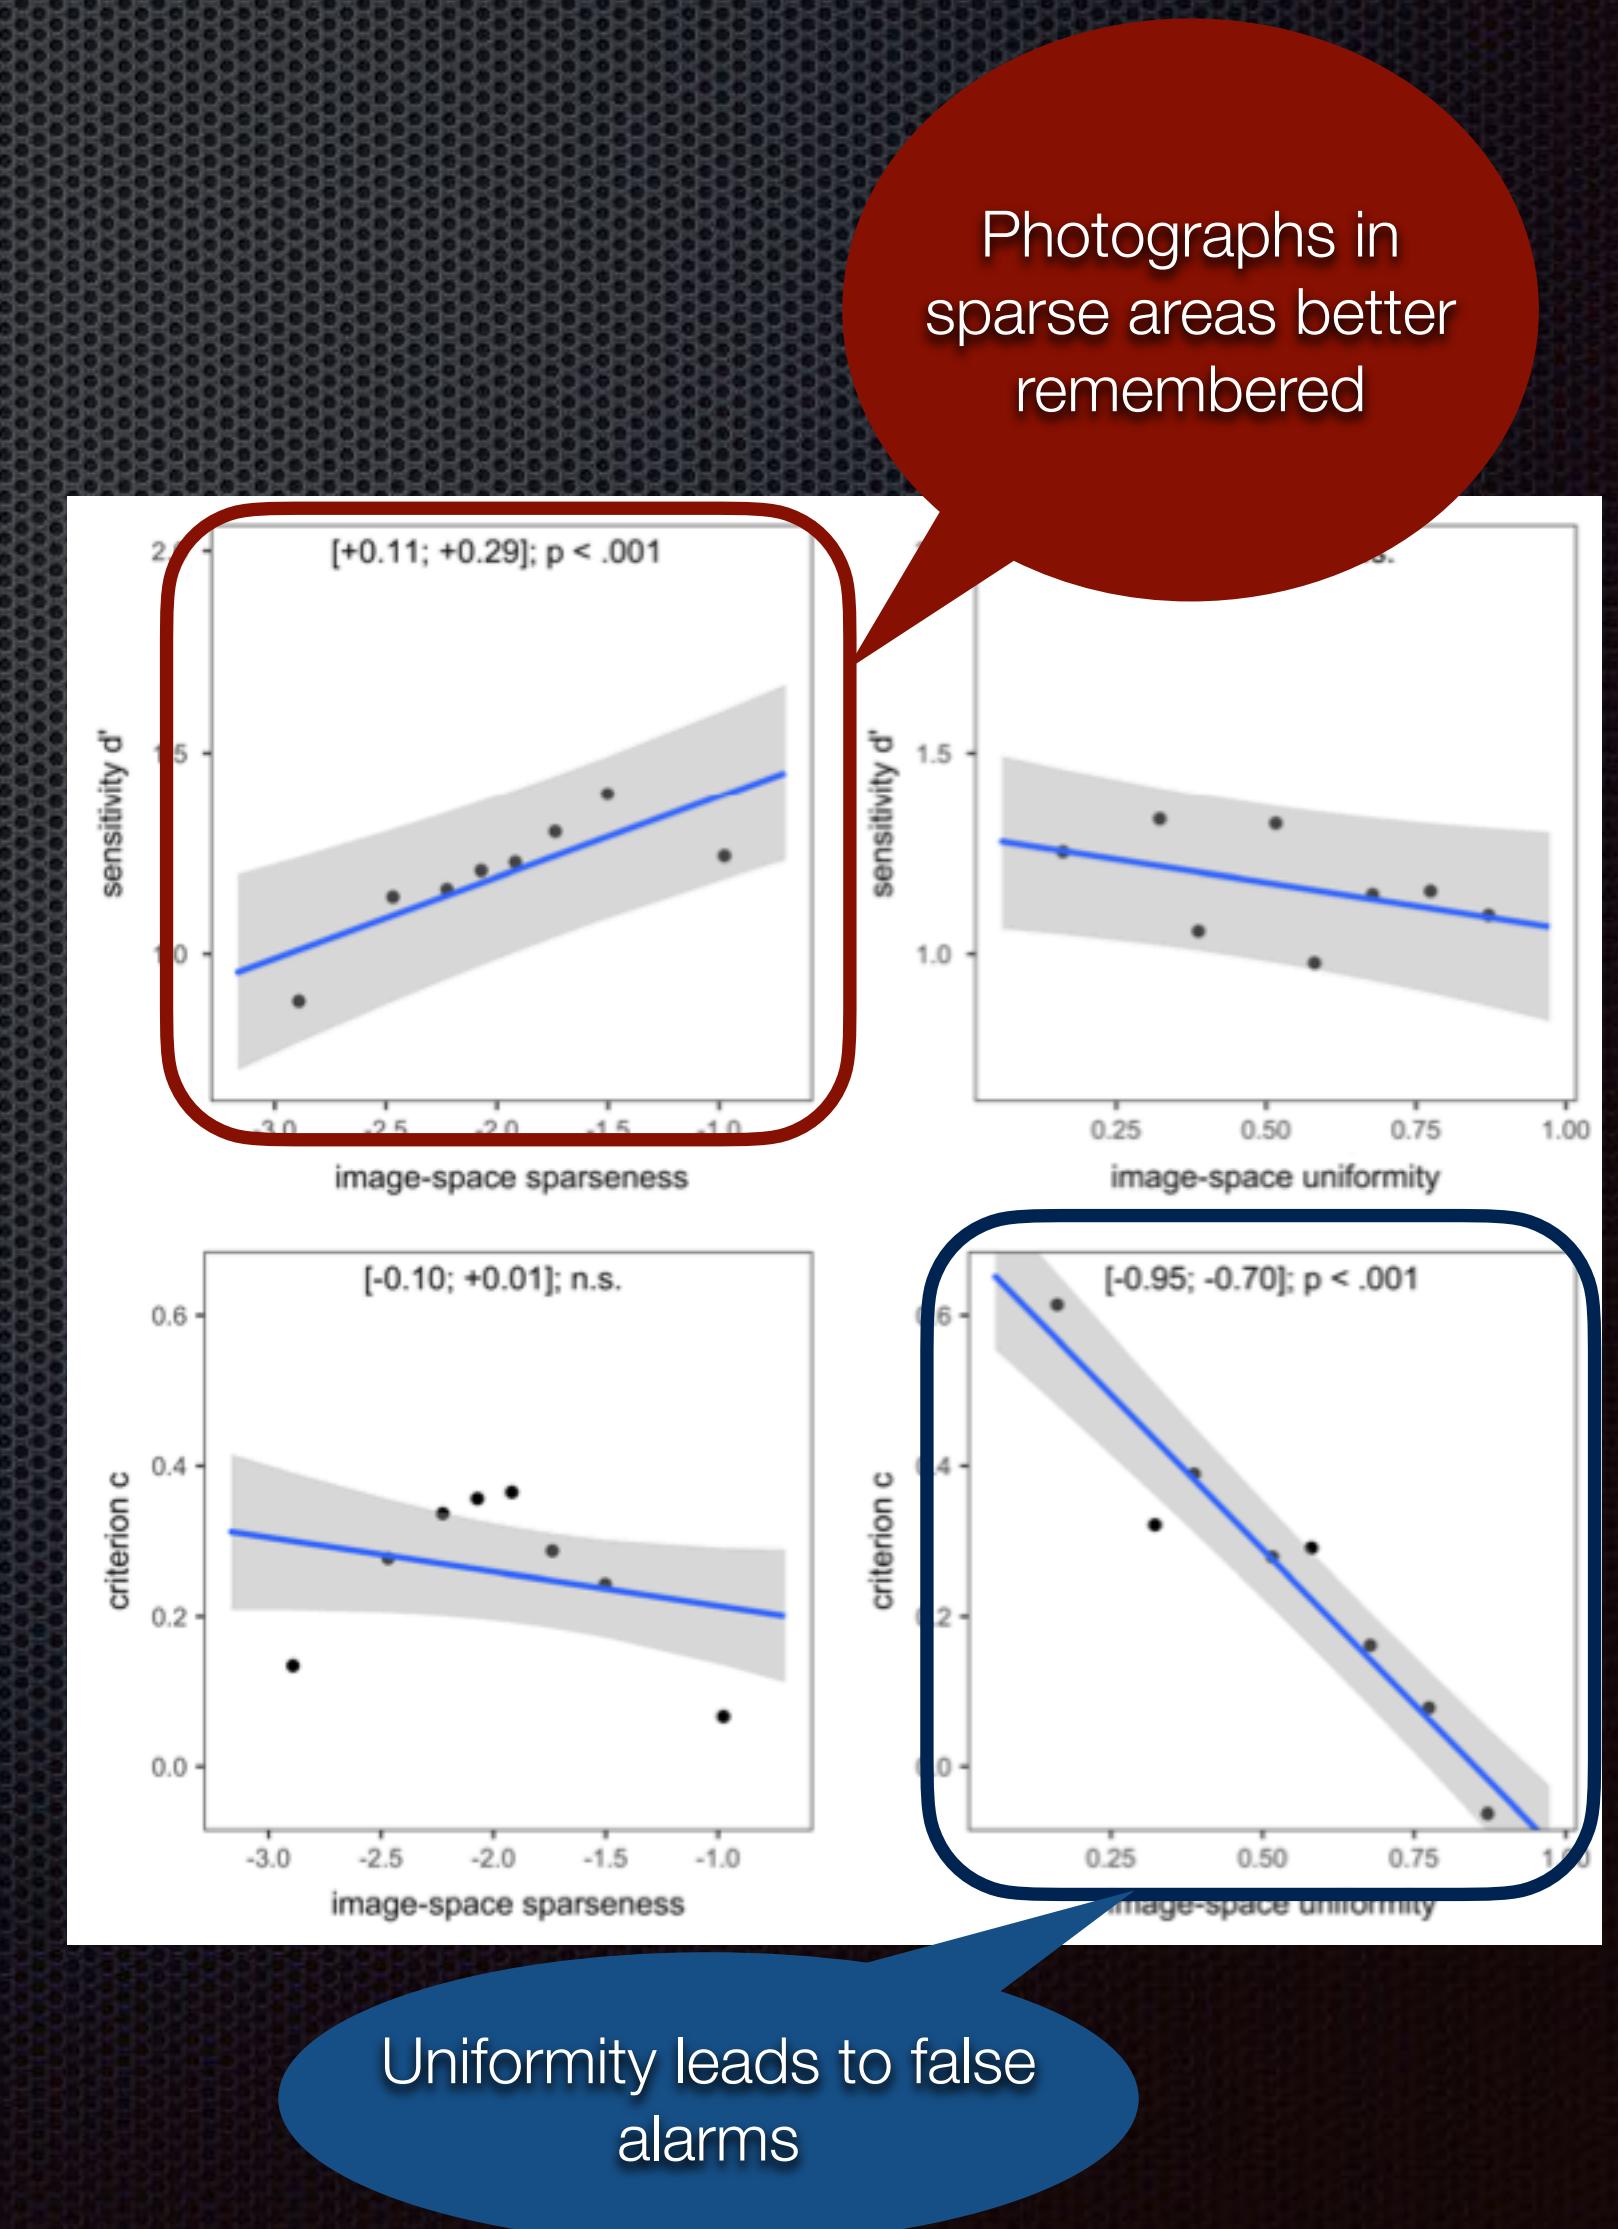


Tyto sítě byly trénovány za jiným účelem

- Naučené vzorce jsou užitečné i tak
- Transfer learning, fine-tuning

Jsou lidé ovlivněni prezentací obrazů nebo existencí obrazů?

- Exp. 1 a 2 se lišily v počtu prezentovaných fotografií
 - 400 – 960 obrázků ze sady 2048 obrázků
- Replikována hlavní zjištění



Není množství false alarms ve Photo DRM experimentu pořád dost nízké?

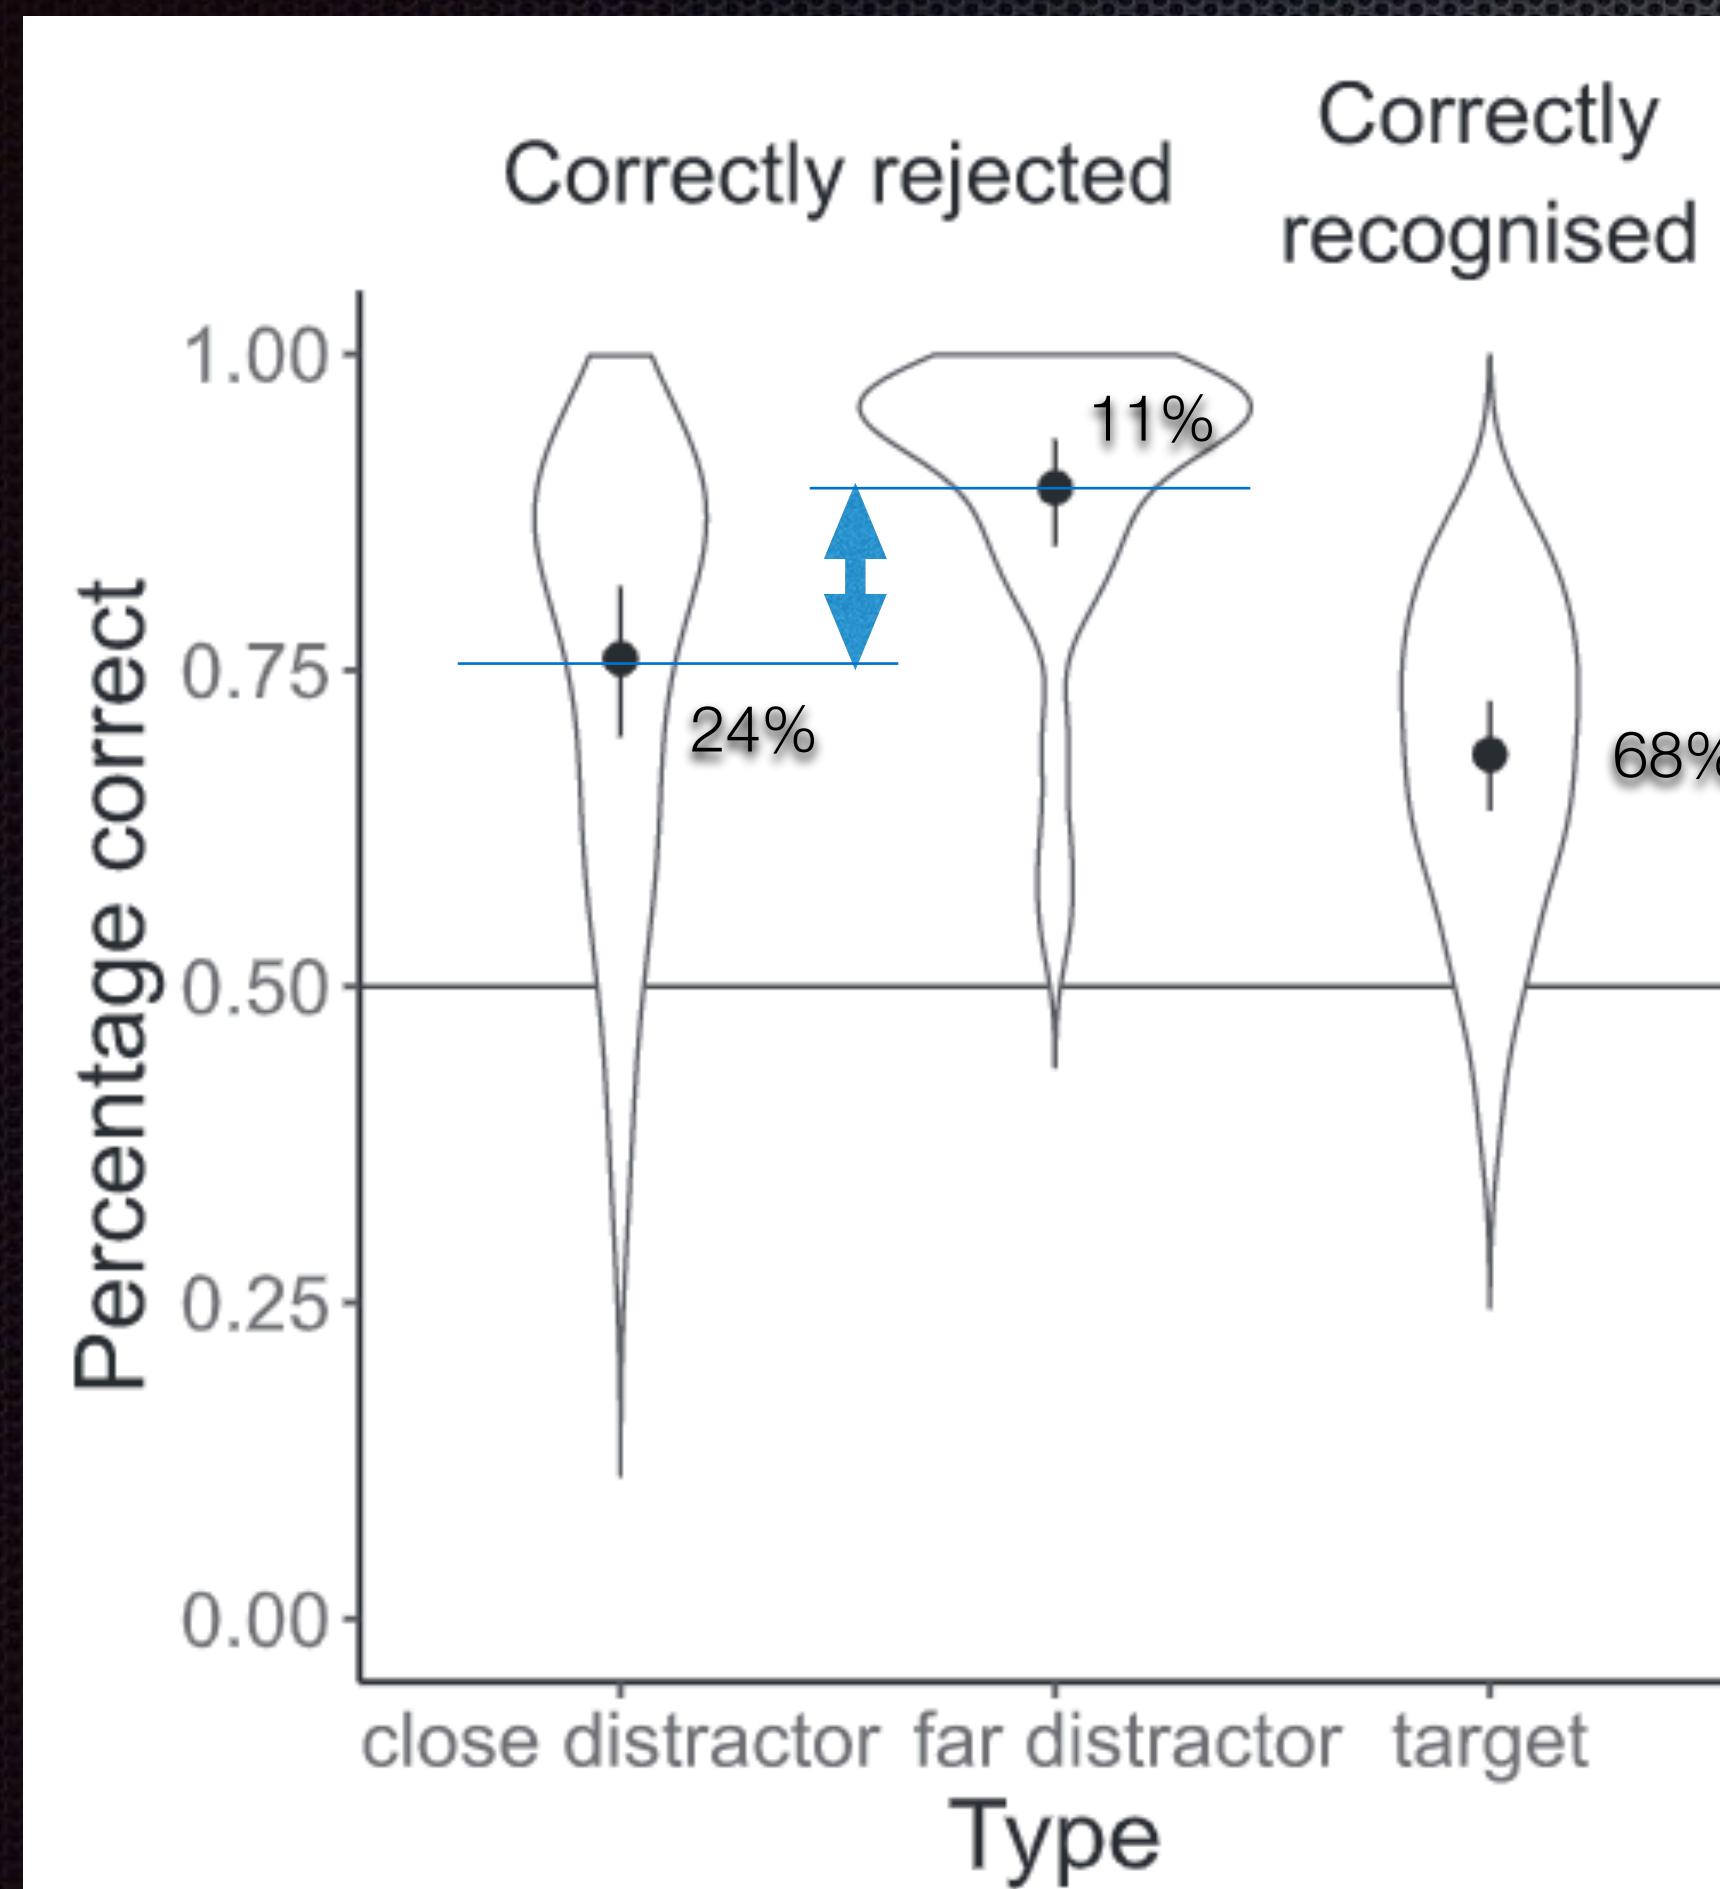


Table 1
Recognition Results for Experiment 1: The Proportion of Items Classified As Sure Old (a Rating of 4), Probably Old (3), Probably New (2), or Sure New (1) and the Mean Ratings of Items As a Function of Study Status

Study status	Old		New		Mean rating
	4	3	2	1	
Studied	.75	.11	.09	.05	3.6
Nonstudied					
Unrelated lure	.00	.02	.18	.80	1.2
Weakly related lure	.04	.17	.35	.44	1.8
Critical lure	.58	.26	.08	.08	3.3

Roediger & McDermott (1995)

Shrnutí

- Similarity-space měřený pomocí předtrénované CNN je relevantní pro lidský paměťový výkon
 - Fotografie v řídkých oblastech se lépe pamatují
 - Uniformita vede k false alarms
- Umožňuje predikci chyb/FA (DRM)
- Omezené použití pro jemná srovnání (change detection)

Díky
za pozornost

lukavsky@praha.psu.cas.cz
@jlukavsky

